Agentes Conversacionais

UNIDADE 07

Large Language Models na construção de agentes conversacionais

Sabemos que para construir agentes conversacionais, devemos seguir uma série de etapas de desenvolvimento e optar por uma solução inteiramente programada em alguma linguagem de programação ou utilizar-se de frameworks de desenvolvimento, como RASA e Dialogflow.

Independentemente de sua escolha, podemos explorar os *Large Language Models* (LLMs), ou grandes modelos de linguagem, que são modelos baseados nas mais modernas arquiteturas de redes neurais, que sustentam agentes conversacionais muito famosos e poderosos, como o chatGPT.

Nesta unidade, teremos uma visão geral sobre os **LLMs e sobre a arquitetura *transformers***, que está por trás desses modelos. Além disso, elencaremos técnicas importantes na construção destes modelos, como o ***transfer learning***, ***fine-tuning*** e ***reinforcement learning***. Por fim, vamos passar por exemplos de **aplicação dos LLMs na construção de agentes conversacionais**.

Modelos de linguagem baseados em deep learning

A última década trouxe grandes avanços para o Processamento de Linguagem Natural (PLN), pois foram desenvolvidos modelos de linguagem baseados em algoritmos de *deep learning*, sendo a geração mais atual **conhecida como *Large Language Models* (LLMs)**, que são capazes de interpretar, inferir, classificar e gerar textos com qualidade similar aos humanos. Podemos encontrar modelos especializados em responder a perguntas, simular conversas, sumarizar textos, gerar novos textos, traduzir textos, transformar texto em fala, classificar textos etc.

Arquitetura *transformers*

A principal revolução, não só na área PLN, mas também na inteligência artificial, foi a introdução da arquitetura ***transformers***, por meio da publicação do artigo *Attention is all you need*, em 2017. Ela veio para substituir as redes neurais recorrentes (RNNs), que são utilizadas em tarefas de sequência, como a geração de diálogos, pois são capazes de capturar a dependência temporal das palavras e gerar respostas coesas.

Essa arquitetura, denominada *sequence to sequence*, utiliza-se de um **mecanismo de atenção** para calcular os pesos de diferentes partes do texto de entrada. Por ser projetada para lidar com dados sequenciais, funciona perfeitamente com dados em linguagem natural que também tem natureza sequencial.

Os *transformers* são considerados ***sequence to sequence***, pois todas as tarefas atribuídas a essa arquitetura recebem como entrada uma sequência de itens, e como saída tem outra sequência de itens, conforme o exemplo de tradução automática apresentado na Figura 1.

Figura 1: Arquitetura transformers: sequence to sequence

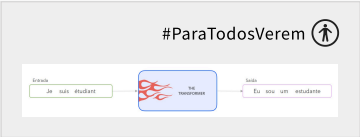

No exemplo de tradução automática, recebemos uma sequência em um idioma como entrada, e o modelo efetua a saída de uma nova sequência como saída.
Fonte: Alammar, J. (2018).

VIDEOAULA: A Arquitetura *Transformers*

No vídeo a seguir, são apresentados mais detalhes de como funciona a arquitetura *transformers* para tarefas de PNL.

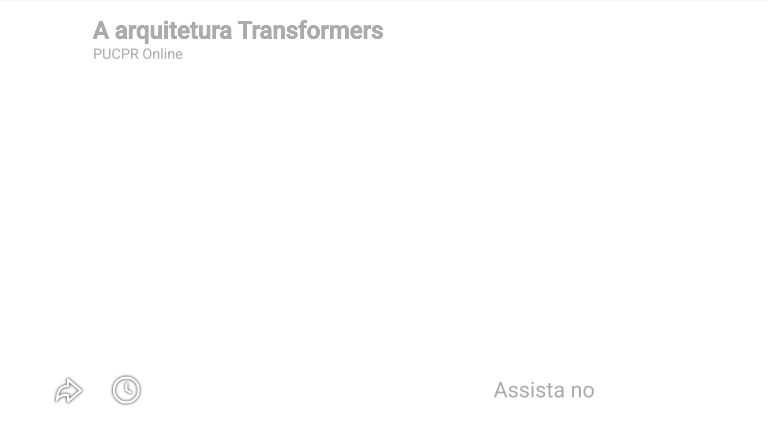

Conforme visto no vídeo, a arquitetura *transformers* é dividida em duas partes, os *encoders* e os *decoders*. Na sequência vamos entrar em mais detalhes de dois importantes modelos, cada qual baseado em uma das partes dos *transformers*, mas antes, vamos falar um pouco mais sobre a possibilidade do *fine-tuning*, que foi mencionado no vídeo.

Transfer learning e fine-tuning

Um dos grandes diferenciais, e um dos motivos pelo grande interesse nos LLMs baseados na arquitetura *transformers*, é a possibilidade de utilização da técnica de ***transfer learning***, que nos permite o reaproveitamento de modelos para realização de tarefas específicas. Esta é uma técnica já muito difundida no ramo visão computacional, que trabalha com imagens, e que com o advento dos *transformers* passou a também ser amplamente utilizada em PLN.

Para entender melhor, vamos primeiro para uma analogia na vida real. Imagine que você está aprendendo a jogar tênis. No início, você aprende os fundamentos básicos do jogo, como segurar a raquete corretamente e acertar a bola na direção certa. Depois de alguns meses de prática, você percebe que essas habilidades básicas podem ser **transferidas para outros esportes de raquete**, como o badminton ou o tênis de mesa. Mesmo que as regras e nuances de cada esporte sejam diferentes, a técnica de segurar a raquete e acertar a bola são semelhantes, e você consegue adaptar facilmente suas habilidades aprendidas no tênis para jogar outros esportes de raquete com um pouco de prática adicional. Da mesma forma, no aprendizado de máquina, **o *transfer learning* ocorre quando um modelo treinado em uma tarefa específica pode ser aproveitado para realizar outra tarefa relacionada, economizando tempo e recursos para recriar um novo modelo do zero**.

Quando aplicamos o *transfer learning*, executamos um processo chamado ***fine-tuning***, que envolve ajustar um modelo pré-treinado em uma tarefa específica, utilizando um novo conjunto de dados relacionado àquela tarefa. Inicialmente, os pesos do modelo pré-treinado são congelados e, em seguida, são atualizados de acordo com os dados do novo conjunto de dados. **Isso permite que o modelo pré-treinado se adapte às características específicas do novo conjunto de dados**, para que possa realizar a nova tarefa com maior precisão. O processo *fine-tuning* é especialmente útil quando há uma quantidade limitada de dados disponíveis para treinar um novo modelo a partir do zero, pois permite aproveitar o conhecimento prévio do modelo pré-treinado.

A Figura 2 apresenta um diagrama que descreve as etapas de *fine-tuning*, podendo ser relacionadas ao domínio de aplicação do modelo ou a tarefa a ser executada. Na Figura 3, temos exemplificado esse mesmo caminho no caso da construção de um modelo *named entity recognition* para o contexto da saúde, além de apresentar uma etapa adicional, o *reinforcement learning from human feedback*, que ganhou muita força após o lançamento do ChatGPT, pois foi por meio dessa técnica que os modelos GPT atingiram, até então, seus melhores resultados.

Figura 2: O processo de fine-tuning

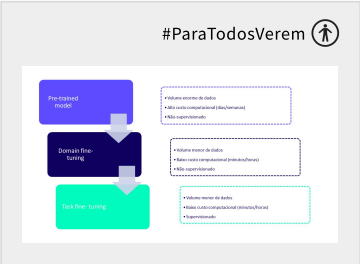

Autor (2023).

O diagrama apresentado mostra que partimos de um LLM pré-treinado (geralmente pelas *big techs*), dado o enorme custo e volume de dados. Esta etapa é completamente não supervisionada, ou seja, não é necessária a anotação de dados, e o modelo aprende relações, contextos, padrões linguísticos e conhecimento geral do idioma que em foi treinado.

Na sequência, podemos realizar o que se chama de *fine-tuning* de domínio, em que podemos atualizar nosso modelo para entender melhor o contexto que vamos trabalhar, por exemplo, eu poderia querer que meu modelo entendesse mais do domínio do direito e texto legais, portanto, eu poderia realizar o ajuste do mesmo para este tipo de texto. Esta etapa é não supervisionada, e pode ser considerada uma continuidade do pré-treinamento.

Ao final, podemos realizar o *fine-tuning* para a tarefa que desejamos que nosso modelo realize, como sumarização de texto, análise de sentimentos, *named entity recognition* etc. Esta é uma etapa supervisionada e exige anotação de textos para que o modelo aprenda a realizar a tarefa, porém, se compararmos às abordagens tradicionais de *machine learning*, precisamos de um volume muito mais baixo de supervisão, visto que nosso modelo já compreende muito bem os textos daquele idioma e domínio, e o processo de treinamento é muito mais focado na tarefa em si.

Vale lembrar que, por serem treinados em grandes volumes de dados reais, estes modelos podem refletir e amplificar os vieses existentes nos dados de treinamento, o que pode resultar em respostas que não são necessariamente neutras e imparciais. É importante ter cuidado para mitigar esses vieses durante o desenvolvimento de agentes conversacionais.

Figura 3: Exemplo de fine-tuning em uma tarefa de NER para saúde.

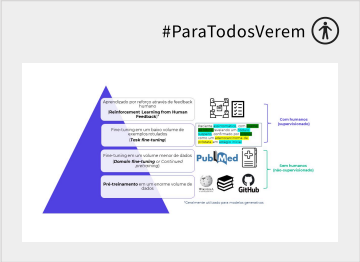

Autor (2023).

As etapas na construção de um modelo de NER para saúde poderiam envolver primeiramente o pré-treinamento de um modelo em um grande volume de dados textuais abertos, disponíveis na internet por exemplo. Depois poderíamos utilizar dados de saúde provindos da literatura médica e de prontuários de pacientes para realizar o *fine-tuning* para o domínio biomédico. Ao final, precisaríamos imputar no processo de *fine-tuning* dados de saúde anotados, para que ele aprenda a realizar a tarefa em questão. Está também ilustrada uma última etapa possível, o *Reinforcement Learning from Human Feedback* (RLHF), que é uma abordagem de aprendizado por reforço onde um agente aprende a partir do feedback fornecido por seres humanos, permitindo treinamento mais rápido e eficiente em tarefas complexas.

Você pode ir mais a fundo no processo de RLHF nos *links* da própria documentação oficial da OpenAI (criadora do ChatGPT), ou na publicação do HuggingFace.

- https://openai.com/research/learning-from-human-preferences
- https://openai.com/research/instruction-following
- https://huggingface.co/blog/rlhf

Generative Pre-trained Transformer (GPT)

O GPT-2 é um modelo de linguagem generativo, **baseado nos *decoders* da arquitetura *transformers***, desenvolvido pela OpenAI. Ele se destaca pela incrível capacidade de gerar textos que parecem escritos por humanos. Já existem versões mais atuais do GPT, como o GPT-3 e GPT-4, que não tem diferenças de arquitetura substanciais se comparados com seu antecessor, mas se diferem principalmente no **volume de dados** utilizados em seu treinamento e **quantidade de parâmetros** agregados ao modelo, o que já se comprovou muito eficaz na melhoria do desempenho destes modelos.

Desde sua criação, houve um interesse muito grande na utilização destes modelos generativos na construção de agentes conversacionais, principalmente com o advento de um produto que foi fruto da evolução destes modelos, o **ChatGPT.** Importante ressaltar, que **o ChatGPT não é um modelo de linguagem, mas sim um produto** (*i.e.*, agente conversacional) que faz uso de diversos LLMs, como o GPT-3 e GPT-4. Na Figura 4 você pode ver o histórico de atualizações do GPT, e na Figura 5 o grande aumento de interesse em LLMs na literatura científica conforme estes modelos foram evoluindo.

Figura 4: Do GPT-1 até o chatGPT

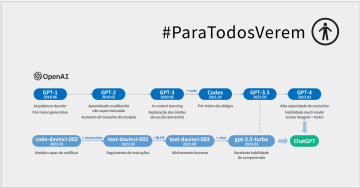

Zhao, W. et. al.(2023). A Survey of Large Language Models.

A Figura apresentada representa uma breve ilustração da evolução técnica dos modelos da série GPT. A linha do tempo foi baseada no lançamento de artigos científicos, artigos de *blog* e APIs oficiais da OpenAI. As linhas sólidas denotam que existe uma evidência explícita (por exemplo, a declaração oficial de que um novo modelo é desenvolvido com base em um modelo-base) no caminho da evolução entre dois modelos, enquanto as linhas tracejadas denotam uma relação de evolução relativamente mais fraca. Para ter acesso ao artigo desta imagem, clique aqui.

Figura 5: Aumento no interesse por Large Language Models

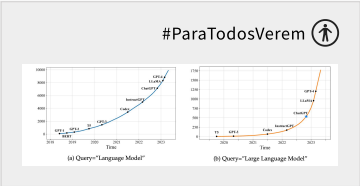

Zhao, W. et. al.(2023). A Survey of Large Language Models.

Os modelos baseados na série GPT tem potencial para serem tanto um agente conversacional *end-to-end* quanto para apoiar tarefas específicas deste contexto, como gerar textos sobre algum assunto, responder FAQs, traduzir textos, sumarizar textos, correção ortográfica etc.

Modelo Bidirectional Encoder Representations from Transformers (BERT)

O BERT é um modelo de linguagem **baseado nos *encoders* da arquitetura *transformers***, desenvolvido pelo Google. Como resultado de seu pré-treinamento em enormes bases de dados de textos, com alguns processos de ajustes (i.e., *fine-tuning*), ele pode produzir modelos com performance estado da arte em diversas tarefas de PLN, como *named entity recognition*, *question answering*, inferência de linguagem e classificação de textos.

Como o BERT não é um modelo generativo como o GPT, não é comumente utilizado para gerar conversações, porém, pode fornecer funcionalidades importantes a um agente conversacional e ser utilizado para classificação de *intents*, ou até mesmo encontrar respostas acerca de algum assunto questionado pelo usuário. Um exemplo disso pode ser visto na nesta publicação, em que os autores desenvolvem um *chatbot* de serviços financeiros baseado no BERT.

A seguir, você entenderá como é possível aplicar um modelo baseado em BERT para apoiar tarefas de um agente conversacional. Neste exemplo, vamos trabalhar com um agente de diálogo voltado para *question-answering*.

DOCUMENTOS
Notebook

Acesse o *notebook* contendo o código-fonte do agente de diálogo de *question-answering*.

https://colab.research.google.com/drive/1TWLi9oDkWtD4cnEzbj2Zta8c0FanwgP6?usp=sharing

Fonte: Autor (2021).

Construção de agentes conversacionais baseados em LLMs

Figura 6: Histórico de Large Language Models

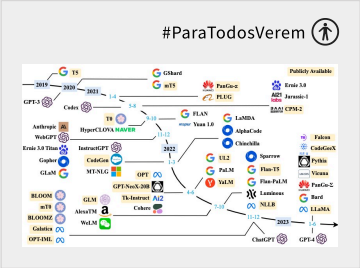

Zhao, W. et. al.(2023). A Survey of Large Language Models.

Os LLMs com melhor desempenho em suas tarefas tendem a **exigir consideráveis recursos computacionais**, como poder de processamento e memória. Implementá-los em Agentes Conversacionais de grande escala pode ser um desafio em termos de infraestrutura e custos, mesmo com estes custos estarem a cada dia mais baixos.

Com o avanço na utilização dos LLMs, vários serviços já disponibilizam APIs para acessar estes recursos em um custo geralmente calculado por volume de informação, como a OpenAI (criadora do ChatGPT). **No início do desenvolvimento de um agente conversacional é recomendada a utilização deste tipo de API**, pois já pode-se entender se o serviço que se está tentando desenvolver é promissor, e consegue ter boa performance por meio dos LLMs, especialmente quando se trata da API da OpenAI, que possui acesso ao GPT-3 e GPT-4, que tem resultados estado da arte em diversas tarefas.

Porém, a utilização exclusiva de LLMs isolados, pode não ser suficiente para criar um agente conversacional verdadeiramente útil e poderoso. Isto geralmente é atingido quando podemos combinar os LLMs com múltiplas fontes de computação e conhecimento.

Para tal, existe um ***framework* chamado LangChain**, que nos permite acessar o poder dos LLMs e integrá-los com diversas outras tecnologias de manipulação de informação, para construirmos grandes aplicações baseadas em conversação.

No *link* a seguir, você vai encontrar um notebook que demonstra como construir um agente conversacional que responda perguntas sobre uma determinada coleção de documentos, como se fosse um ChatGPT de um tema específico. O algoritmo pode ser facilmente adaptado para qualquer coleção de documentos desejada, como relatórios de uma empresa, artigos científicos, posts de um *blog* etc.

DOCUMENTOS
Notebook

Acesse o notebook contendo o código-fonte do agente conversacional construído com LangChain e acesso a API da OpenAI.

https://colab.research.google.com/drive/1-dQYFeLSAbYZexA9pHVgm29u96pIbSUT

Fonte: Autor (2023).

Conclusão

Aqui acaba a unidade, na qual você:

- Conheceu alguns modelos de linguagem baseados na arquitetura *transformers*.
- Foi apresentado aos conceitos de *transfer learning* e *fine-tuning*.
- Testou a utilização de LLMs na construção de agentes conversacionais

Referências Bibliográficas

ALAMMAR, J. The Illustrated Transformer. **GitHub**, Jay Alammar, 2018. Disponível em: http://jalammar.github.io/illustrated-transformer/. Acesso em: 15 dez. 2020.

DATA SCIENCE ACADEMY. **Deep Learning Book**, 2021. Disponível em: https://www.deeplearningbook.com.br/. Acesso em: 15 dez. 2020.

DEVLIN, J.; CHANG, M.; LEE, K.; TOUTANOVA, K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. **Cornell University**, Nova York, 2019. Disponível em: https://arxiv.org/pdf/1810.04805.pdf. Acesso em: 15 dez. 2020.

GUILLOU, P. NLP | Modelo de Question Answering em qualquer idioma baseado no BERT base (estudo de caso em português). **Medium**, 2020. Disponível em: https://medium.com/@pierre_guillou/nlp-modelo-de-question-answering-em-qualquer-idioma-baseado-no-bert-base-estudo-de-caso-em-12093d385e78. Acesso em: 15 dez. 2020.

RADFORD, A.; WU, J.; CHILD, R.; LUAN, D.; AMODEI, D. **Language Models are Unsupervised Multitask Learners**. 2018. Disponível em: https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf. Acesso em: 15 dez. 2020.

VASWANI A., SHAZEER N., PARMAR N, USZKOREIT J., JONES L., GOMEZ A. N., KAISER L., POLOSUKHIN I. Attention Is All You Need. **Cornell University**, Nova York, 2017. Disponível em: https://arxiv.org/pdf/1706.03762.pdf. Acesso em: 15 dez. 2020.

© PUCPR - Todos os direitos reservados.