Agentes Conversacionais

UNIDADE 08

Avaliação e implantação de agentes conversacionais

*Como etapas finais, e cruciais, no desenvolvimento de agentes conversacionais, são encontradas a **avaliação** e a **implantação** dos sistemas construídos. Nesta Unidade, você será apresentado a uma série de métricas de avaliação de chatbots e agentes de diálogo, que geralmente são distintas para cada tipo de agente conversacional. Por fim, serão listadas as principais possibilidades para implantação dos agentes, etapa esta que pode ser muito facilitada se aproveitarmos vários dos serviços de nuvem disponíveis, e principalmente, os frameworks que automatizam este processo.*

Avaliação de agentes conversacionais

A avaliação de agentes conversacionais, em sua grande maioria, é **feita por humanos**. Ao contrário de grande parte das tarefas de processamento de linguagem natural e *machine learning* (*e.g.*, classificação de textos, extração de informação, regressão etc.), o uso de métricas e metodologias de avaliação automática ainda tem limitações no que se refere a agentes.

Apesar disso, metodologias de avaliação automática são um recurso desejável e em constante progresso pela comunidade científica (*i.e.*, revisão sobre processos de avaliação automática de agentes conversacionais), pois a sua utilização reduziria o custo operacional na realização da avaliação, que quando feita exclusivamente por humanos, necessita de muito tempo, e por vezes, recursos financeiros para sua execução.

A **importância da avaliação** pode ser evidenciada por alguns motivos:

1- Para os **desenvolvedores**, é essencial determinar se o sistema funciona conforme o esperado.

2- Para os **usuários**, é importante saber se o sistema:

- Atende às necessidades do usuário.
- Compreende as suas interações.
- O auxilia na execução eficaz de suas tarefas (no caso de agentes de diálogo baseado em tarefas).
- Provê uma experiência agradável (no caso de *chatbots* que não sejam baseados em tarefas).

3- Para os **pesquisadores**, é necessário estabelecer se os objetivos de pesquisa foram atingidos (*e.g.*, validação de uma nova técnica ou *benchmarking* contra outro sistema estado da arte).

A avaliação, geralmente, pode ser conduzida de duas maneiras:

- **Avaliação por participante**, que ocorre quando o próprio humano que entrou em contato com o agente que realiza a avaliação.
- **Avaliação por observador**, que ocorre quando um humano que não entrou em contato com o agente tem acesso a *scripts* de conversação entre o agente e outro humano, ou até mesmo a gravações das interações entre eles, e assim, realiza a avaliação.

Independentemente da condução de avaliação escolhida, **ainda não há na literatura um método definitivo para a avaliação de agentes conversacionais**. Os mais diversos estudos na área geralmente apresentam avaliações similares, porém com algumas variações de acordo com a necessidade ou vontade do pesquisador/desenvolvedor.

Avaliação por participante

O cenário de avaliação por participante geralmente é realizado por meio do preenchimento de um formulário por parte do usuário, após a utilização do sistema por um tempo/interações pré-determinados. Neste formulário, o usuário pode **avaliar diversas características do modelo**, comumente no formato múltipla escolha, utilizando uma escala, como a de Likert (conforme o exemplo apresentado na Figura 1). A seguir, confira algumas características que podemos avaliar:

- Qualidade conversacional.
- Fluência.
- Repetição de diálogo.
- Interesse do usuário.
- Coerência das frases.
- Engajamento.
- Comportamento humano.

Figura 1: Exemplo de avaliação por participante

#ParaTodosVerem

[Envolvimento] Você gostou de conversar com este usuário?
- De jeito nenhum
- Um pouco
- De alguma forma
- Bastante

[Interesse] Você achou esta conversa interessante ou chata?
- Muito chata
- Um pouco entediante
- Um pouco interessante
- Muito interessante

[Curiosidade] Quanto o usuário tentou conhecê-lo?
- Não perguntou nada sobre mim
- Perguntou um pouco sobre mim
- Perguntou muito sobre mim
- Perguntou em excesso sobre mim

[Atenção] Quanto o usuário pareceu prestar atenção ao que você disse?
- Sempre ignorou o que eu disse
- Ignorou o que eu disse na maioria das vezes
- Prestou atenção ao que eu disse na maioria das vezes
- Sempre prestou atenção ao que eu disse

[Evitar a Repetição] Quão repetitivo era este usuário?
- Repetiu-se continuamente
- Às vezes dizia a mesma coisa duas vezes
- Sempre disse algo novo

[Fluência] Com que naturalidade esse usuário falava inglês?
- Muito não natural
- Não natural na maioria das vezes
- Natural na maioria das vezes
- Muito natural

[Fazer sentido] Com que frequência esse usuário disse algo que NÃO fazia sentido?
- Nunca fez sentido
- A maioria das respostas não fazia sentido
- Algumas respostas não faziam sentido
- Tudo fez sentido perfeitamente

[Humanidade] Você acha que este usuário é um *bot* ou um humano?
- Definitivamente um *bot*
- Provavelmente um *bot*
- Provavelmente um humano
- Definitivamente um humano

[Resgate de Persona] Qual comando (característica) você acha que o outro usuário recebeu nesta conversa?
Entrevistado escolhe uma das duas personas fornecidas

Formulário de avaliação do estudo de See et al. (2019), que contém diversas características do modelo dispostas em escalas para avaliação. Fonte: Traduzido de See *et al.* (2019).

As características podem estar associadas ao **conteúdo** textual pelo agente enviado ao usuário durante as interações, ou associadas à **satisfação do usuário** ao utilizar o sistema. Até mesmo **aspectos funcionais** do sistema também podem ser avaliados. A granularidade das características avaliadas também varia muito, podendo ser relacionadas a aspectos mais gerais, por exemplo: qualidade do agente ou características mais específicas, como as listadas anteriormente.

Há ainda outras classificações de avaliação por participante, quanto ao ambiente de execução dela, conforme as três categorias apresentadas a seguir.

1) Avaliação em laboratório: os participantes realizam a avaliação em um ambiente controlado, e nem sempre representam o público real de usuários do agente. No ambiente acadêmico, por exemplo, é comum utilizar estudantes para realizar a avaliação, mesmo que o público real do agente seja outro. Neste tipo de avaliação, os procedimentos são bem controlados, e vários cenários podem ser investigados, permitindo que dados confiáveis e em uma boa quantidade sejam coletados. Talvez o principal problema da avaliação em laboratório é que talvez ela não reflita a utilização do agente em um ambiente real. Por exemplo, em um agente que auxilie no atendimento a pacientes com suspeita de AVC, uma avaliação em laboratório nunca conseguirá refletir o uso real do agente, que envolve um paciente com sintomas que podem levá-lo a comportamentos inesperados.

2) Avaliação em campo: coleta o *feedback* de usuários reais do agente conversacional. Um exemplo disso são as avaliações de satisfação que você responde ao final de uma sessão com um *chatbot* de alguma empresa. Da mesma maneira que geralmente fornecem *insights* mais alinhados com a realidade de uso do agente, a avaliação em campo pode sofrer com a falta de engajamento do usuário para realizar a avaliação ao final da utilização.

3) ***Crowdsourcing***: envolve a utilização de usuários recrutados pela internet para realizar o processo de avaliação. Este processo pode ser voluntário (geralmente é o caso quando se trata de algum projeto *open-source*), porém, há uma tendência de mercado em remunerar participantes e recrutá-los por meio de plataformas de *crowdsourcing*, como o Amazon Mechanical Turk. Esta é a maneira mais fácil para se obter um grande volume de avaliação, mesmo podendo trazer consequências quanto a sua confiabilidade e qualidade.

Em suma, é importante estar ciente dos efeitos dos diferentes ambientes e tipos de usuários sobre os resultados que podem ser obtidos nas avaliações. Embora os ambientes de laboratório forneçam maior controle experimental, eles não refletem necessariamente como os usuários em ambientes reais interagem com o agente. Outro problema é como recrutar usuários suficientes para a avaliação, pois pode ser caro, tanto em tempo quanto em dinheiro, para executar tais processos. Problema este que é resolvido com o *crowdsourcing*, que por sua vez, pode trazer problemas de qualidade.

Avaliação por observador

A avaliação por observador conta com avaliadores que não tiveram contato com o agente conversacional, mas acesso às interações entre agente e outros usuários, seja em forma de texto, ou até mesmo de vídeo ou gravação de tela.

Há algumas maneiras de se realizar esta avaliação, por exemplo: podemos pedir que os avaliadores designem pontuações para cada interação do agente, ou até mesmo comparar *outputs* de sistemas distintos e o avaliador definir qual deles funcionou melhor, conforme o exemplo apresentado na Figura 2.

Figura 2: Exemplo de avaliação por observador

#ParaTodosVerem

Avaliação chamada de ACUTE-EVAL, proposta por Li, Wetson e Roller do Facebook AI Research, em que o observador deve escolher entre o agente 1 (azul claro) e o agente 2 (azul escuro). Fonte: Traduzido de Li; Weston; Roller (2019).

As características a serem avaliadas pelo observador podem seguir a mesma linha de quando a avaliação é feita pelo participante, assim como as classificações quanto ao ambiente de execução da avaliação.

Avaliação de agentes de diálogo baseados em tarefas

Além de todas as questões apresentadas até o momento, devemos ter um olhar especial quando estamos tratando de sistemas de diálogo baseado em tarefas. A natureza do diálogo deste tipo de agente é muito mais estruturada, pois são fluxos conversacionais muitas vezes pré-definidos para obtenção de dados do usuário e consequente realização de tarefas (*e.g.*, agendar uma consulta médica, solicitar segunda via de boleto etc.). Geralmente com poucas interações é alcançado ao objetivo final e a satisfação do usuário.

Devido a estas características, os estudos geralmente não focam muito no conteúdo textual (e.g., fluência, qualidade conversacional) produzido pelo agente, mas sim nos **aspectos funcionais**, ou diretamente na **satisfação do usuário**.

Quando se fala em medir a satisfação do usuário ou aspectos funcionais, caímos novamente nos formulários de avaliação (como o apresentado na Figura 1), porém, com características que não são voltadas ao conteúdo textual gerado, mas sim, **atributos qualitativos e subjetivos** relacionados à experiência do usuário com o agente. Uma ferramenta muito utilizada para isso é o *Subjective Assessment of Speech System Interfaces* (SASSI), desenvolvido por Hone e Graham (2000). Para avaliar um agente, o SASSI dispõe de 34 itens distribuídos ao longo de seis escalas diferentes. A seguir as seis escalas, e alguns dos 34 itens pertencentes a cada uma.

1- Acurácia da resposta do sistema (*system response accuracy*)

- O sistema é acurado.
- A interação com o sistema é consistente.
- A interação com o sistema é eficiente.

2- Simpatia pelo sistema (*likeability*)

- O sistema é útil.
- O sistema é agradável.
- Eu usaria este sistema.

3- Demanda cognitiva (*cognitive demand*)

- Me senti confiante ao utilizar o sistema.
- O sistema foi fácil de se utilizar.

4- Irritabilidade (*annoyance*)

- A interação com o sistema foi irritante.
- O sistema foi pouco flexível.

5- Habitualidade (*habitability*)

- Eu sempre soube o que dizer ao sistema.
- Eu nem sempre tive certeza do que o sistema estava fazendo.

6- Velocidade (*speed*)

- A interação com o sistema foi rápida.
- A resposta do sistema é muito devagar.

Mas o grande diferencial na avaliação de agentes de diálogo baseado em tarefas está na possibilidade de trabalhar com **métricas quantitativas**, algumas delas sendo obtidas automaticamente durante a interação do usuário, já outras sendo calculadas por anotadores ao verificar os históricos de conversação. Dentre as métricas quantitativas populares para **avaliação geral do agente**, estão:

- Sucesso da tarefa.
- Duração da tarefa.
- Número de interações do sistema.
- Número de interação do usuário.
- Número de interações de interrupção feitas pelo usuário.
- Número de interações de ajuste.
- Número de *timeouts*.
- Taxa de erro de palavras.
- Latência de resposta.

Algumas métricas adicionais mais específicas são utilizadas em agentes conversacionais comerciais (*i.e.*, centrais de contato de grandes empresas) como a taxa de acerto na transferência do consumidor ao setor correto, a taxa de contatos que não precisaram ser transferidos para humanos ou até mesmo a taxa de abandono da conversa antes da finalização da tarefa.

Por fim, ainda podemos optar por **avaliar os módulos** de nosso agente separadamente, como o *speech-to-text*, NLU, gerenciador de diálogos, NLG e *text-to-speech*. Neste caso, podemos continuar utilizando métricas quantitativas, e geralmente seguindo como uma avaliação normal de sistemas de processamento de linguagem natural ou *machine learning*. A vantagem de se avaliar cada módulo do agente é que podemos apontar exatamente onde o problema pode estar ocorrendo, por exemplo: a interação pode não ser bem-sucedida devido a uma taxa alta de erros na identificação das entidades quando o usuário vai agendar algo.

Para que fique clara a semelhança da avaliação dos módulos com as avaliações que já estamos acostumados a fazer para PLN e ML, vamos verificar como faríamos para avaliar o **módulo de NLU**. Precisamos medir a sucesso da **classificação de *intents*** e **extração de entidades**, neste caso, podemos colocar os acertos e erros em uma matriz de confusão. A seguir, confira um exemplo de agente que realiza agendamento de consultas de uma clínica médica, contendo uma amostra de 30 classificações de *intent*.

		***intent* correta**		
***intent* predita**		agendar_consulta	cancelar_consulta	alterar_consulta
	agendar_consulta	10	3	1
	cancelar_consulta	0	8	2
	alterar_consulta	0	1	5

Com base nesta matriz, podemos ver que o sistema classificou corretamente a intent agendar_consulta 10 vezes, incorretamente como cancelar_consulta três vezes e incorretamente como alterar_consulta uma vez. Na sequência, poderíamos calcular as medidas já conhecidas de *precision*, *recall* e F1.

Qual a melhor maneira de se avaliar agentes conversacionais?

Resumindo: **ainda não há uma solução definitiva para avaliação de agentes conversacionais**. Esta ainda é uma área de pesquisa em evolução, e como tal, ainda exige uma análise mais detalhada do que queremos ter como resultado no desenvolvimento de nosso agente. Levando em conta todas as considerações expostas anteriormente, temos sempre de responder algumas perguntas antes de iniciar uma avaliação:

- O agente é baseado em tarefas? Se sim, utilize métricas que estimem a satisfação do usuário por meio do sucesso na realização da tarefa, eficiência e algumas da métricas qualitativas.
- O agente não é baseado em tarefas? Neste caso, utilize métricas que estimem a qualidade da interação, como algumas previstas no ACUTE-Eval e SSA.
- Seu público-alvo estaria disposto a avaliar o produto após o uso? Realize uma avaliação por participante simples ao final da interação com o agente (*e.g.*, você está satisfeito com o resultado deste contato? A informação foi útil?).
- É uma avaliação utilizada para pesquisa acadêmica? Se o contexto do agente permitir, utilize avaliação em laboratório. Se o orçamento permitir, utilize *crowdsourcing*.
- O que é mais importante para mim, medir a eficácia de minhas técnicas de PLN ou a satisfação do usuário? Se é a primeira opção, você pode focar em métricas quantitativas e *frameworks* de avaliação automática para comprovar a eficácia de suas técnicas, focando no conteúdo produzido pelo agente e alguns aspectos funcionais. Já para a segunda opção, geralmente quando estamos produzindo um produto comercial, deve-se focar em uma avaliação mais completa ou mais focada em aspectos funcionais e de satisfação de usuário.

Implantação de agentes conversacionais

Enfim, chegamos na última etapa de desenvolvimento de agentes conversacionais, que é a sua implantação no ambiente de produção, ou seja, torná-lo acessível ao público. Assim como a avaliação, vários fatores devem ser levados em conta para decidirmos quais as melhores especificações de implantação do agente, além disso, existem várias maneiras e canais diferentes para publicar seu agente.

A seguir, listaremos algumas orientações gerais para implantação de seu agente e detalharemos o processo de implantação do seu agente quando utilizamos o *framework* Dialogflow.

Segurança e privacidade

O primeiro fator que deve ser levado em conta é a segurança e privacidade dos dados. Você deve garantir que a manipulação dos dados siga as diretivas da Lei Geral de Proteção de Dados Pessoais (**LGPD**), bem como quaisquer outras políticas relacionadas a indústria e/ou regulações locais.

Fornecer informações para o usuário com base em seu nível de autorização também é essencial, assim como definir níveis de permissão para acesso a canais e *intents* específicos de sua aplicação. E, por fim, deve-se hospedar o agente em um ambiente com encriptação de dados, utilizando-se de protocolos seguros, como o https.

Dimensionando as necessidades

O dimensionamento não é um processo simples, nem tanto uma ciência exata: ele depende de uma combinação de experiência de desenvolvimento, conhecimento da arquitetura do sistema e conhecimento sobre o domínio de aplicação.

Um levantamento deve ser feito a fim de dimensionar os recursos necessários em termos de *hardware*, *software* e de pessoal para a implantação do agente, focando nas seguintes qualidades:

- **Performance**: determinar os requisitos mínimos do sistema e analisar *use-cases* semelhantes.
- **Segurança**: quais protocolos de segurança são necessários e como eles podem afetar os recursos?
- **Disponibilidade**: existem picos de uso? Preciso pensar em redundância de serviços ou balanço de carga?
- **Custos**: quais serão os custos de todos os recursos listados anteriormente? Existe algum fator limitador?

Implantação de um agente Dialogflow

Implantar um agente conversacional construído no Dialogflow talvez seja o cenário mais simples dentre as possibilidades de agentes conversacionais, pois o *framework* já é baseado no Google Cloud, o que torna sua implantação um processo quase que automático. Apesar disso, uma estimativa de uso de seu agente também deve ser feita, pois o Dialogflow impõe alguns limites e cotas de uso, tanto para a sua versão gratuita (Dialogflow ES) quanto para a versão paga (Dialogflow CX). Os preços também devem ser consultados para estimar questões orçamentárias.

Ao criar o seu agente no Dialogflow, você já pode relacioná-lo a um Google Project associado à sua conta no Google Cloud, e uma vez que você o faça, você já pode, por meio do Google Cloud Console, subir seu agente em forma de *webservice* ou qualquer outra maneira que você desejar.

Caso você já tenha uma infraestrutura pronta e queira adicionar o agente conversacional a ela, você pode utilizar o módulo de integração para isso. Imagine que você já tenha o *website* de sua empresa hospedado em um servidor qualquer, e queira adicionar o *chatbots* ao site. Para isso, basta acessar as integrações no Dialogflow e ir na opção Dialogflow Messenger (conforme a Figura 3, apresentada a seguir). Nesta opção, será dado um código HTML para que você possa incorporar o agente em seu *site*. Lembrando que mesmo que a interface esteja em seu *website*, toda a hospedagem e "inteligência" de seu agente continuaram no Google Cloud.

Figura 3: Integração do Dialogflow em *website*

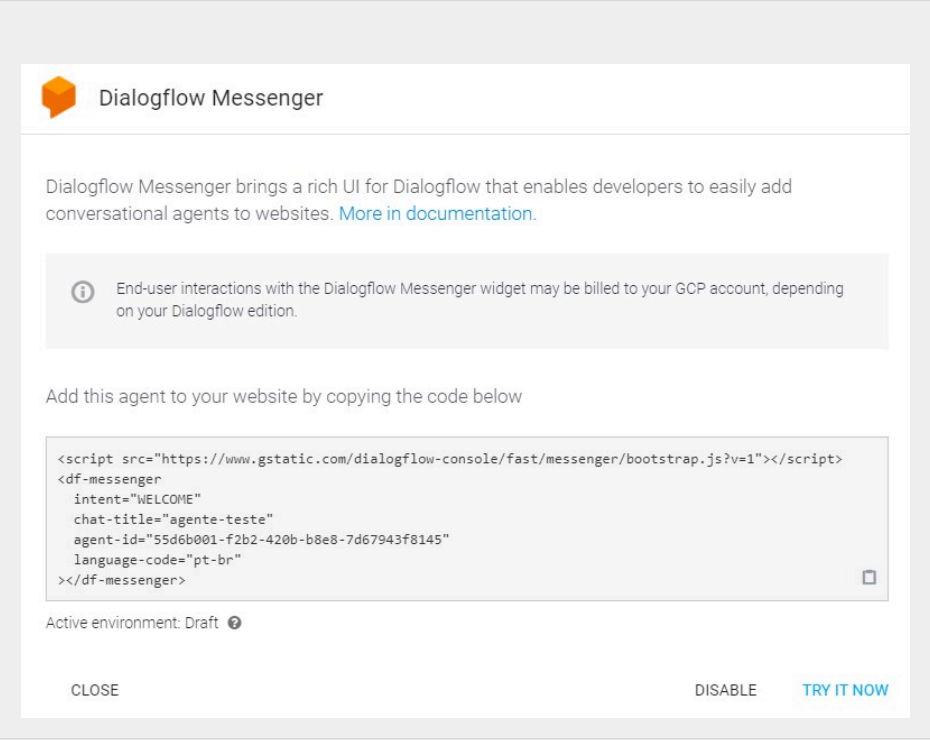

Exemplo de integração do Dialogflow em *website*, por meio de código HTML de incorporação. Fonte: Diagflow Messenger (2021).

Lembre-se: que todas possibilidades de integração e implantação estão detalhadas na documentação do Dialogflow. Na videoaula, você poderá conferir como implantar um servidor para controle de *fulfillment* na plataforma Heroku.

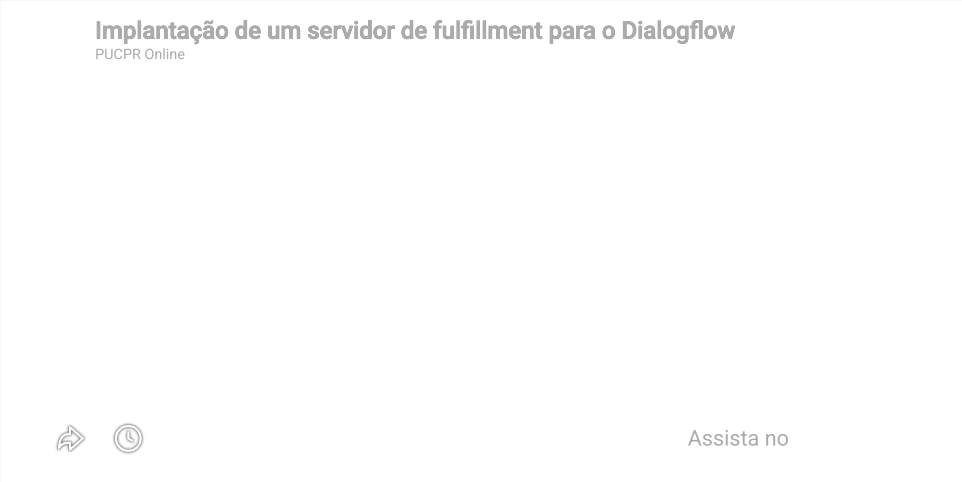

Nesta Unidade de Estudo:

- Conhecemos diversas **métricas de avaliação** de agentes.
- Entendemos os **tipos de avaliação** e seu uso recomendado.
- Verificamos **recomendações de implantação** de agentes.

Referências

DERIU, J.; RODRIGO, A.; OTEGI, A.; ECHEGOYEN, G.; ROSSET, S.; AGIRRE, E.; CIELIEBAK, M. Survey on evaluation methods for dialogue systems. **Artif Intell**, Suíça, vol. 54, p. 755-810, 2021. Disponível em: https://doi.org/10.1007/s10462-020-09866-x.

GOOGLE CLOUD. Documentação do Dialogflow ES. **Diagflow**, 2020. Disponível em: https://cloud.google.com/Dialogflow/es/docs/. Acesso em: 15 dez. 2020.

HONE, K. S., GRAHAM, R. Towards a tool for the subjective assessment of speech system interfaces (sassi). **Natural Language Engineering**, Reino Unido, vol. 6, p. 287-303, 2000.

JURAFSKY, D; MARTIN J H. **Speech and Language Processing**. 3. ed. California: Stanford, 2020. Disponível em: https://web.stanford.edu/~jurafsky/slp3/. Acesso em: 15 dez. 2020.

LI, M.; WETSON, J.; ROLLER, S. ACUTE-EVAL: Improved Dialogue Evaluation with Optimized Questions and Multi-turn Comparisons. **NeurIPS19 Workshop on Conversational AI**, Cornell University, 2020.

MCTEAR, M. **Conversational AI**: dialogue systems, conversational agents, and chatbots. California: Morgan & Claypool, 2020.

RAJ, S. **Building Chatbots with Python**. Berkeley: Apress, 2019.

SEE, A., ROLLER, S., KIELA, D., WETSON, J. What makes a good conversation? How controllable attributes affect human judgments. **Proceedings of the 2019 Conference of the North American** – Chapter of the Association for Computational Linguistics: Human Language Technologies, vol.1 (long and short papers), 1702-1723. 2019.

RASA. Rasa: developer documentation. **RASA DOCS**, 2020. Disponível em: https://rasa.com/docs/. Acesso em: 15 dez. 2020.

© PUCPR - Todos os direitos reservados.