



Preparação e Análise Exploratória de Dados

UNIDADE 02

Análise descritiva de dados univariados

Nesta semana, você estudará técnicas fundamentais de análise descritiva de dados, com foco na análise univariada.

Vamos aprender a interpretar histogramas, *boxplots* e tabelas estatísticas, além de desenvolver habilidades para resumir, visualizar e comunicar os principais aspectos dos conjuntos de dados estudados.

Bons estudos!

A análise descritiva de dados é o ponto de partida para compreender conjuntos de informações, seja no contexto acadêmico, profissional ou pessoal. Imagine que você recebeu as notas de cem alunos em uma planilha: como descobrir rapidamente padrões, identificar quem está fora do esperado ou resumir tudo em poucas linhas? Com as técnicas certas, essas respostas ficam claras e objetivas.

| Dados univariados e multivariados

Dados univariados referem-se à análise de apenas uma variável em um conjunto de dados. Essa variável pode representar qualquer tipo de característica, como altura, idade, tempo de deslocamento, temperatura, entre outros. O objetivo principal da análise univariada é entender as propriedades dessa única variável, como sua distribuição, tendência central (média, mediana), dispersão (variância, desvio padrão) e identificação de valores atípicos (*outliers*).

Essa análise é fundamental para fornecer uma visão inicial e direta sobre o comportamento do dado antes de avançar para análises mais complexas. Técnicas como histogramas, *boxplots* e tabelas estatísticas são especialmente eficazes para analisar dados univariados, pois são projetadas para sumarizar e visualizar uma única dimensão de informação, facilitando a compreensão sobre a estrutura e os padrões presentes na variável.

Em contraste, **dados multivariados** envolvem a análise simultânea de duas ou mais variáveis, buscando entender as relações, correlações, padrões conjuntos e dependências entre elas. Por exemplo, analisar a altura e o peso de um grupo de pessoas para verificar a relação entre essas duas características é um estudo multivariado. Para dados multivariados, as técnicas analíticas são mais complexas e abrangem métodos

como análise de correlação, regressão múltipla, análise de componentes principais (PCA) e outras técnicas multivariadas que exploram as interações entre variáveis. A análise multivariada é essencial em contextos nos quais os fenômenos estudados são influenciados por múltiplos fatores simultaneamente, permitindo descobertas mais ricas e *insights* aprofundados sobre o comportamento dos dados em múltiplas dimensões.

Portanto, a principal diferença entre dados univariados e multivariados está na quantidade de variáveis analisadas e no tipo de informação que se busca extrair: o univariado foca o estudo individual da variável, enquanto o multivariado investiga as inter-relações entre várias variáveis, exigindo técnicas e abordagens específicas para cada caso.

Para analisar dados univariados, três recursos fundamentais são utilizados: **histogramas**, **boxplots** e **tabelas estatísticas**. O histograma permite visualizar a distribuição dos dados, mostrando as faixas em que mais alunos se concentram. O *boxplot* revela dispersão e possíveis “alunos fora da curva”, conhecidos como outliers. Já as tabelas, organizam médias, medianas e modas, ajudando a resumir a turma de forma prática.

A cada exemplo, pense nos dados ao seu redor: salários em empresas, idades em turmas, vendas de produtos. Os métodos que você vai conhecer ajudam a transformar dados brutos em informação acessível, facilitando decisões e análises. Veremos a seguir cada um deles.

| Histogramas

Histogramas são ferramentas gráficas utilizadas na análise descritiva de dados para visualizar a distribuição de uma variável numérica. Eles mostram a frequência com que os valores aparecem dentro de intervalos definidos, chamados de *bins* ou classes. Na prática, isso significa que os dados são agrupados em faixas e, para cada faixa, é desenhada uma barra cuja altura indica quantos valores estão naquele intervalo.

Esse tipo de gráfico facilita a identificação de padrões, como concentrações de dados em determinadas regiões (moda), assimetrias, dispersões e lacunas na distribuição.



EXEMPLO

Ao analisar as notas de uma turma, um histograma permite visualizar rapidamente em quais faixas de nota está concentrada a maioria dos alunos, indicando o desempenho predominante. Além disso, histogramas podem ajudar a identificar dados fora do padrão que podem representar erros, variações relevantes ou *outliers*.

A escolha do tamanho das classes é importante:

- Classes muito largas podem esconder detalhes relevantes.
- Classes muito estreitas podem gerar gráficos muito fragmentados e difíceis de interpretar.

O histograma é uma representação importante para compreender o comportamento geral dos dados antes da aplicação de técnicas mais avançadas.

Essas características tornam o histograma uma ferramenta intuitiva e eficaz para apresentar resultados de forma rápida e visual, facilitando a comunicação e a tomada de decisões baseadas em dados.

Criação de um histograma

1

Dados iniciais

Coleta dos dados.

2

Definição dos intervalos

Definir a quantidade de intervalos que vai compor o histograma.

3

Histograma

Organizar os dados da tabela em intervalos e representá-los no gráfico.

Tipos de dados


O histograma representa graficamente a distribuição de dados quantitativos.



| Boxplots

Boxplots, também conhecidos como diagramas de caixa, são gráficos utilizados para mostrar a distribuição de um conjunto de dados, destacando a mediana, os quartis e os possíveis valores atípicos (*outliers*). Eles oferecem uma visão compacta da dispersão e da simetria dos dados, facilitando comparações rápidas entre diferentes grupos ou variáveis.

A caixa central do *boxplot* representa os 50% centrais dos dados e é delimitada pelo primeiro quartil (Q1) e pelo terceiro quartil (Q3). A linha dentro da caixa indica a mediana, que divide os dados em duas metades. Os “bigodes” se estendem até os valores máximos e mínimos dentro de 1,5 vezes o intervalo interquartil ($Q3 - Q1$). Pontos fora dessa faixa são considerados *outliers* e aparecem indicados separadamente, destacando valores que se afastam do comportamento geral do grupo.



Os *boxplots* são especialmente úteis para identificar simetria, assimetria, presença de *outliers* e para comparar distribuições entre diferentes grupos de forma rápida e clara. Por exemplo, ao analisar os salários em diferentes departamentos de uma empresa, os *boxplots* ajudam a identificar onde há maior variação ou se algum departamento apresenta salários atípicos, o que pode indicar a necessidade de ajustes ou análises mais detalhadas.

Essa forma visual de sumarização permite interpretar dados complexos de maneira clara e eficiente, sendo uma ferramenta importante para a análise exploratória e para a comunicação de resultados.

| Tabelas estatísticas

Tabelas estatísticas são ferramentas fundamentais para resumir e organizar informações quantitativas de forma clara e acessível. Elas apresentam medidas descritivas que sintetizam o comportamento dos dados em números que traduzem características importantes.

Entre os principais elementos que compõem uma tabela estatística estão:

Medidas de tendência central	⌵
Como média (valor médio), mediana (valor central que divide os dados em duas metades) e moda (valor mais frequente).	
Medidas de dispersão	⌵
Indicam a variação dos dados, como o desvio padrão, variância e amplitude (diferença entre o maior e o menor valor).	
Quartis e percentis	⌵

Dividem os dados em partes, facilitando a interpretação da distribuição, indicando, por exemplo, onde se situam os 25%, 50%, 75% dos dados.

As tabelas facilitam a comparação entre grupos e a comunicação dos resultados de forma objetiva, sendo utilizadas para apresentar resumos em relatórios, estabelecer *benchmarks* ou identificar padrões em estudos e análises.

Ao analisar o desempenho de uma equipe de vendas, por exemplo, uma tabela que apresente a média, a mediana e o desvio padrão das vendas mensais permite compreender não só o resultado médio, mas também a consistência das vendas, apontando se há grande variação entre os meses.

Assim, as tabelas estatísticas são essenciais para transformar dados brutos em informações compreensíveis e úteis para a tomada de decisão, servindo como base para análises futuras e auxiliando na avaliação crítica dos dados.



EXEMPLO

Considere um levantamento de consumo de água por família em uma cidade.

Ao construir um **histograma**, você percebe que a maioria das famílias consome entre 20 e 40 m³ mensais, enquanto poucas ultrapassam 60 m³. O gráfico facilita a visualização de tendências: há concentração em faixas específicas, indicando um padrão de uso.

Ao gerar um **boxplot** desse consumo, é possível detectar famílias que estão muito acima ou abaixo da média, apontando *outliers*, talvez causados por vazamentos ou pelo fato de a residência ter poucas pessoas. Esses outliers merecem atenção, pois podem indicar problemas a serem solucionados.

Em **tabelas estatísticas**, como as que apresentam os valores mínimos, máximos, média e mediana do consumo, torna-se simples comunicar os resultados: “A média foi de 35 m³, mas a mediana esteve em 30 m³, sinalizando que muitos consumos baixos puxaram a média para cima”.

Veja como cada ferramenta complementa a outra, oferecendo múltiplos olhares sobre o mesmo conjunto de dados.

Essas técnicas podem antecipar decisões no seu dia a dia. Ao analisar vendas de um pequeno comércio, por exemplo, **histogramas** indicam os produtos mais populares, enquanto **boxplots** mostram períodos de vendas fora do padrão (como altos picos em datas comemorativas), já **tabelas estatísticas** resumem o desempenho, facilitando apresentações para sócios ou planejamento de estoque.

Pergunte-se sempre: “Qual padrão é mais comum nesse grupo de dados? O que pode estar distorcendo o resultado? Há algo que mereça investigação mais detalhada?” Esses questionamentos conectam teoria à prática, tornando a análise descritiva uma ferramenta central para entender e resolver problemas reais.

Busque experimentar com seus próprios dados, adaptando os exemplos e as técnicas apresentadas nesta aula. Aprender análise descritiva é, acima de tudo, adquirir repertório para interpretar o mundo à sua volta com olhar crítico e curioso.

| Videoaula: Análise univariada – histogramas, boxplots e tabelas com Pandas e Numpy

Vamos aprender a criar histogramas, *boxplots* e tabelas usando as bibliotecas Pandas e Numpy. Esses recursos são essenciais para entender rapidamente a distribuição, a dispersão e os resumos estatísticos dos seus dados.

| Ligando os pontos

Em 2025, uma das principais novidades no campo da análise de dados e visualização é a incorporação cada vez mais avançada de inteligência artificial (IA) nas ferramentas utilizadas para explorar e interpretar dados. Essas ferramentas inteligentes, como o Tableau Einstein e outras plataformas emergentes, já estão integrando funcionalidades de IA que não apenas facilitam o acesso à análise, mas também automatizam etapas complexas.

Por exemplo, elas sugerem *insights*, destacam padrões, detectam anomalias automaticamente, geram visualizações dinâmicas e preditivas, e oferecem assistentes interativos para guiar os usuários em perguntas frequentes e análises detalhadas. Essa democratização da análise de dados com a IA permite às pessoas com menos experiência técnica extraírem valor de grandes volumes de dados em tempo real,

transformando dados brutos em conhecimento de forma rápida e intuitiva. A inteligência artificial auxilia também na redução do tempo gasto na limpeza e preparação dos dados, muitas vezes a etapa mais complexa e demorada.

Essa tendência está alinhada ao movimento mundial para tornar a análise de dados mais acessível a todos, acelerando decisões nas organizações e fomentando a cultura *data-driven* (orientada por dados). Segundo artigos recentes do [DevTrends](#) (2025) e análises da [Bix Tecnologia](#), essas inovações vêm sendo adotadas por empresas de todos os portes, gerando maior eficiência, precisão e agilidade nos processos decisórios.

Adicionalmente, plataformas modernas estão incorporando recursos para análises colaborativas e em nuvem, permitindo a equipes distribuídas trabalharem simultaneamente em projetos, aumentando a produtividade e facilitando o alinhamento entre diferentes áreas da empresa. Como resultado, o papel do analista de dados está evoluindo, utilizando essas ferramentas para concentrar esforços em interpretações estratégicas e recomendações de ação, enquanto a IA cuida das tarefas operacionais rotineiras.

Portanto, a grande novidade é que a análise descritiva, visualização e mineração de dados estão deixando de ser tarefas exclusivamente para especialistas técnicos e se tornam parte do cotidiano de profissionais variados, otimizando negócios e ampliando o alcance do conhecimento gerado pelos dados.

Leia mais sobre essas tendências em:

- [Tableau](#)
- [Bix Tecnologia](#)
- [DevTrends](#)

| Questões reflexivas



EXERCÍCIO

Questão 1 - Como a escolha inadequada do tamanho das classes em um histograma pode impactar a interpretação dos dados em um projeto na sua área?

Questão 2 - Em uma análise de desempenho de equipes, como o uso adequado de *boxplots* pode ajudar a identificar necessidades de melhoria? E quais são os riscos de desconsiderar os outliers?

Questão 3 - De que forma a apresentação clara dos resultados em tabelas estatísticas pode influenciar a tomada de decisão em uma empresa? Como garantir que as informações sejam compreendidas por diferentes públicos?



Resposta



Questão 1 - Como a escolha inadequada do tamanho das classes em um histograma pode impactar a interpretação dos dados em um projeto na sua área?

Resposta sugerida: A escolha do tamanho das classes influencia o nível de detalhe e clareza do histograma. Classes muito largas podem ocultar variações importantes e mascarar padrões, levando a conclusões superficiais ou erradas. Já classes muito estreitas podem gerar ruído visual, dificultando a identificação de tendências. Por isso, é fundamental ajustar o tamanho para que o gráfico represente a distribuição real dos dados sem perder informações relevantes, garantindo decisões mais precisas.

Questão 2 - Em uma análise de desempenho de equipes, como o uso adequado de *boxplots* pode ajudar a identificar necessidades de melhoria? E quais são os riscos de desconsiderar os outliers?

Resposta sugerida: *Boxplots* permitem visualizar a dispersão e a mediana do desempenho, identificando variações entre os membros. A presença de outliers pode indicar casos extremos — como altos ou baixos desempenhos — que merecem investigação, pois podem representar talentos ou problemas como falta de treinamento. Ignorar esses *outliers* pode resultar em perda de oportunidades para melhorar a equipe ou corrigir falhas que impactam os resultados.

Questão 3 - De que forma a apresentação clara dos resultados em tabelas estatísticas pode influenciar a tomada de decisão em uma empresa? Como garantir que as informações sejam compreendidas por diferentes públicos?

Resposta sugerida: Tabelas estatísticas resumem dados complexos em medidas simples, facilitando a comunicação dos resultados para gestores e equipes, ajudando na tomada de decisões baseadas em fatos. Para diferentes públicos, é essencial contextualizar as medidas, usar linguagem acessível, destacar *insights* principais e, quando possível, combinar tabelas com gráficos para facilitar o entendimento visual. Essa clareza promove confiança e alinhamento entre as partes envolvidas.

| Ligando conceitos

Nesta semana, exploramos como a análise descritiva é fundamental para entender e interpretar conjuntos de dados por meio de técnicas como histogramas, *boxplots* e tabelas estatísticas, que, juntos, nos permitem visualizar a distribuição, identificar padrões e outliers, e resumir informações complexas de forma clara e objetiva. Compreender como escolher o melhor tipo de visualização, ajustar parâmetros e interpretar resultados é essencial para conectar dados brutos a decisões informadas, seja no ambiente acadêmico ou no mundo do trabalho, onde a capacidade de transformar números em conhecimento acessível e aplicável faz toda a diferença. Esta base sólida abre caminho para análises mais avançadas e prepara o estudante para ser um agente crítico e estratégico no uso dos dados, reafirmando a importância da estatística e da visualização conjunta para a tomada de decisões inteligentes.

| Referências

CASTRO, D. G. F. L. N. **Introdução à mineração de dados:** conceitos básicos, algoritmos e aplicações. Rio de Janeiro: Saraiva Uni, 2016.

FACELI, K.; LORENA, A. C.; GAMA, J.; ALMEIDA, T. A.; CARVA, A. C. P. L. F. **Inteligência artificial:** uma abordagem de aprendizado de máquina. 3. ed. Rio de Janeiro: LTC, 2025.

FERREIRA, R. G. C.; MIRANDA, L. B. A.; PINTO, R. A. **Preparação e análise exploratória de dados.** Porto Alegre: SAGAH, 2021.

