



Preparação e Análise Exploratória de Dados

UNIDADE 03

Análise multivariada: correlação e visualização multivariada

Nesta semana, você vai estudar sobre análise descritiva de dados com foco na análise multivariada. Serão abordados conceitos essenciais como correlação e técnicas de visualização multivariada, fundamentais para compreender relações entre múltiplas variáveis em conjuntos de dados. A aplicação desses métodos estatísticos ajuda a revelar padrões e interações importantes, promovendo uma visão crítica e aprofundada dos dados. Essa etapa é crucial para avançar em análises exploratórias mais complexas.

| Videoaula: Correlação e visualização multivariada com Pandas e Seaborn

Como descobrir se e como duas ou mais variáveis em um conjunto de dados estão relacionadas? Na videoaula de hoje, vamos desvendar o conceito de correlação e mostrar, na prática, como calcular e interpretar essa relação entre variáveis usando a biblioteca Pandas. Além disso, vamos explorar formas eficientes de visualizar múltiplas variáveis ao mesmo tempo com o Seaborn, facilitando a compreensão dos padrões que os dados escondem.



SAIBA MAIS

Você sabe o que é a biblioteca Pandas? Trata-se de uma biblioteca de código aberto focada em análise e manipulação de dados, muito utilizada em ciência de dados e *machine learning*. Ela fornece estruturas como *Series* (colunas) e *DataFrames* (tabelas) para trabalhar com dados tabulares, semelhantes a planilhas. Além disso, facilita tarefas como ler arquivos (CSV, Excel, SQL), limpar valores faltantes, filtrar linhas, criar colunas, agrupar e resumir dados (média, mediana, contagem etc.).

E você sabe o que é a biblioteca Seaborn? Trata-se de uma biblioteca de visualização estatística em Python, construída sobre o Matplotlib, com foco em gráficos mais claros e esteticamente agradáveis. Ela se integra diretamente com *DataFrames* do Pandas: basta passar o *DataFrame* e o nome das colunas para gerar gráficos. Também permite criar facilmente gráficos de dispersão, linhas, barras, histogramas, mapas de calor, gráficos de regressão, gráficos de pares, entre outros, muito utilizados em análise exploratória de dados.

Este vídeo é essencial para quem deseja ir além da simples observação de dados e aprender a identificar conexões que podem influenciar decisões e análises mais aprofundadas. Você verá passo a passo como aplicar essas técnicas em exemplos reais, tornando o aprendizado claro, prático e aplicável no seu dia a dia.

Na análise de dados, trabalhamos frequentemente com conjuntos que possuem várias variáveis ao mesmo tempo. Esses são chamados de dados multivariados, ou seja, dados que nos oferecem múltiplas características ou atributos sobre os objetos ou eventos estudados.



EXEMPLO

Ao analisar um conjunto sobre carros, podemos ter variáveis como potência, consumo, preço e peso. Entender os dados multivariados é essencial porque as variáveis raramente atuam isoladamente; suas interações podem revelar informações importantes que não seriam evidentes observando cada uma separadamente.

Aqui entra um conceito poderoso e simples: a **correlação**. Pense nela como uma régua mágica que mede o quanto duas variáveis caminham juntas, seja para o mesmo lado ou para lados opostos.



EXEMPLO


Se, ao aumentar o peso do carro, o consumo também aumenta (ou seja, o carro fica menos eficiente), podemos observar uma correlação positiva. Da mesma forma, se ao aumentar a potência o consumo também aumenta, há uma correlação positiva; mas, se ao aumentar a potência o preço cai, teríamos uma correlação negativa (sim, isso pode acontecer!).

E se o aumento em uma variável não mudar nada na outra? Nesse caso, a correlação será próxima de zero — sinal de que essas variáveis não “conversam” linearmente entre si.

A correlação pode ser representada por um gráfico de dispersão, como no gráfico a seguir, que mostra a correlação entre idade e renda.

correlação entre idade e renda. O que se pode interpretar a partir dele?

Gráfico 1 – Gráfico de dispersão: idade vs. renda



Fonte: o autor.

Mas cuidado: correlação não é sinônimo de causa e efeito! É só um indício de que duas variáveis estão “dançando” juntas, mas isso pode ser por acaso, uma influência externa ou outros fatores envolvidos.

Quando nos deparamos com conjuntos de dados que possuem múltiplas variáveis, a complexidade da análise aumenta, mas também se ampliam as possibilidades de extração de conhecimento significativo. É nesse contexto que entram as visualizações multivariadas, que permitem observar os dados de forma integrada, capturando as nuances e as relações entre as variáveis que, isoladamente, poderiam passar despercebidas. Ao representar visualmente essas inter-relações, seja por meio de mapas de calor, gráficos de dispersão múltiplos ou correlações tabeladas, torna-se possível compreender melhor os padrões presentes nos dados e aprofundar a análise exploratória.



EXEMPLO

Saúde

Um exemplo clássico ocorre em análises de saúde pública nas quais, simultaneamente, estudamos variáveis como pressão arterial, níveis de colesterol, índice de massa corporal, frequência cardíaca e idade. Visualizando tudo junto, é possível notar, por exemplo, que enquanto a pressão arterial pode estar fortemente correlacionada com a idade e o índice de massa corporal, o nível de atividade física do paciente pode revelar uma correlação negativa com o colesterol elevado, indicando um possível fator protetor. Esses padrões em camadas podem orientar tratamentos médicos personalizados e políticas públicas mais eficazes, mostrando o valor da visão multivariada para decisões baseadas em dados.

Negócios


Na área de negócios, imagine analisar simultaneamente receita, gastos com *marketing*, número de funcionários, satisfação do cliente e estoque disponível. Um mapa de calor dessas correlações pode mostrar que, embora haja relação positiva entre investimento em *marketing* e receita, um aumento desproporcional no estoque pode estar negativamente correlacionado com a satisfação do cliente, indicando problemas logísticos ou de qualidade. Aqui, mais do que saber o valor isolado de cada métrica, a compreensão das conexões entre elas é o diferencial para ajustar estratégias, otimizar recursos e melhorar a experiência do consumidor.

Além disso, em cenários de análise de mercado e comportamento do consumidor, gráficos como de dispersão matriciais (*pairplots*) ajudam a estabelecer relações entre preço, volume de vendas, avaliações de clientes, sazonalidade e concorrência. Esses gráficos facilitam a visualização das múltiplas associações simultâneas, revelando, por exemplo, como o preço pode ser moderado pela avaliação dos usuários e afetar o volume de vendas de forma não linear, enquanto a sazonalidade influencia essa dinâmica de modo periódico. Nesses casos, o uso do gráfico multivariado auxilia analistas a narrar uma história mais rica e coerente dos dados, elevando o impacto dos insights entregues.



EXEMPLO

Uma empresa de frota de ônibus deseja analisar a relação entre as milhas dirigidas e o custo por milha. Para realizar essa análise, foi gerado um gráfico de dispersão.



Fonte: Adaptado de Ferreira; Miranda; Pinto *et al.*, 2021, p. 112.

Outro ponto relevante é a distinção clara que esses gráficos proporcionam entre correlações fortes, moderadas e fracas, permitindo priorizar quais relações investigar mais profundamente.

Um mapa de calor colorido utiliza gradientes para indicar essas forças, tornando a interpretação visual rápida e intuitiva. Esse recurso é especialmente útil em projetos de ciência de dados, em que o volume de variáveis é grande, e o desafio é direcionar os esforços para as ligações mais promissoras. Assim, a análise exploratória deixa de ser um processo de tentativa e erro para se tornar um caminho estruturado e eficiente.

Por fim, a visão multivariada não é apenas uma técnica visual; é uma filosofia de análise que promove pensar os dados em conjunto, entendendo a complexidade do mundo real onde variáveis raramente atuam isoladamente. É essa abordagem que permite construir modelos mais precisos, evitar conclusões equivocadas por olhar dados isoladamente e fomentar a criatividade ao buscar soluções inovadoras para problemas complexos. Portanto, ao dominar a visualização e análise multivariada, você habilita um olhar mais crítico e completo, capaz de orquestrar informações em singular harmonia, para decisões melhores e mais fundamentadas.

Essa compreensão amplia sua capacidade analítica, fazendo com que enxergue não apenas números isolados, mas uma rede dinâmica e interligada de informações que, juntas, revelam o verdadeiro potencial dos dados.

Coeficiente de correlação de Pearson

O cálculo da correlação entre duas variáveis quantitativas é feito por meio de uma fórmula estatística chamada coeficiente de correlação de Pearson, que mede a intensidade e a direção do relacionamento linear entre elas.

O resultado r pode indicar:

- $r = 1$: correlação positiva perfeita (quando uma variável aumenta, a outra também aumenta).
- $r = -1$: correlação negativa perfeita (quando uma variável aumenta, a outra diminui).
- $r = 0$: ausência de correlação linear.

Na prática, correlações perfeitas (+1 ou -1) ou totalmente ausentes (0) são muito raras. Em situações reais, sempre há pequenas variações, fatores externos e ruídos nos dados que afetam o resultado.

Por isso, o mais importante não é buscar correlações extremas, mas compreender o sentido e a força da relação entre as variáveis:

Correlação positiva

Quando uma variável aumenta, a outra tende a aumentar também.

Correlação negativa

Quando uma aumenta, a outra tende a diminuir.

Correlação fraca

A relação existe, mas outros fatores também influenciam o comportamento dos dados.

Em resumo, a correlação não precisa ser perfeita para ser útil; ela já fornece informações valiosas sobre tendências e padrões nos dados.

| Ligando os pontos



© Imagem gerada por IA – Gemini

Nesta seção, vamos apresentar o conceito de **correlação espúria**, uma situação em que duas variáveis parecem estar relacionadas, mas não possuem uma relação real de causa e efeito.

No áudio a seguir, você verá um exemplo curioso que ajuda a entender por que a correlação nem sempre significa causalidade.

O estranho caso de Nicolas Cage e piscina

PUCPR Online



Assista no



SAIBA MAIS

Quer criar gráficos de correlação e explorar dados multivariados interativamente? Recomendamos [Tableau Public](#), uma ferramenta gratuita de visualização de dados para aplicar e experimentar na análise visual dos dados estudados.

| Questões reflexivas

Antes de finalizar seus estudos, propomos que você faça uma pausa para responder algumas questões. Vamos lá?



EXERCÍCIO

Questão 1- Em um projeto de análise de dados em uma empresa, você observa uma alta correlação entre duas variáveis que parecem não ter relação lógica evidente. Como você procederia antes de aceitar essa correlação como relevante para a tomada de decisão?

Questão 2- Em qual situação do dia a dia do mundo do trabalho a compreensão da diferença entre correlação e causalidade pode evitar um erro crítico? Dê um exemplo prático.

Questão 3- Como o uso de visualizações multivariadas pode ajudar um analista a fortalecer relatórios para a liderança, especialmente em dados complexos?



Resposta



Questão 1. Sugestão de resposta: investigar a existência de uma variável oculta que influencie ambas as variáveis, avaliar se a correlação pode ser espúria, explorar o contexto do negócio e buscar validação com outros dados ou especialistas.

Questão 2. Sugestão de resposta: um exemplo pode ser interpretar que um aumento nas vendas de sorvete causa aumento de afogamentos, enquanto na verdade é o calor a variável causal das duas. Entender isso evita medidas adequadas e comunicação errada.

Questão 3. Sugestão de resposta: Visualizações que mostram múltiplas variáveis e suas relações de forma clara facilitam a identificação de padrões e comunicação dos insights, aumentando a clareza e a confiança das decisões.

| Ligando conceitos

Ao longo desta unidade, exploramos como a análise de dados multivariados e a correlação entre variáveis são ferramentas poderosas para compreender o comportamento de conjuntos complexos, mas também aprendemos que nem toda correlação possui um significado causal, destacando a importância de reconhecer e questionar correlações espúrias para evitar conclusões precipitadas. Vimos como a visualização de dados, por meio de gráficos de dispersão e mapas de calor, torna essas relações mais claras e acessíveis, facilitando a tomada de decisão no mundo real. Ao conectar esses conceitos, fica evidente que o sucesso na análise exploratória depende não só do domínio das ferramentas estatísticas, mas também de um olhar crítico e contextualizado sobre os dados, garantindo interpretações com *insights* confiáveis e relevantes.

| Referências

CASTRO, D. G. F. L. N. **Introdução à mineração de dados:** conceitos básicos, algoritmos e aplicações. Rio de Janeiro: Saraiva Uni, 2016.

FACELI, K.; LORENA, A.C.; GAMA, J.; ALMEIDA, T. A.; CARVA, A. C. P. L. F. **Inteligência artificial:** uma abordagem de aprendizado de máquina. 3. ed. Rio de Janeiro: LTC, 2025.

FERREIRA, R. G. C.; MIRANDA, L. B. A.; PINTO, R. A. *et al.* **Preparação e análise exploratória de dados.** Porto Alegre: Sagah, 2021.

