



Preparação e Análise Exploratória de Dados

UNIDADE 05

Tratamento de dados: detecção de valores faltantes e outliers

Nesta semana, você aprenderá métodos para detectar valores faltantes e *outliers* em conjuntos de dados, e entenderá seu impacto nas análises. Exploraremos técnicas para tratar essas inconsistências, garantindo a qualidade e confiabilidade dos dados. Ao final, estará apto a aplicar soluções práticas para preparar dados reais, facilitando análises mais robustas e decisões informadas.

O **tratamento de dados** é uma etapa essencial para garantir a qualidade e a confiabilidade de qualquer análise. Dados incompletos ou com valores anômalos podem levar a interpretações equivocadas e decisões erradas. Por isso, é fundamental reconhecer e lidar adequadamente com valores faltantes e *outliers*.

Valores faltantes correspondem a informações ausentes em um conjunto de dados. Eles podem surgir por diversos motivos, como erros na coleta, falhas de registro ou até mesmo pela natureza dos dados. Já os *outliers* são observações que apresentam valores muito diferentes da maioria, podendo indicar erros, variabilidade extrema ou fenômenos importantes a serem investigados.

Nesta semana, você aprenderá os conceitos básicos desses problemas, suas consequências para a análise e as principais técnicas para identificá-los e tratá-los, preparando seus dados para análises robustas e confiáveis.

| Valores faltantes

Valores faltantes são dados ausentes em um conjunto de dados que podem ocorrer por diversos motivos, como falhas na coleta, problemas na transmissão ou até omissões involuntárias. Identificar esses valores é fundamental, porque eles podem comprometer a qualidade da análise, gerar viés ou reduzir o poder estatístico dos testes.

Para detectar valores faltantes, é possível usar métodos simples, como a verificação da contagem e percentual de dados ausentes por variável, além de ferramentas visuais como mapas de calor (*heatmaps*) que destacam onde as faltas ocorrem. Essas técnicas permitem entender a extensão e o padrão dos dados ausentes, que podem ser aleatórios ou sistemáticos.

No tratamento dos valores faltantes, há diferentes estratégias:

- Exclusão de registros incompletos, que pode ser adequada quando a quantidade de dados faltantes é pequena.
- Imputação, que substitui os dados ausentes por estimativas baseadas na média, mediana, moda ou modelos mais sofisticados, como regressão ou algoritmos de *machine learning*.

A escolha da melhor abordagem depende do contexto do problema e do impacto esperado na análise.

| Outliers

Outliers são valores que se desviam significativamente do padrão normal dos dados, aparecendo como pontos extremos ou isolados. Eles podem surgir por erros na coleta ou entrada de dados, ou representar fenômenos reais pouco comuns que merecem atenção.

A identificação de *outliers* geralmente é feita por métodos estatísticos, sendo o intervalo interquartílico (IQR) um dos mais utilizados. Basicamente, calcula-se o intervalo entre o primeiro e o terceiro quartis e define-se uma faixa fora da qual os valores são considerados *outliers*. Outra abordagem é avaliar desvios-padrão, considerando valores muito afastados da média.

Visualmente, os *outliers* podem ser detectados em gráficos como *boxplots*, em que aparecem como pontos fora da “caixa”, e gráficos de dispersão, nos quais são isolados. O tratamento pode envolver a remoção, transformação dos dados ou análise separada, dependendo do contexto e do impacto que esses valores têm para a análise.

| Impacto dos valores faltantes e outliers

Valores faltantes e *outliers* podem comprometer gravemente a qualidade dos dados e as análises que deles se derivam. Quando não tratados, os valores faltantes podem causar distorções, principalmente em estatísticas como média, variância e correlações, levando a conclusões enviesadas.

Outliers, por sua vez, podem alterar significativamente medidas de tendência central e dispersão, além de impactar modelos preditivos, influenciando o ajuste e a *performance*. Em alguns casos, *outliers* podem representar erros que devem ser corrigidos; em outros, fenômenos importantes a serem investigados.

Por isso, é fundamental avaliar criticamente a presença destes dados antes da análise, ponderar seu impacto e decidir a melhor forma de tratamento, garantindo decisões baseadas em dados mais confiáveis e representativos.



EXEMPLO

1. Valores faltantes

Imagine que uma loja está analisando seus dados de vendas para calcular o faturamento semanal. Porém, o sistema falhou em registrar o preço unitário de alguns produtos, deixando lacunas na tabela.

- **Tabela original com valores faltantes**

Produto	Quantidade vendida	Preço unitário
A	10	15.00
B	5	NaN*
C	8	20.00
D	12	NaN*
E	7	30.00

* NaN = *Not a number*.

Esses “NaN” dificultam cálculos, como faturamento total. Para resolver, aplicamos imputação usando a **média dos preços disponíveis**: $\text{média} = (15 + 20 + 30) / 3 = 21,67$

- Após imputação

Produto	Quantidade vendida	Preço unitário
A	10	15.00
B	5	21.67
C	8	20.00
D	12	21.67
E	7	30.00

Agora todos os registros podem ser usados normalmente nas análises.

2. Detecção de *outlier*

Agora considere que a equipe está avaliando o desempenho das vendas por produto. Ao observar os dados, um valor chama atenção:

- Tabela original com um *outlier*

Produto	Quantidade vendida	Preço unitário
A	10	15.00
B	5	18.00
C	8	20.00
D	1000	16.00

E	7	30.00
---	---	-------

Como consequência, esse *outlier* puxa a média para cima, distorce gráficos e pode gerar interpretações equivocadas. Por isso, valores como esse devem ser investigados e tratados antes da análise final.

O tratamento de valores faltantes e *outliers* é indispensável para garantir a integridade e a qualidade dos dados utilizados em análises exploratórias. Ao reconhecer esses problemas, o analista pode aplicar técnicas adequadas para minimizar seus impactos e evitar distorções nos resultados, preservando a confiabilidade das conclusões.

Aprender a identificar, interpretar e corrigir esses dados críticos ajuda a construir bases sólidas para análises mais avançadas, modelos preditivos e tomadas de decisão informadas. A prática constante e a avaliação crítica desses processos tornam-se habilidades essenciais para qualquer profissional que trabalha com dados.

Vamos ver na prática como identificar e tratar valores faltantes utilizando a biblioteca Pandas em Python?

| Videoaula: Tratamento de valores faltantes com Pandas

Você já se perguntou como lidar com dados faltantes em seus conjuntos de dados e qual o impacto disso nas suas análises? Nesta videoaula, vamos explorar como identificar e tratar valores faltantes utilizando a biblioteca Pandas em Python, uma ferramenta essencial para quem trabalha com ciência de dados.

Descubra as principais técnicas para detectar esses valores, entender suas causas e aplicar métodos eficientes de imputação ou exclusão, garantindo que seus dados estejam prontos para análises confiáveis e precisas. Além disso, ensinaremos comandos práticos que você poderá usar imediatamente em seus projetos.

Se preparar para tratar dados faltantes é fundamental para evitar distorções nos resultados e melhorar a qualidade das suas análises. Não perca essa oportunidade de dominar uma habilidade indispensável na manipulação de dados!



CURIOSIDADE

Você sabia que nem todos os *outliers* são erros? Alguns *outliers* apontam para descobertas importantes, como fraudes financeiras, falhas em processos industriais ou eventos extremos na saúde pública.

Por exemplo, um aumento incomum no número de reclamações em um dia pode indicar problemas de qualidade ou ataque cibernético. Identificar e analisar esses pontos fora do comum pode revelar informações valiosas, que seriam perdidas se apenas removêssemos os outliers sem investigação.

Portanto, *outliers* podem ser tanto um desafio quanto uma oportunidade para análises mais aprofundadas e tomadas de decisão estratégicas.



SAIBA MAIS

- Livro: *Introdução à mineração de dados* de Castro e Ferrari (2016).
Aborda fundamentos teóricos e práticos sobre preparação e limpeza de dados, incluindo técnicas para lidar com dados incompletos e discrepantes.

📖 Introdução à Mineração de Dados: Conceitos Básicos, Algoritmos e Aplicações.

- Livro: *Inteligência artificial - uma abordagem de aprendizado de máquina* de Faceli et al. (2025).
Oferece visão atualizada sobre métodos de imputação e identificação de *outliers* com aplicação em *machine learning*.

📖 Inteligência Artificial - Uma Abordagem de Aprendizado de Máquina.

| Questões reflexivas

Antes de finalizar seus estudos, propomos que você faça uma pausa para responder algumas questões. Vamos lá?



EXERCÍCIO

Questão 1

Você está trabalhando com um conjunto de dados de vendas em uma empresa e percebe que há muitos valores faltantes em uma variável importante, como a quantidade vendida. Quais são os riscos de simplesmente eliminar as linhas com dados faltantes? Quais estratégias você consideraria antes de tomar essa decisão?

Questão 2

Ao analisar dados financeiros, você detecta alguns *outliers* elevados em vendas. Deveria remover esses *outliers* automaticamente para evitar distorções? Por quê?

Questão 3

Como o tratamento inadequado de valores faltantes e *outliers* pode impactar diretamente a tomada de decisão em uma organização? Dê exemplos práticos.



Resposta



Questão 1

Sugestão de resposta:

Eliminar muitas linhas pode reduzir o tamanho e a representatividade do conjunto de dados, levando a análises enviesadas. É importante avaliar a quantidade e o padrão dos dados faltantes, considerar imputações apropriadas (média, mediana, modelos) e entender se os dados faltantes são aleatórios ou sistemáticos para decidir a melhor abordagem.

Questão 2

Sugestão de resposta:

Nem sempre os *outliers* devem ser removidos automaticamente, pois podem indicar eventos extraordinários importantes, como fraudes ou oportunidades de mercado. É necessário investigar a origem dos *outliers* e considerar seu impacto antes de decidir remover ou tratar esses valores.

Questão 3

Sugestão de resposta:

Tratamentos inadequados podem levar a conclusões erradas, impactando decisões críticas, como avaliação de desempenho, definição de preços, alocação de recursos ou detecção de fraudes. Por exemplo, ignorar *outliers* de despesas pode esconder gastos excessivos, ou ignorar dados faltantes em estoque pode causar falta de produtos.

| Ligando conceitos

Ao longo desta semana, estudamos temas fundamentais para o tratamento de dados, começando pelo reconhecimento da importância de identificar valores faltantes e *outliers*, elementos que podem comprometer a qualidade das análises se não forem bem compreendidos e tratados. Discutimos como detectar esses dados problemáticos por meio de métodos estatísticos e visuais, aprendendo, por exemplo, que valores ausentes podem ser imputados de diferentes formas, e que *outliers* precisam ser avaliados cuidadosamente para decidir se devem ser removidos, ajustados ou investigados como eventos relevantes. Refletimos sobre os impactos dessas questões na tomada de decisão, destacando que dados tratados de maneira equivocada podem levar a conclusões errôneas, enquanto um tratamento consciente fortalece a confiabilidade das análises e abre espaço para descobertas valiosas.

Essa compreensão integrada prepara o caminho para práticas mais críticas e eficazes em ciência de dados, essenciais para seu desempenho profissional e sucesso no mundo do trabalho.

| Referências

CASTRO, D. G. F. L. N. **Introdução à mineração de dados**: conceitos básicos, algoritmos e aplicações. Rio de Janeiro: Saraiva Uni, 2016.

FACELI, K.; LORENA, A. C.; GAMA, J.; ALMEIDA, T. A.; CARVA, A. C. P. L. F. **Inteligência artificial** - uma abordagem de aprendizado de máquina. 3. ed. Rio de Janeiro: LTC, 2025.

FERREIRA, R. G. C. *et al.* **Preparação e análise exploratória de dados**. Porto Alegre: SAGAH, 2021.

