



Preparação e Análise Exploratória de Dados

UNIDADE 06

Tratamento de valores faltantes

Você já se perguntou como lidar com dados faltantes em suas análises e evitar que eles comprometam seus resultados? Nesta semana, vamos explorar técnicas práticas de imputação de dados utilizando a biblioteca Pandas. Você aprenderá passo a passo como identificar valores ausentes e aplicar métodos eficazes para preenchê-los, preservando a qualidade e a integridade do seu conjunto de dados. Esta aula é essencial para quem deseja dominar a preparação de dados e garantir análises mais robustas e precisas.

Como vimos na unidade anterior, no tratamento de dados, é comum encontrarmos valores faltantes, que podem surgir por diversos motivos, como falhas na coleta, erros de registro ou dados não informados. Esses dados ausentes podem comprometer análises estatísticas, reduzir a qualidade dos modelos preditivos e levar a conclusões errôneas. Por isso, é fundamental entender e aplicar técnicas de imputação, que consistem em substituir esses valores faltantes por estimativas plausíveis.

A imputação de dados não é simplesmente preencher espaços vazios, mas, sim, um processo cuidadoso que visa a preservar as características principais do conjunto de dados. As técnicas mais comuns incluem substituição por medidas estatísticas, como média, mediana ou moda, e métodos mais avançados, que utilizam modelos preditivos para estimar os valores ausentes. Cada escolha deve considerar o tipo de dado, a quantidade e o padrão dos valores faltantes, buscando minimizar vieses e distorções.

| Imputação de dados

As técnicas básicas para imputação de dados são métodos simples e diretos para preencher valores faltantes em um conjunto de dados, garantindo sua continuidade e a qualidade da análise subsequente. São elas:

Substituição pela média (*mean imputation*)



Consiste em substituir os valores faltantes pela média dos valores observados na mesma variável contínua. É simples, mas

pode reduzir a variabilidade dos dados e introduzir viés se os dados não estiverem distribuídos normalmente.

Substituição pela mediana (*median imputation*)



Similar à média, mas utiliza a mediana, que é uma medida mais robusta para dados assimétricos ou com *outliers*, preservando melhor a distribuição original da variável.

Substituição pela moda (*mode imputation*)



Usada principalmente para variáveis categóricas, nas quais os valores faltantes são preenchidos com o valor que ocorre com maior frequência na variável.

Substituição por valor constante



Atribuir um valor fixo, como zero ou um rótulo “desconhecido”, para os valores faltantes. Essa técnica é útil para destacar valores ausentes como uma categoria à parte.

Remoção dos dados faltantes



Embora não seja imputação, é importante citar que a eliminação de registros ou variáveis com valores faltantes pode ser uma abordagem quando a quantidade de dados ausentes é pequena e não compromete a análise.



EXEMPLO

Imagine que você está trabalhando em uma pesquisa para entender o perfil de consumidores de uma loja *on-line*. O objetivo é analisar características como idade, cor favorita e estado civil para identificar padrões de comportamento. Porém, ao receber o conjunto de dados coletado pelo formulário, você percebe que alguns participantes deixaram perguntas sem resposta — o que gerou valores faltantes.

A seguir, temos a tabela original, com os dados brutos:

Índice	Idade	Cor_favorita	Estado_civil
1	23	azul	solteiro
2	25	vermelho	casado
3	NA	NA	NA
4	28	azul	divorciado
5	NA	NA	NA
6	22	verde	solteiro

Para seguir com a análise, é necessário tratar esses valores faltantes. Dependendo do tipo de variável e do objetivo da pesquisa, diferentes técnicas podem ser aplicadas. A seguir, você vê como cada método funcionaria nesse conjunto de dados.

1. Imputação pela média (Idade):

A média é usada em variáveis numéricas quando os dados têm distribuição aproximadamente simétrica.

- **Média das idades disponíveis:** $(23 + 25 + 28 + 22) / 4 = 24,5$.

- Idades após imputação pela média: 23, 25, **24.5**, 28, **24.5**, 22.

2. Imputação pela mediana (Idade):

A mediana é mais robusta quando há *outliers* ou distribuição assimétrica.

- Mediana das idades disponíveis: 24.
- Idades após imputação pela mediana: 23, 25, **24**, 28, **24**, 22.

3. Imputação pela moda (Cor favorita):

- Usada para variáveis categóricas. Escolhe-se o valor mais frequente: **Moda de Cor_favorita: "azul"**
- Cores após imputação pela moda: azul, vermelho, **azul**, azul, **azul**, verde

4. Imputação por valor constante (Estado civil):

- Indicada quando se quer preservar a informação de que havia um dado faltante (ex.: "não informado"). Valor escolhido: "**desconhecido**"
- Estado civil após imputação por valor constante: solteiro, casado, **desconhecido**, divorciado, **desconhecido**, solteiro

5. Remoção dos dados faltantes:

Utilizada quando há muitas informações ausentes e a remoção não prejudica a análise.

- Linhas 3 e 5 apresentam valores faltantes nas três variáveis: podem ser removidas sem grande perda de informação.
- Registros restantes: 1, 2, 4 e 6.

Para concluir, é importante destacar que a escolha da técnica de imputação adequada depende do contexto dos dados e do problema que está sendo analisado. Técnicas simples como a substituição por média, mediana ou moda são rápidas e fáceis de implementar, mas podem não capturar completamente a complexidade dos dados. Já a remoção de dados faltantes, embora prática, pode resultar em perda significativa de informação quando a quantidade de dados ausentes é grande.

Por isso, a imputação deve sempre ser feita com cuidado, avaliando o impacto das escolhas no resultado da análise ou modelo. Além disso, técnicas mais avançadas e específicas podem ser exploradas, como imputação por regressão, k-vizinhos mais próximos (KNN) ou algoritmos de aprendizado de máquina, que fazem estimativas mais precisas baseadas em padrões dos dados.

Compreender e aplicar corretamente a imputação de dados é fundamental para garantir a qualidade e a confiabilidade das análises, tornando os resultados mais robustos e representativos.

Na videoaula a seguir, você terá a oportunidade de praticar essas técnicas na biblioteca Pandas, consolidando o aprendizado e preparando-se para desafios reais na preparação e análise de dados. Esse cuidado com os dados faltantes é um dos pilares para transformar dados brutos em informação valiosa, um passo essencial na jornada de qualquer profissional de ciência de dados.



SAIBA MAIS

Você sabia que cerca de 80% dos dados do mundo atual são considerados “não estruturados” e muitos deles contêm valores faltantes? Esse fenômeno é tão comum que o tratamento adequado dos valores ausentes pode determinar o sucesso ou fracasso de uma análise de dados. Ignorar ou remover esses dados pode causar vieses e perda de informações importantes, especialmente em análises que envolvem múltiplas variáveis. Por isso, aprender a imputar dados faltantes de maneira eficiente não só melhora a qualidade dos resultados, mas é uma habilidade indispensável para profissionais de ciência de dados e áreas correlatas.



Questão 1

Questões reflexivas

EXERCÍCIO

Em uma análise multivariada, ao se deparar com um conjunto de dados com 10% de valores faltantes distribuídos em várias variáveis importantes, qual seria a sua decisão entre remover as linhas com dados faltantes ou aplicar técnicas de imputação? Justifique sua escolha.

Questão 2

Como o tratamento inadequado dos valores faltantes pode impactar negativamente um modelo preditivo desenvolvido para classificação de clientes em uma instituição financeira?

Questão 3

Em quais situações a substituição simples de valores faltantes pela média ou mediana de uma variável pode ser prejudicial? Quais alternativas você consideraria nesses casos?



Resposta



Questão 1

Sugestão de resposta:

A remoção das linhas pode reduzir o tamanho do conjunto de dados e causar perda significativa de informação, além de potencialmente introduzir viés se os dados faltantes não forem aleatórios. A imputação mantém o volume dos dados e pode ajudar a preservar padrões importantes, mas deve ser feita com métodos adequados para não distorcer a distribuição dos dados. Portanto, geralmente, a imputação é preferível, especialmente para valores faltantes em variáveis relevantes, a fim de manter a representatividade.

Questão 2

Sugestão de resposta:

Valores faltantes ignorados ou maltratados podem levar a um modelo enviesado, com baixa capacidade preditiva, pois o modelo pode interpretar a ausência de dados como ausência de informação relevante. Por exemplo, a remoção indiscriminada de registros ou o preenchimento inadequado podem ocultar padrões importantes ou criar relações falsas. Isso compromete a performance do modelo e pode afetar decisões críticas na instituição, como concessão de crédito.

Questão 3

Sugestão de resposta:

A substituição pela média ou mediana pode ser prejudicial quando os dados estão distribuídos de forma assimétrica, possuem *outliers* ou quando os valores faltantes não são aleatórios. Nesses casos, essa técnica pode distorcer a variabilidade dos dados e introduzir viés. Alternativas mais robustas incluem o uso de imputação por modelos preditivos, algoritmos baseados em k-vizinhos mais próximos (KNN) ou técnicas específicas para lidar com padrões complexos de ausência de dados, visando a preservar as propriedades originais do conjunto.

| Ligando conceitos

Ao longo desta semana, exploramos o que significa lidar com valores faltantes nos dados, compreendendo por que eles representam um desafio crítico que pode afetar a qualidade e a confiabilidade das suas análises. Vimos como a imputação, técnica usada para preencher esses valores ausentes, é essencial para preservar a integridade dos dados e garantir resultados mais precisos, destacando as estratégias básicas como substituição pela média, mediana, moda, valor constante e até a remoção de entradas. Além disso, discutimos a importância de escolher o método adequado considerando o contexto dos dados e a complexidade das relações multivariadas, pois o tratamento correto não apenas evita vieses, como também mantém o padrão e as interdependências entre variáveis. Assim, ao aplicar esses conceitos e técnicas com consciência e critério, você estará mais preparado para transformar conjuntos de dados imperfeitos em fontes confiáveis de informação e *insight* para o mundo do trabalho.

| Referências

CASTRO, D. G. F. L. N. **Introdução à mineração de dados**: conceitos básicos, algoritmos e aplicações. Rio de Janeiro: Saraiva Uni, 2016.

FACELI, K.; LORENA, A. C.; GAMA, J.; ALMEIDA, T. A.; CARVA, A. C. P. L. F. **Inteligência artificial** - uma abordagem de aprendizado de máquina. 3. ed. Rio de Janeiro: LTC, 2025.

FERREIRA, R. G. C.; MIRANDA, L. B. A.; PINTO, R. A. *et al.* **Preparação e análise exploratória de dados**. Porto Alegre: SAGAH, 2021.

