



Preparação e Análise Exploratória de Dados

UNIDADE 07

Tratamento de dados: discretização de dados

Nesta semana, você aprenderá a transformar dados contínuos em dados discretos por meio da discretização. Abordaremos técnicas como intervalos iguais, frequências e métodos supervisionados, que facilitam a análise e o uso de algoritmos que exigem dados categóricos. Compreender a importância e as aplicações da discretização permitirá preparar melhor seus dados para análises exploratórias e modelagem, tornando suas descobertas mais claras e eficazes.

A discretização de dados é uma técnica fundamental que transforma variáveis contínuas em variáveis discretas, dividindo seus valores em intervalos ou categorias. Essa transformação facilita a análise, especialmente em algoritmos que trabalham melhor com dados categóricos, como alguns métodos de aprendizado de máquina. Além disso, ajuda a simplificar o problema e a identificar padrões com mais clareza.

Sua importância vai além da simplificação. A discretização pode melhorar o desempenho dos modelos ao reduzir o impacto de pequenas variações e ruídos nos dados contínuos. Também contribui para a interpretação dos resultados e para a comunicação dos insights, tornando-os mais acessíveis para diferentes públicos.

Esse processo pode ser realizado por diferentes técnicas, como a divisão em intervalos de mesma amplitude ou com base na frequência dos dados. O objetivo é criar categorias que preservem a informação essencial, reduzindo a complexidade sem comprometer o significado dos dados originais.

Por isso, a discretização é uma etapa importante na preparação e na análise exploratória de dados.

| Importância da discretização para análise e modelagem de dados

A discretização desempenha um papel importante na análise e modelagem de dados, pois transforma variáveis contínuas em categorias. Isso simplifica o processamento e facilita a interpretação das informações.

Ao converter valores contínuos em faixas, reduzimos a complexidade dos dados, o que ajuda na identificação de padrões e tendências que nem sempre são visíveis em sua forma original.

No contexto de aprendizado de máquina, alguns algoritmos se beneficiam dessa transformação. É o caso das árvores de decisão e das regras de associação, que trabalham melhor com dados categóricos. A discretização também contribui para reduzir o impacto de pequenas variações e ruídos, tornando os modelos mais robustos.

Além disso, esse processo melhora a interpretação dos resultados, o que é essencial para comunicar *insights* a públicos não técnicos. Em alguns casos, também pode contribuir para maior eficiência computacional e maior estabilidade dos modelos.

Por isso, a discretização é uma etapa importante na preparação dos dados, tanto para a análise exploratória quanto para a modelagem preditiva.

| Métodos de discretização: não supervisionada e supervisionada

Discretização não supervisionada

É um método que divide dados contínuos em categorias sem considerar qualquer variável-alvo ou objetivo externo. Ela se baseia apenas na distribuição dos dados e começa dividindo o intervalo de valores da variável em faixas, que podem ser de tamanho igual ou conter a mesma frequência de dados.

Exemplos comuns incluem a discretização por intervalos iguais (*equal width*) e por frequência igual (*equal frequency*). Esse método é simples e rápido, sendo útil quando não se tem informação prévia sobre o relacionamento dos dados com a variável-alvo. Contudo, ele pode não otimizar a separação das categorias para tarefas preditivas.



EXEMPLO

Intervalos iguais

Imagine um conjunto de dados com a idade dos clientes variando de 18 a 80 anos. A discretização por intervalos iguais dividiria esse intervalo em, digamos, 4 categorias: 18–33, 34–49, 50–65 e 66–80. Cada registro seria classificado em uma dessas faixas baseando-se apenas no valor da idade, independentemente de outros dados.

Por frequência

Outro exemplo é a discretização por frequência, em que o mesmo conjunto poderia ser dividido em quatro grupos, cada um contendo aproximadamente 25% dos registros, adaptando os intervalos para equilibrar a quantidade de dados em cada categoria.

Discretização supervisionada

Utiliza informações da variável-alvo para guiar a criação das categorias. O objetivo é maximizar a relação entre as faixas discretizadas e a variável que se quer prever ou explicar.

As técnicas supervisionadas utilizam critérios como entropia, ganho de informação, ou similaridade para definir os melhores limites entre intervalos, buscando aumentar a pureza das categorias em relação à variável-alvo. Isso resulta em uma discretização que pode melhorar significativamente o desempenho de modelos de aprendizado de máquina, ao criar categorias com maior poder discriminativo.

Aqui, a criação das categorias é guiada pela variável-alvo, buscando melhorar a capacidade preditiva dos dados.



EXEMPLO

Exemplo 1

Considere o mesmo conjunto de dados com idades, mas agora com a variável-alvo “probabilidade de compra”. A discretização supervisionada avaliaria onde definir os limites das faixas etárias para maximizar a distinção na probabilidade de compra entre elas. Assim, a faixa “18–25” poderia ser um grupo, “26–40” outro, e “41–80” um terceiro, se esses intervalos produzirem maior separação entre clientes que compram e os que não compram. Técnicas como o método de entropia de informação analisam o ganho de informação para definir esses cortes de forma otimizada.

Exemplo 2

Imagine um banco que quer prever se um cliente vai fazer um empréstimo (variável-alvo: “Sim” ou “Não”) com base na renda mensal (variável contínua). Na discretização supervisionada, a renda não é dividida arbitrariamente em faixas iguais, mas sim em intervalos que maximizam a separação entre clientes que fizeram ou não o empréstimo. Por exemplo, o método pode descobrir que clientes com renda até R\$ 2.000 têm uma alta chance de não fazer empréstimo, enquanto os clientes com renda entre R\$ 2.001 e R\$ 5.000 têm uma chance mista, e clientes com mais de R\$ 5.000 têm maior probabilidade de fazer o empréstimo. Assim, ao fazer essa divisão orientada pela variável-alvo, o modelo pode aprender regras mais precisas de classificação, usando as categorias de renda geradas pela discretização supervisionada.

Em resumo, a escolha entre métodos supervisionados e não supervisionados depende do contexto: para análises exploratórias ou preparação inicial, a discretização não supervisionada é rápida e eficiente; para modelagem preditiva e tarefas onde a variável-alvo é conhecida, a discretização supervisionada oferece vantagens claras, pois é orientada para melhorar a relação entre atributos e resultado. Conhecer e aplicar esses métodos de forma adequada é crucial para extrair o máximo valor dos dados discretizados.

| Técnicas de discretização

Existem várias técnicas específicas de discretização, como:

Discretização por intervalos iguais



Esta técnica divide o intervalo total dos dados contínuos em faixas de tamanho igual. Por exemplo, se temos uma variável que varia de 0 a 100 e queremos criar 5 categorias, cada intervalo terá tamanho 20 (0–20, 21–40, 41–60, 61–80, 81–100). É uma técnica simples e rápida, porém pode gerar categorias desequilibradas quando os dados não estão uniformemente distribuídos.

Discretização por frequência



Embora o número de categorias seja definido, cada categoria terá aproximadamente o mesmo número de registros. Por exemplo, dividindo uma lista de 1000 valores em 5 grupos, cada grupo conterá cerca de 200 valores. Os intervalos serão definidos conforme a distribuição real dos dados. Isso é útil para evitar categorias com poucos dados, mas pode criar intervalos de tamanhos variados.

Discretização baseada em entropia



Essa técnica é supervisionada e utiliza critérios da teoria da informação para definir os limites que maximizam a “pureza” das categorias em relação a uma variável-alvo. Por exemplo, ao prever se um cliente compra ou não, os intervalos são criados para maximizar a distinção na variável-alvo dentro de cada categoria, usando o conceito de ganho de informação (redução de entropia).

Discretização baseada em similaridade



Nesta abordagem, é feita a segmentação dos dados em grupos que compartilham características similares, buscando minimizar a variabilidade interna dos grupos e maximizar a diferença entre eles. Técnicas como *clustering* (agrupamento) são aplicadas para definir os intervalos, levando em conta medidas de distância ou correlação nos dados.

Essas técnicas apresentam diferentes vantagens e aplicações, permitindo ao analista escolher a abordagem que melhor equilibra simplicidade, interpretabilidade e *performance* para o problema específico em análise.

| Aplicações práticas da discretização em análise exploratória de dados

A discretização é uma técnica valiosa para tornar os dados mais manejáveis e interpretáveis durante a análise exploratória. Quando lidamos com variáveis contínuas, muitas vezes é difícil visualizar padrões e tendências devido à grande variabilidade dos valores. Ao agrupar esses valores em categorias discretas, facilitamos a identificação de comportamentos relevantes, como segmentos de clientes por faixa etária, níveis de renda ou classes de temperatura.

Na prática, a discretização permite a criação de tabelas de contingência e gráficos categóricos, que ajudam a revelar relações importantes entre variáveis, inclusive em contextos multidimensionais. Por exemplo, ao analisar dados de vendas, discretizar a variável “quantidade vendida” em faixas “baixa”, “média” e “alta” permite comparar mais facilmente a influência de outras variáveis, como localização ou canal de venda.

Além disso, a discretização ajuda a preparar os dados para modelagens que exigem atributos categóricos, como árvores de decisão e regras de associação. Ao segmentar os dados em categorias significativas, o analista pode aplicar técnicas preditivas e descritivas mais adequadas, aumentando a robustez dos resultados e a qualidade dos insights extraídos. Dessa forma, a discretização se torna um passo estratégico para transformar dados brutos em conhecimento valioso.

| Videoaula: Discretização de dados usando Pandas e Numpy

Nesta videoaula, será apresentado o processo prático de discretização de dados usando as poderosas bibliotecas Python, Pandas e Numpy.

Você vai aprender a criar intervalos, definir categorias e transformar variáveis contínuas em discretas aplicando técnicas essenciais para melhorar seu entendimento dos dados e preparar para modelos que exigem dados categóricos.

Além disso, a videoaula mostrará exemplos passo a passo, para que você possa aplicar essas técnicas em seus próprios projetos com facilidade e confiança, potencializando sua análise exploratória.

| Ligando os pontos

Você sabia que a discretização pode revelar padrões ocultos que passam despercebidos quando analisamos números contínuos?

Em dados financeiros, pequenas variações nos valores monetários muitas vezes são consideradas ruído, dificultando a identificação de segmentos importantes de clientes. Ao agrupar os dados em categorias discretas, esses ruídos são suavizados, permitindo identificar comportamentos ou tendências que impactam decisões estratégicas, como campanhas de *marketing* personalizadas ou políticas de crédito mais eficazes. Portanto, discretizar não é apenas uma questão técnica, mas uma estratégia inteligente para extrair mais valor dos dados!

Imagine um conjunto de dados com a seguinte variável contínua: renda mensal (em reais) de 12 clientes:

Cliente	Renda (R\$)
1	1.800
2	2.200
3	2.500
4	2.700
5	3.300
6	3.500
7	4.000
8	4.200
9	4.800
10	5.000
11	5.600
12	6.000

Usando discretização por intervalos iguais com três categorias divididas igualmente entre 1800 e 6000, teremos:

- Baixa renda: 1.800 – 3.133.
- Média renda: 3.134 – 4.466.
- Alta renda: 4.467 – 6.000.

Os clientes seriam classificados assim:

- Baixa: 1.800, 2.200, 2.500, 2.700, 3.300 (note que 3.300 está perto do limite).
- Média: 3.500, 4.000, 4.200.
- Alta: 4.800, 5.000, 5.600, 6.000.

Vemos que pequenas variações como 3.300 ou 3.500 mudam a categoria, agrupando clientes de forma prática. Sem discretizar, essas diferenças poderiam ser ruídos dificultando análises e decisões focadas em perfis claros.

Essa simplicidade da discretização ajuda a revelar padrões de comportamento e facilita a criação de estratégias personalizadas, por exemplo, para ofertas de crédito ou promoções específicas para cada faixa de renda.

| Questões reflexivas

Aqui estão duas questões reflexivas para estimular o pensamento crítico sobre discretização e análise de dados no contexto do trabalho.



EXERCÍCIO

Questão 1 – Em um projeto de análise de dados, você recebe um conjunto com variáveis contínuas que apresentam alta variabilidade e ruídos. Deveria optar por discretizar essas variáveis antes da análise? Quais fatores você consideraria para tomar essa decisão e quais impactos a discretização poderia ter nos resultados e interpretações?

Questão 2 – Suponha que você está trabalhando em um modelo preditivo e utiliza a discretização supervisionada para definir intervalos com base na variável-alvo. Quais riscos há em se basear fortemente na variável-alvo para segmentar as variáveis preditoras? Como garantir que o modelo não fique “viciado” em uma discretização muito específica ao conjunto de dados?

Questão 3 – Imagine que você é responsável pela análise exploratória de um conjunto de dados de clientes de uma empresa de serviços financeiros. As variáveis incluem idade, renda mensal (valores contínuos) e o perfil do cliente para crédito (aprovado ou não). Seu desafio é aplicar a discretização para preparar esses dados para uma análise mais robusta

e criação de modelos preditivos.

Aqui está o conjunto de dados hipotético, com as variáveis contínuas renda mensal e idade, e a variável-alvo perfil para crédito (aprovado ou não):

Cliente	Idade	Renda (R\$)	Crédito
1	23	1800	Não
2	30	2200	Não
3	35	2500	Sim
4	40	2700	Sim
5	45	3300	Sim
6	50	3500	Sim
7	29	4000	Não
8	33	4200	Sim
9	60	4800	Sim
10	62	5000	Sim
11	55	5600	Sim
12	48	6000	Não

a) Qual técnica de discretização você escolheria para as variáveis contínuas e por quê?

b) Como a discretização pode impactar a interpretação dos dados e a *performance* dos modelos de crédito?

c) Quais cuidados você tomaria para evitar perder informações importantes durante a discretização?



Resposta



Questão 1

Sugestão de resposta:

A decisão depende do tipo de análise e do objetivo do projeto, além do comportamento dos dados. Discretizar pode facilitar a identificação de padrões e reduzir ruídos, favorecendo a visualização e criação de modelos interpretáveis. Porém, pode haver perda de informação se os intervalos não forem bem definidos. Também deve-se analisar se o modelo ou algoritmo a ser usado requer dados discretos para funcionar corretamente.

Questão 2

Sugestão de resposta:

O risco principal é o *overfitting*, que ocorre quando a discretização é tão ajustada que funciona bem só para os dados atuais e não generaliza para dados futuros. Para evitar isso, deve-se usar validação cruzada, testar a discretização em diferentes subconjuntos e garantir que os intervalos façam sentido para o problema real, mantendo um equilíbrio entre ajuste e generalização.

Questão 3

Sugestão de resposta:

a) A escolha da técnica deve considerar os objetivos e a distribuição dos dados; por exemplo, discretização por frequência pode equilibrar categorias, enquanto métodos supervisionados podem otimizar segmentos relevantes para aprovação de crédito.

- b) A discretização pode facilitar a criação de grupos de clientes mais homogêneos, melhorando a interpretação e desempenho do modelo; porém, má-definição dos intervalos pode levar à perda de nuances importantes ou à introdução de ruídos.
- c) Importante analisar a distribuição dos dados, validar a discretização com a variável-alvo, e garantir que o número de categorias seja adequado para manter o equilíbrio entre simplificação e perda de informação. Testar diferentes métodos e evitar *overfitting* são práticas recomendadas.
-

| Ligando conceitos

Ao longo desta semana, exploramos a importância da discretização como uma poderosa ferramenta para transformar dados contínuos em categorias que facilitem a análise e a modelagem, tornando os dados mais acessíveis e interpretáveis, especialmente no contexto do aprendizado de máquina. Compreendemos os métodos supervisionados e não supervisionados, que possibilitam flexibilidade na preparação dos dados, seja buscando simplicidade ou otimizando a capacidade preditiva dos modelos. Além disso, as técnicas específicas de discretização, como por intervalos iguais, por frequência ou baseadas em critérios matemáticos, oferecem alternativas para diferentes tipos de dados e objetivos analíticos. Por fim, vimos como a discretização tem aplicação prática fundamental na análise exploratória, ajudando a revelar padrões ocultos e a preparar os dados para tomadas de decisão mais eficazes. Esses conceitos, quando aplicados com reflexão e cuidado, ampliam sua capacidade de extrair valor real dos dados no dia a dia profissional.

| Referências

CASTRO, D. G. F. L. N. **Introdução à mineração de dados: conceitos básicos, algoritmos e aplicações**. Rio de Janeiro: Saraiva Uni, 2016.

FACELI, K.; LORENA, A. C.; GAMA, J.; ALMEIDA, T. A.; CARVA, A. C. P. L. F. **Inteligência artificial** – uma abordagem de aprendizado de máquina. 3. ed. Rio de Janeiro: LTC, 2025.

FERREIRA, R. G. C.; MIRANDA, L. B. A.; PINTO, R. A. *et al.* **Preparação e análise exploratória de dados**. Porto Alegre: SAGAH, 2021.



© PUCPR - Todos os direitos reservados.