



IA na Gestão de Negócios


UNIDADE 03

Planejamento de Vendas e Operações – Parte 1

| Planejamento de Vendas e Operações – Parte 1

Para aumentar a vantagem competitiva comercial em um ambiente de constantes mudanças, os gestores de uma organização devem tomar a decisão correta no momento certo, com as informações que tiverem em mãos. Uma previsão acertada tem papel fundamental nesse processo. Compreendendo melhor o comportamento do consumidor e sua resposta às alterações nos fatores controláveis que o varejista articula. Os gestores podem prever os resultados de suas ações e obter dados de diagnósticos para se suprir de informações que permitam ações acertadas no futuro. Inúmeras técnicas de previsão têm sido desenvolvidas na tentativa de melhor elucidar o problema de previsão de vendas. Tais técnicas podem ser divididas em dois grupos principais de abordagem: **qualitativa** e **quantitativa**. Dentro de cada grupo, várias subdivisões distintas já foram propostas na literatura para classificar as técnicas de previsão, sendo que uma delas é apresentada na figura a seguir.

Figura 1 – Esquema de classificação de técnicas de previsão



Fonte: Adaptado de PASSARI (2003)

Uma série temporal é uma sequência de valores, ordenados no tempo, de uma variável de interesse particular. Modelos de séries temporais realizam previsões baseadas em uma série de dados observados em intervalos de tempo regulares, buscando padrões no passado para prever o futuro. Esse tipo de modelagem é especialmente útil quando há pouco conhecimento da base teórica sobre o processo em que os dados foram gerados ou quando a complexidade da explicação sobre o processo é muito alta, como no caso de previsão de vendas no varejo.

Apesar de sua grande aceitação, as técnicas de previsão de séries temporais possuem sérias limitações. A mais visível delas é o fato de as causas que agem sobre as variáveis previstas serem completamente ignoradas. Todas as forças externas, como fatores econômicos, esforços de marketing, ações dos competidores e assim por diante, são desprezadas. Outra deficiência é que os padrões históricos que geraram as séries mudam com o tempo, e algumas técnicas podem não detectar tais mudanças. Assim, estas técnicas podem resultar em previsões com baixa acurácia, especialmente a longo prazo.

Entretanto, para obter informações suficientes para elaborar um planejamento de ações e obter um valor futuro de venda mais próximo do real, algumas técnicas de previsão de séries temporais demonstram grande aplicabilidade e excelentes resultados. A preocupação, nesta aplicação, é prever com certo grau de precisão o que vai acontecer e não o porquê vai acontecer. Com isso, as técnicas mais avançadas de previsão de séries temporais, os algoritmos matemáticos e estatísticos, podem ser implementados, mesmo que o esforço computacional seja muito grande, de modo a encontrar valores futuros de venda que indiquem como prever ações e antecipar as necessidades do mercado.

A literatura é vasta quanto à utilização de algoritmos de previsão de séries temporais. Nela encontram-se evidências de que, mesmo não considerando as variáveis de mercado, podem-se ajustar os modelos de modo a compreender e prever períodos de sazonalidades, tendências de queda de venda ou de elevação de venda, comportamento de clientes e outras características mercadológicas. O avanço das técnicas baseadas em Redes Neurais é um exemplo de que se pode prever um valor de venda com qualidade e boa precisão, gerando uma referência para antecipação das ações operacionais.

Unindo a previsão a um planejamento estratégico nas operações, já discutidas nas aulas anteriores, pode-se oferecer uma vantagem competitiva no mercado. Assim, procura-se aumentar o nível de serviço logístico e diminuir a ruptura, aumentando a qualidade de serviço ao cliente. O modelo chamado de VMI (*Vendor Managed Inventory* – Estoque gerenciado pelo fornecedor) corresponde à prática onde o fornecedor é responsável pelo gerenciamento do estoque no cliente, inclusive no processo de reposição, disponibilizando o material a ser usado quando e

quanto for necessário pelo cliente. O **termo** VMI surgiu no início dos anos 90 nos Estados Unidos durante a implementação de novos projetos de alguns grandes varejistas, sendo o Walmart um destes. Apesar da origem, a prática passou a ser utilizada por grandes empresas de manufatura como um meio de amenizar o crescente poder dos grandes varejistas.

A implementação e a operacionalização de um VMI só fazem sentido se estiverem baseadas em uma relação de parceria e confiança, com um compartilhamento extensivo de informações. Seu funcionamento efetivo requer significativa integração de informações e de coordenação de processos e de operações entre as empresas da *Supply Chain* (Cadeia de Suprimentos) nele envolvidas. Muitas empresas têm dificuldades em entender um destes princípios fundamentais do VMI que é a relação de parceria, colaboração entre fornecedor/cliente, e acabam implementando-o de forma equivocada, utilizando-o como um meio de abdicar-se da responsabilidade em executar um planejamento mais detalhado e de maior qualidade e transferir parte dos custos de estoques aos fornecedores. O **conceito** VMI surgiu em meados da década de 80, porém, só agora com o gerenciamento da cadeia de suprimentos é que está sendo utilizado para aumentar a eficiência do sistema, tratando-se de uma alternativa para a tradicional relação comprador/fornecedor. Ao implantar o VMI, o fluxo de informações (dados de inventário do cliente) é transmitido ao fornecedor geralmente através de EDI (*Electronic Data Interchange*) sendo que ele tem a autonomia de emitir pedidos de reposição de materiais para o cliente quando houver a necessidade.

Alguns requisitos básicos para o sucesso do VMI, são:

- o compromisso dos líderes, que devem conhecer o esforço que será necessário e os recursos que serão investidos;
- aceitação e contribuição dos funcionários;
- sincronização de arquivos e/ou dados; o fornecedor e o cliente devem ter seus arquivos compartilhados e atualizados em tempo real;
- apoio e aceitação do cliente quanto ao plano de reposição e estocagem do fornecedor;
- troca de informações sobre consumo por parte do cliente ao fornecedor; e
- um registro rígido dos dados, pelo cliente, como a atualização de itens consumidos.

O VMI pode ser uma boa alternativa para a redução do efeito chicote na cadeia de suprimentos. A seguir tem-se algumas vantagens e desvantagens da implementação deste modelo tanto sob a perspectiva das empresas fornecedoras quanto das empresas clientes.

Quadro 1 – Vantagens e desvantagens do VMI

	Empresa fornecedora	Empresa cliente
Vantagens	Melhor atendimento e maior “fidelização” do cliente; Melhor gestão da demanda; Melhor conhecimento do mercado.	Menor custo dos estoques e de capital de giro; Melhor atendimento por parte do fornecedor; Simplificação da gestão dos estoques e das compras.
Desvantagens	Custo do estoque mantido no cliente; Custo da gestão do sistema.	Maior dependência do fornecedor; Perda do controle sobre seu abastecimento.

Fonte: Adaptado de Pires (2010)

As técnicas de previsão de demanda podem ser elaboradas por dois métodos: quantitativos e qualitativos.

Métodos quantitativos

- Levam em conta dados históricos (repetição do passado);
- Modelos matemáticos e estatísticos como principais fontes de previsão;
- Média Móvel, Ponderação Exponencial, Decomposição de Séries Temporais, ARIMA (Box & Jenkins) e Redes Neurais Artificiais.

Métodos qualitativos

- Recorrem a julgamento, intuição, pesquisas ou técnicas;
- Método Delphi, o Júri de Executivos, a Força de Vendas, a Pesquisa de Mercado, Analogia Histórica, o Painel de Consenso e a Previsão Visionária.

Uma técnica muito utilizada nas empresas é a junção do método quantitativo e do qualitativo. Esta junção pode proporcionar um resultado mais abrangente, já que os valores serão referentes a dados históricos da empresa com interferência de conhecimentos adquiridos pela experiência de colaboradores.

Previsões baseadas em séries temporais são realizadas a partir de dados passados e não sofrem alterações de outras variáveis. É o método mais simples e usual de previsão e quando bem elaborado oferece bons resultados.

Uma **série temporal** é qualquer conjunto de observações ordenadas no tempo. Podemos ter séries temporais discretas ou contínuas. Uma série temporal **discreta** é obtida através da amostragem de uma série temporal contínua em intervalos de tempos iguais. Na prática, não existe um modelo único de previsão capaz de ser o melhor em todas as situações. Uma combinação dos resultados de vários modelos pode transformar-se em previsões mais estáveis e de maior exatidão.

Há uma infinidade de pesquisas e pesquisadores com o foco em elaborar uma metodologia capaz de auxiliar a tomada de decisões no meio empresarial. São apresentados os principais modelos estatísticos de previsão, tais como Suavização Exponencial, Decomposição, Box & Jenkins e Redes Neurais. Além disso, busca-se um procedimento para a estruturação de um sistema de previsão de demanda onde, a partir de uma sequência estruturada de passos, as diretrizes para a implementação das técnicas de previsão de demanda são indicadas. Não preciso – nem afirmar – que esse tema está intimamente ligado às aplicações de técnicas de IA nos negócios. A previsão é a base de todas as ações. É o começo de tudo. Cabe a nós, estudantes dessa área, nos aprofundarmos mais neste tema.

Uma observação importante na gestão da cadeia de suprimentos, conhecida como **efeito chicote**, sugere que a variabilidade da demanda aumenta à medida que a cadeia de suprimentos aumenta. Foram citados dois motivos que podem causar este efeito: a **previsão de demanda** e a **ordem de prazo de entrega**. O efeito chicote pode ser reduzido caso a informação da demanda seja ou não centralizada no cliente. O comportamento de entrega evidencia, nestes últimos anos, que a demanda tem crescido significativamente, com sazonalidade das mais variadas possíveis.

Tem-se, como regra geral, que o método para gerar dados de previsão da demanda compreende três etapas:

1. análise dos dados históricos de demanda;
2. verificação da sazonalidade e aplicação do modelo matemático; e
3. validade e aplicação do modelo matemático.

O modelo matemático é validado teoricamente com dados reais, separados em conjunto de treinamento e conjunto de testes, e comparando-o com modelos clássicos de previsão e as respostas controladas (valores que deveriam ser previstos nos conjuntos de dados para testes). Um aspecto fundamental da gestão da cadeia de suprimentos é uma previsão de demanda precisa. Um problema com previsão de demanda intermitente, ou seja, uma demanda com uma grande proporção de valores zero é bastante comum para itens de manutenção. Este padrão é característico da demanda de estoques de peças de reposição com alto valor financeiro e de bens de capital, e é difícil de prever. A técnica clássica de Alisamento Exponencial e o Método de Croston (1972) são utilizados com frequência para este tipo de demanda e estão implementados em diversos *softwares* comerciais.

O estudo e a utilização de métodos estatísticos para a previsão de séries temporais ainda não têm grande penetração no meio comercial, mesmo com alta taxa de divulgação e interesse. A dificuldade de compreensão e o rigor matemático dos métodos são grandes estímulos para “fugas” da tentativa de absorção das lógicas envolvidas. Nesses casos, costuma-se utilizar os pacotes prontos de linguagens como R e Python, mas que podem estar com grande subutilização, justamente devido à falta de compreensão da técnica estatística em si.

Após analisar a estrutura das séries temporais é necessário encontrar e ajustar o modelo de previsão condizente, com o objetivo de melhorar a acuracidade do modelo. Isto é, a taxa de assertividade da resposta obtida pelos métodos de previsão. Uma grande parte da aplicação de técnicas de previsão nos negócios trata de avaliar as séries históricas e, por meio desses dados, gerar previsões para os períodos subsequentes. Os métodos utilizados, em geral, são métodos tradicionais de previsão, por meio dos quais se verificam os erros cometidos ao longo do tempo e decide-se pela utilização do método que gera o menor erro acumulado. Em adição às previsões tradicionais obtidas, pode-se utilizar modelos econométricos, em que, por meio de uma função, gera-se uma previsão baseada em valores de algumas variáveis contextuais do mercado.

A estratégia de reposição de produtos deve ser efetiva no suprimento das lojas. Porém, deve ser controlada de modo a não reestocá-las excessivamente. A grande maioria dos controladores de estoque comercializados e usados nas empresas possui um sistema de previsão simplificado, em geral, utilizando métodos estatísticos, como o “Alisamento Exponencial Simples” e as “Médias Móveis”. Estes métodos utilizados para a previsão de séries temporais são de fácil entendimento e aplicação para séries temporais com alta instabilidade, porém, estes métodos acabam por não satisfazer o objetivo de prever com qualidade a série estudada.

A previsão da demanda é uma etapa-chave dentre as etapas de uma cadeia de suprimentos devido à complexidade e incertezas intrínsecas às suas atividades. Uma estratégia de reposição de produtos baseada nesses métodos pode ocasionar falhas de suprimento de produtos, seja pela falta ou excesso de estoque. Isso pode ocorrer com grande facilidade devido à característica de vendas dos produtos no setor de varejo, por exemplo, onde a instabilidade de vendas é muito grande. A sazonalidade, o preço do produto, o dia da semana, a concorrência, o atendimento e as promoções são componentes que influenciam diretamente no comportamento de vendas. A série temporal de vendas é muito sensível a qualquer um desses aspectos, fazendo com que um método mais robusto deva ser utilizado para a previsão de vendas.

Os métodos tradicionais são aplicados quando se consegue identificar a características de demanda e a composição do seu componente sistemático.

Médias Móveis



É o método mais conhecido e simples, por meio do qual se calcula a média de demanda dos n períodos anteriores e a cada nova ocorrência atualiza-se essa média, deslocando o cálculo em uma unidade de tempo para frente e obtendo a nova previsão.

Alisamento Exponencial Simples



É o método por meio do qual se incorpora a informação da previsão do período anterior e a ocorrência do período anterior, fazendo uma combinação convexa dessas duas informações. A estimativa do método está no ajuste do fator da combinação convexa calculada, a chamada “constante de alisamento”. Para a aplicação deste método, a demanda não pode possuir tendência ou sazonalidade para se obter bons resultados.

Método de Holt e Método de Winter

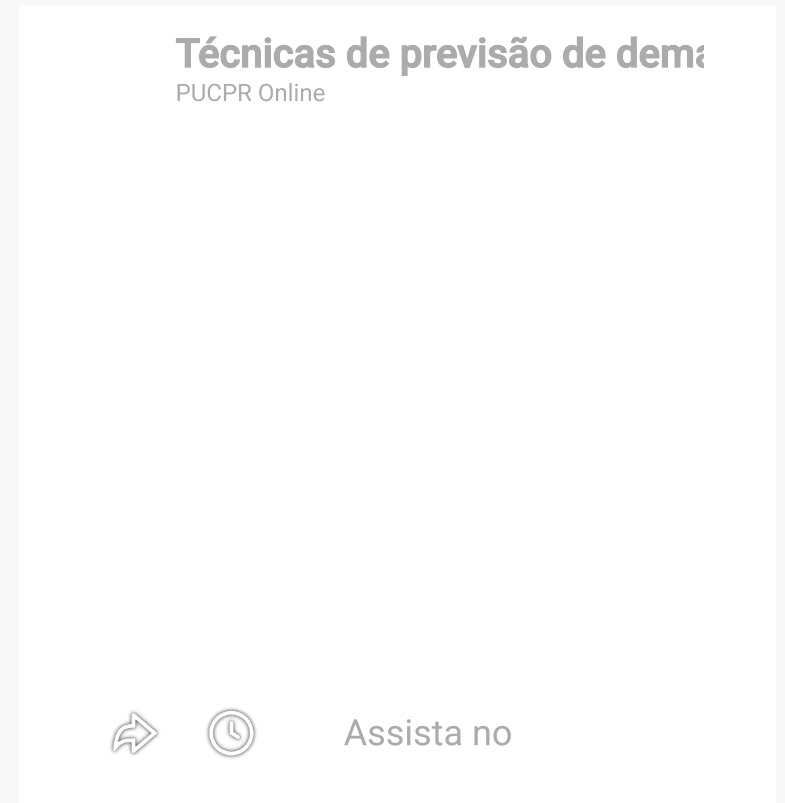


O Método de Holt é o alisamento exponencial corrigido pela tendência, e se o alisamento exponencial for corrigido pela tendência e sazonalidade tem-se o Método de Winter. Ambos os métodos necessitam da estimativa de coeficientes de influência dessas características e a determinação destes coeficientes, em geral, é feita por interpretações do decisor sobre a influência dos dados observados recentemente.

Os métodos de decomposição das séries temporais têm uma grande aceitação em sua aplicação devido a sua simplicidade matemática e precisão de informações. Este método decompõe a série histórica em quatro fatores: tendência, sazonalidade, ciclo e ruído branco ou índice residual. Na prática, o valor previsto, que é a multiplicação desses quatro índices, pode se resumir aos dois primeiros, Tendência e sazonalidade. Para a tendência, em geral, estima-se o valor através do clássico modelo dos Mínimos Quadrados. Já para a sazonalidade, o valor é calculado como o quociente da demanda real em relação à demanda média, num determinado período. A Análise de Regressão Múltipla é uma técnica estatística que ajuda a determinar o grau de associação entre um número de variáveis selecionadas e a demanda. A informação sobre as variáveis preditivas é convertida em uma equação de regressão, a fim de proporcionar uma previsão de demanda. Todos os métodos possuem aderência em aplicações reais. Pense assim: se um método fosse muito melhor que todos os outros, não haveria sentido em ter todos os outros. Assim, a escolha adequada do método em relação ao fenômeno a ser previsto é parte inerente a qualquer sistema de IA que se deseja implementar.

| VIDEOAULA: Técnicas de Previsão de Demanda

A videoaula apresenta os métodos de forma resumida e servirá de apoio para futuros desenvolvimentos relacionados a essas técnicas.



Ao aproximar os métodos estatísticos da necessidade de previsão nos negócios, percebe-se que, em muitos casos, as previsões ficam muito aquém do desejado. Neste momento, as técnicas baseadas em Redes Neurais Artificiais são opções de desenvolvimento. De acordo com Rumelhart (1986), que apresenta um modelo conexionista, baseado em RNAs, para a previsão de dados, este modelo pode ser descrito por seis elementos principais:

- Um conjunto de unidades de processamento;
- Um estado de ativação;
- Uma função de saída;
- Um padrão de interconexão;
- Uma regra de propagação;

- Uma regra de ativação.

Com isso, o último componente de RNAs é o ambiente onde a rede deve funcionar. É necessário especificar a natureza do ambiente, estabelecendo os possíveis padrões de entrada e saída. Em alguns modelos, por exemplo, no PDP (*Parallel Distributed Processing* / Distribuição de Processamento Paralelo) aplicado nas RNAs, o ambiente é representado como uma função estocástica que varia ao longo do tempo sobre um espaço de padrões de entrada. Geralmente, o ambiente é caracterizado como uma distribuição de probabilidade estável sobre um conjunto de padrões de entrada. Esta distribuição pode ser independente, ou não, de entradas ou de respostas passadas do ambiente.

Outro problema enfrentado pela retropropagação (algoritmo *backpropagation*) é a quebra de simetria, ou seja, se os pesos das RNAs começam todos com o mesmo valor e se a solução só pode ser alcançada com pesos diferentes, podendo, assim, o sistema não aprender. Essas características de RNAs trazem uma aplicabilidade no mundo dos negócios muito interessante para a generalização do modelo de previsão. Em diversos casos, a previsão utilizada em um planejamento de reposição ou compras será aderente caso tenha alta taxa de acerto, mesmo sem uma explicação do porquê isto está prevendo o que está. Embora uma alta taxa de acerto seja um grande impulsionador do uso de RNA em sistemas de IA, dependendo do caso e da aplicação, os profissionais que utilizam essa informação podem apresentar resistência para a sua real utilização. Essa resistência está associada, em geral, ao conhecimento empírico que este profissional possui. Embora não tenha comprovação científica alguma, o profissional com experiência pode argumentar que seu conhecimento tácito do problema tem maior capacidade de acerto do que uma técnica matemática como RNA que não tem “explicação” mercadológica clara. A única maneira de certificar quem está com a razão, o conhecimento humano prático ou a técnica de IA, é a comparação registrada da previsão e o cruzamento real do ocorrido *a posteriori*. Como muitas empresas não registram essa informação, o mercado e seus decisores ficam com a eterna discussão de quem acerta mais.

O problema de aprendizagem de RNAs a partir de amostras está relacionado sobre como obter o tamanho da amostra que é suficiente para a obtenção da função estocástica de aproximação quase ótima. Em relação à função de ativação, mostra-se que menos parâmetros quadráticos é quase ideal para o problema de previsão com RNAs. Entretanto, a aplicação prática e a utilização de previsões nas áreas comerciais estão pouco interessadas neste sentido. As RNAs podem ser aplicadas em diversas áreas. Um exemplo disso é a aplicação das RNAs para realizar a previsão de séries temporais em dados históricos em ligas de baseball. As RNAs têm sido bastante empregadas na predição de valores e na identificação de séries temporais. A rede neural MLP (*Multilayer Perceptron*) é a mais utilizada dentre as RNAs existentes, apesar de usar em sua maioria um mapeamento estático de entrada-saída.

Um ponto interessante é a discussão de Redes Neurais baseadas em regras ou símbolos de sistemas de Inteligência Artificial. Embora tenham um apelo prático enorme, ainda são raros os *softwares* comerciais que apresentam essa abordagem. São exemplos de aplicações de RNAs na previsão de séries temporais: os processos logísticos de reposição de produtos, a previsão de falência de bancos e/ou empresas, as políticas de estabilização de preços e a previsão de possíveis fraudadores. Muitas organizações estão investindo em RNAs e mineração de dados para soluções de problemas que tradicionalmente têm caído sob a responsabilidade das equipes de pesquisa e desenvolvimento das empresas. De maneira geral, as RNAs são modelos que relacionam dados de entrada com suas respectivas saídas. A partir da observação de exemplos e seu constante treinamento, obtém-se uma matriz de pesos, que, por sua vez, representam as ligações entre os neurônios de entrada e saída, imitando o que ocorre nas interconexões entre as células nervosas do cérebro humano. A grande vantagem do uso das RNAs relaciona-se com a adaptabilidade, que permite seu refinamento e minimização dos erros de previsão.

Com o intuito de melhorar os métodos de previsão de séries temporais, muitos trabalhos passaram a comparar dois ou mais métodos de previsão e tentar assim encontrar um que forneça melhores resultados de previsão, gerando menores erros. Em geral, deseja-se comparar o desempenho de previsão através de RNAs e métodos estatísticos tradicionais de previsão de séries temporais, como ARIMA e os modelos citados anteriormente. Os modelos baseados em RNAs parecem produzir previsões mais precisas. Entretanto, os modelos ARIMA ainda são uma referência adequada para a comparação com os outros modelos. A aplicação das metodologias de treinamento híbridas têm se mostrado mais eficientes, embora a dificuldade de uso comercial esteja no fato de poucos profissionais dominarem essas técnicas de forma suficiente para o desenvolvimento de modelos específicos de negócio.



PODCAST

Prever ou não prever? Eis a questão!

▶ 0:00 / 0:00 — 🔊 ⋮

| CONCLUSÃO

- Todo planejamento Operacional é iniciado pelo processo de Previsão.
- Selecionar o método de previsão adequado é uma necessidade inerente do processo a ser previsto.
- Técnicas simples podem e devem ser aplicadas quando o problema de previsão abordado é relativamente estável.
- As Redes Neurais Artificiais possuem uma estrutura que se adapta a diversos tipos de séries temporais.
- A topologia das RNAs escolhidas é definida por exaustivos testes computacionais.
- Há uma “corrida” por utilização de técnicas de Previsão e IA, porém, muitas vezes, técnicas consagradas como ARIMA são bastante assertivas e aderentes para uma previsão adequada.

| REFERÊNCIAS

ANDRADE, E. L. **Introdução à pesquisa operacional: método e modelos para análise de decisões**. 5. ed. Rio de Janeiro: LTC, 2015.

ARENALES, M. **Pesquisa operacional**. São Paulo: Elsevier, 2015. [Minha Biblioteca]

COLIN, E. C. **Pesquisa operacional: 170 aplicações em estratégia, finanças, logística, produção, marketing e vendas**. 2. ed. São Paulo: Atlas, 2017.

FÁVERO, L. P. **Pesquisa operacional: para cursos de engenharia**. Rio de Janeiro: LTC, 2012. [Minha Biblioteca]

MORETTIN, P. A. **Análise de séries temporais**. São Paulo: Blucher, 2018. [Minha Biblioteca]

NORVIG, P. **Inteligência artificial**. Rio de Janeiro: LTC, 2013.

SHARPE, N. R.; VEAUX, R. D. D.; VELLEMAN, P. F. **Estatística aplicada**. Porto Alegre: Bookman, 2011. [Minha Biblioteca]

STEIN, R. et al. **Modelagem e otimização de sistemas da produção**. Porto Alegre: SAGAH, 2018. [Minha Biblioteca]

