



IA na Gestão de Negócios

Planejamento de Vendas e Operações – Parte 2

Na prática, o GCS e a logística envolvida têm por objetivo levar o produto ou serviço no **local** certo, na **hora** certa e na **quantidade** correta. Isto é, realizar a atividade de reposição ou ressuprimento de modo efetivo. Em relação aos fenômenos com característica intermitente, a correta previsão pode fazer uma grande diferença no orçamento da corporação. É necessário entender que a fragmentação do processo logístico tradicional e a logística de processo intermitente, tem um impacto diferente nos custos de estoque e transporte.

As séries temporais utilizadas como objeto de estudo em modelos de previsão representam produtos comercializáveis envolvendo uma cadeia de produção e logística. Em geral, o número de produtos sendo manuseados simultaneamente é enorme. Por isso, muitas vezes é necessário definir critérios de classificação e/ou prioridade para encaminhar o fluxo de operações. Os critérios de classificação de séries cronológicas temporais podem ser definidos de várias formas, porém sempre estão alinhados com algum objetivo organizacional. Um método de classificação pode ser definido em uma das três grandes áreas:

- I. gestão de estoques;
- II. previsão de demanda; e
- III. estratégias de produção.

Em primeiro lugar, vários trabalhos na literatura propuseram metodologias de classificação de séries cronológicas com foco na gestão de estoques. Em geral, eles são associados e integrados com técnicas de gerenciamento de armazém (determinação do ponto de pedido, estoque de segurança, quantidade de pedidos/produção). Em segundo lugar, há um trabalho que se concentra na área II (previsão da demanda). A principal vantagem de ter um método de classificação eficaz para este fim é tornar a escolha do método de previsão mais assertiva.

Um dos aspectos importantes na seleção do método é o comportamento da demanda ao longo do tempo. A eficiência de diferentes métodos de previsão utilizados é fortemente influenciada pelo padrão da demanda do item, ou seja, se ele é regular, intermitente, *slow-moving*, etc. Sabe-se, por exemplo, que métodos baseados na abordagem ARIMA (Box & Jenkins) não conseguem distinguir entre tendência e sazonalidade

quando há muitos períodos com demanda zero, precisamente as séries intermitentes que são o foco desta discussão. Portanto, estas técnicas estatísticas clássicas não seriam as mais adequadas para prever a demanda lenta ou intermitente. Por outro lado, há métodos como o Método de Croston ou seus derivados que são conhecidos por serem específicos das séries intermitentes.

Finalmente, o objetivo III (estratégias de produção) está mal representado em termos de produção científica e até mesmo de aplicação no mundo corporativo. Em termos de estratégias de produção, questões como a definição de canais de distribuição, priorização de clientes, decisões de produção para encomenda ou para estoque, análise de ciclo de vida de produtos, entre outras cuja abordagem em termos de previsão de séries temporais é apenas um dos muitos aspectos a serem considerados.

A literatura trata da existência de três diferentes padrões de demanda, a saber: regular (*smooth*), esporádica (*sporadic*) e intermitente (*slow-moving*). A variabilidade da demanda ao longo do horizonte de previsão (LTD – *Lead Time Demand*), é uma característica que pode descrever os diferentes padrões de demandas existentes, contribuindo assim para a escolha do método de previsão e das políticas de reposição de estoques.

A variância do LTD é dada pela soma das suas três parcelas componentes: a variabilidade no número de ocorrências de demanda, a variabilidade do tamanho das ocorrências e a variabilidade no *lead-time* de reposição do estoque.

Seja o número de ordens que chegam ao sistema em unidades sucessivas de tempo independentes e identicamente distribuídos (i.i.d.) com média $\bar{n}$ e variância $var(n)$. Seja o tamanho das ordens que chegam i.i.d. com média $\bar{x}$ e variância $var(x)$. Seja também o *lead-time* de reposição do estoque i.i.d com média $\bar{L}$ e variância $var(\bar{L})$. Então, a variância do LTD pode ser estimada por:

$$var(LDT) = \bar{x}^2 \bar{L} var(n) + \bar{n} \bar{L} var(x) + n^2 \bar{x}^2 var(\bar{L})$$

Também podemos escrever esta equação em termos do coeficiente de variação de cada termo, tornando-a, assim, adimensional:


$$C_{LDT}^2 = \frac{C_n^2}{\bar{L}} + \frac{C_x^2}{\bar{n}\bar{L}} + C_L^2$$

Onde C_n é o coeficiente de variação da distribuição do número de ordens e assim por diante. Esta última equação possibilita que vários métodos sejam utilizados para classificar produtos através da partição de C_{LDT}^2 , dependendo de circunstâncias em particular. Supondo, por exemplo, que a ocorrência de chegada de demandas segue uma distribuição Poisson com média λ e os *lead-times* entre demandas sejam constantes, então:

$$C_{LDT}^2 = \frac{1}{\gamma\bar{L}} + \frac{C_x^2}{\gamma\bar{L}}$$

Dessa forma, os produtos podem ser classificados pela soma destas duas parcelas, onde a primeira parcela representa o número médio de *lead-times* entre demandas e a segunda parcela é uma medida do grau de “lumpiness” – ou **irregularidade da demanda**. A figura a seguir apresenta a proposta final do autor, que consiste na definição dos “limites” entre as regiões, criando quadrantes distintos.

Figura 1 – Representação da definição dos limites entre as regiões



Fonte: Adaptado de Williams (1984)

A definição dos limites entre as regiões é uma decisão gerencial e que depende do conjunto de dados usado. Não há uma orientação em relação à qual método de previsão utilizar em cada categoria de demanda, porém testes computacionais podem indicar o método mais adequado de acordo com a classificação da série temporal. Outra classificação defende que há cinco diferentes tipos de demanda: regular (*smooth*), irregular, *slow-moving*, e com intermitência média (*midly intermittent*) ou alta (*highly intermittent*).

Quadro 1 – Métodos de previsão de demanda

Variabilidade do número de ordens	Variabilidade do tamanho de ordem	Variabilidade do <i>Lead-Time</i>	Classificação do Padrão de Demanda
$\leq 0,74$	$\leq 0,10$	-	Regular
$\leq 0,74$	$> 0,10$	-	Irregular
$> 0,74$	$\leq 0,10$	-	<i>Slow-moving</i>
$> 0,74$	$> 0,10$	$\leq 0,53$	Intermitente Médio
$> 0,74$	$> 0,10$	$> 0,53$	Intermitente Alto

Fonte: Adaptado da Classificação de Eaves e Kingman (2004)

Como na classificação anterior, não há uma definição clara entre os limites dos tipos de demanda de acordo com os dados utilizados (estoque de peças de reposição, por exemplo), uma vez que a classificação não é universal. O critério desta classificação é bastante simples e pode ser utilizado nos sistemas de IA de forma automática: o primeiro quartil dos dados define o limite para a variabilidade do número de ordens (25% dos itens classificados como “Regular” ou “Irregular”). Os demais limites foram definidos pela mediana dos valores restantes.

Entre os métodos de previsão do tipo de série, intermitente ou *Slow-movings*, estão: Croston, SBA (*Syntetos e Boylan Approximation*), SES (Suavização Exponencial Simples ou *Single Exponential Smoothing*) e MMS (Médias Móveis Simples ou *Moving Average*). Quando tentamos aplicar os métodos de previsão neste tipo de série temporal, em geral não existe um método único que possa ser considerado o melhor em

todos os testes. Na prática, fica evidente que mesmo os métodos mais simples, como o SES e MMS, podem ser os melhores métodos para demandas do tipo intermitente e *slow-moving*, enquanto o método SBA e o Croston, originalmente indicado para a demanda intermitente, podem ser bons para a demanda regular (*smooth*) e irregular. Cabe ao tomador de decisão implementar sistemas de IA que façam comparações sistemáticas para esta decisão, delimitando critérios de aceitação de forma experimental.

A identificação do melhor método de previsão para um sistema de reposição de produtos de manutenção não é tão objetiva quando se utilizam métricas tradicionais para a medida de performance. As próprias medidas de erro podem ser questionáveis, pois, as medidas percentuais não podem ser calculadas quando a demanda é nula, e podem surgir diferentes conclusões dependendo da medida utilizada. Além disso, a escolha da estratégia de previsão e medição do erro pode impactar na análise e está aberta ao debate: se a previsão é feita para um único período ou para todo o período e se o erro é mensurado no período completo ou apenas quando a demanda ocorre.

É interessante comentar que sistemas que simulam o funcionamento de um sistema de reposição de estoques, utilizando todos os métodos de previsão e contabilizando os custos de estoques gerados por cada método, são indicados para a tomada de decisão. A conclusão geral é que uma simulação do sistema de reposição de estoques pode auxiliar na identificação do melhor método de previsão. Um dos trabalhos mais citados na literatura sobre este tema foi publicado por Syntetos e Boylan (2005). Segundo estes autores, a arbitrariedade na escolha dos limites entre os tipos de padrão de demanda propostos nas classificações citadas pode colocar em descrédito o potencial na aplicação destes modelos em contextos diferentes dos já estudados. Assim, tem-se um outro método de classificação baseado em duas métricas: o intervalo médio entre demandas não-nulas (ADI – *Average Inter-Demand Interval*) e o coeficiente de variação ao quadrado das demandas não-nulas (CV^2). Enquanto o ADI é uma medida de intermitência, o CV^2 é uma medida de variabilidade do tamanho das demandas. Esta proposta indica quatro tipos de demanda, a saber:

Smooth ou regular

Possui baixa variabilidade na demanda e baixo nível de intermitência.

Erratic ou errática

Possui alta variabilidade na demanda e baixo nível de intermitência.

Lumpy ou irregular


Possui alta variabilidade na demanda e alto nível de intermitência.

Slow-moving ou intermitente

Possui baixa variabilidade na demanda e alto nível de intermitência.

A “estrutura” de classificação é similar aos anteriores, em que existem fronteiras estabelecidas entre os diferentes tipos de demanda com valores fixos dividindo as regiões, conforme figura a seguir.

Figura 2 – Estrutura de classificação de Syntetos e Boylan (2005)



Fonte: Adaptado de Syntetos and Boylan (2005)

As RNAs também são aplicadas em séries temporais com muitos zeros em sua composição, isto significa que são aplicadas técnicas de inteligência artificial para previsão de séries temporais do tipo *lumpy*. Na aplicação nos negócios, há duas vantagens no uso de redes neurais: a flexibilidade de adaptação a diferentes comportamentos de demanda e a capacidade em capturar padrões não lineares nos dados. Os resultados obtidos em diversos testes com dados reais e aplicações diversas mostram que os métodos tradicionais possuem melhor desempenho apenas quando a quantidade de observações não-nulas aumenta consideravelmente (séries mais próximas do tipo *smooth*).

A partir de 2008, há um aumento considerável na quantidade de aplicações de técnicas baseadas em inteligência artificial para previsão de séries temporais. Entretanto, as publicações não abordam a questão da possível escolha do método de previsão e controle de estoque, dependendo do tipo de padrão de demanda, mas apenas da performance do método aplicado. Esta característica de comparação aumenta devido à maior capacidade computacional e à disponibilidade de sistemas de IA mais robustos, mas ainda distante do cotidiano das empresas em geral. Existe uma dificuldade em identificar a existência de um método de previsão que possa ser considerado “o melhor” para itens de reposição (*spare parts*), apesar do surgimento de novos métodos de previsão.

Embora muitos trabalhos tenham evidenciado um desempenho superior nos métodos derivados de Croston, ainda não foi realizada uma análise investigativa abrangente, e mesmo com pesquisas pontuais, a generalização dos resultados seria leviana. Além do fato de que cada pesquisa utiliza dados diferentes, também são utilizadas métricas de erro diferentes, dificultando a análise e a transferência desse conhecimento para sistemas que possam ser utilizados de forma direta pelo mercado corporativo. As aplicações nas empresas, em geral, não têm a preocupação científica com os desafios da aplicabilidade dos métodos em contextos reais, como por exemplo a falta de disponibilidade e/ou dificuldade de obtenção e processamento de dados, a complexidade de uso dos métodos, as habilidades do usuário, entre outras questões. Isto se deve a dois aspectos práticos básicos: os profissionais envolvidos não possuem a formação técnica apropriada e/ou é utilizado o método mais aderente, seguindo um critério empírico, de acordo com a resposta da “caixa peta” de linguagens como R ou Python.

VIDEOAULA: Métodos de Previsão de Séries Slow Movings e Aplicações

A videoaula apresenta uma análise de algumas possíveis aplicações de métodos para a previsão de séries do tipo *slow-movings*. Confira a seguir:

Métodos de previsão de séries slow
PUCPR Online



Assista no



PODCAST

POODCAST: Formando o profissional de IA, desafios e a busca do mercado – Episódio 3

O Podcast desta aula reflete sobre a capacidade dos sistemas de IA em relação aos métodos de previsão generalistas.

▶ 0:00 / 0:00 — 🔊 ⋮

| Conclusão

Considerando todas as críticas, sugestões e resultados da literatura e das aplicações reais relatadas em artigos científicos, diversas lacunas fundamentam o desenvolvimento de sistemas de IA para este tema. Os principais aspectos são:

- A tênue linha entre a pesquisa que desenvolve esquemas de classificação com o objetivo de facilitar a escolha do método de previsão e de controle de estoque e a necessidade de utilização da previsão para planejamento prático nas empresas não tem recebido tanta atenção quanto deveria.
- A busca por um esquema de classificação de caráter universal torna-se cada vez mais necessária conforme novos métodos de previsão e controle de estoque surgem.
- A aplicação de uma maior quantidade de métodos de previsão contribui para uma melhor abrangência na análise.
- A escolha do indicador de desempenho é de fato importante para a construção dos esquemas de classificação e identificação dos vencedores, porém os trabalhos publicados não delineiam este aspecto tanto quanto necessário e não o relacionam diretamente com características específicas dos artigos ou com as aplicações reais.

| Referências

ARENALES, M. **Pesquisa operacional**. São Paulo: Elsevier, 2015. [Minha Biblioteca]

COLIN, E. C. **Pesquisa operacional: 170 aplicações em estratégia, finanças, logística, produção, marketing e vendas**. 2. ed. São Paulo: Atlas, 2017.

FÁVERO, L. P. **Pesquisa operacional: para cursos de engenharia**. Rio de Janeiro: LTC, 2012. [Minha Biblioteca]

MORETTIN, P. A. **Análise de séries temporais**. São Paulo: Blucher, 2018. [Minha Biblioteca]

NORVIG, P. **Inteligência artificial**. Rio de Janeiro: LTC, 2013.

SHARPE, N. R.; VEAUX, R. D. D.; VELLEMAN, P. F. **Estatística aplicada**. Porto Alegre: Bookman, 2011. [Minha Biblioteca]

STEIN, R. et al. **Modelagem e otimização de sistemas da produção**. Porto Alegre: SAGAH, 2018. [Minha Biblioteca]

