



IA na Gestão de Negócios

Cadeia de Suprimentos 4.0: parte 2

Não há dúvidas de que os problemas de agrupamento estão no topo dos métodos de IA nos negócios, mas a maioria dos gestores está vendo apenas os agrupamentos estratégicos qualitativos. Em outras palavras, agrupamentos para uso em marketing, em geral. Agrupar clientes com o mesmo perfil, agrupar fornecedores com o mesmo tipo de pagamento, agrupar terceiros com as mesmas características, agrupar vendedores com os mesmos desempenhos, e assim por diante. Outra área de agrupamento, pouco explorada pela IA nos negócios é a dos agrupamentos físicos. Sejam de clientes para receberem seus pedidos, sejam de área de atuação de vendas, sejam de regiões para diferentes alternativas de abordagens.



PODCAST

Ouça o Podcast: “Dividir para conquistar” não: agrupando corretamente para conquistar.

▶ 0:00 / 0:00 — 🔊 ⋮

A maior parte dos problemas de distribuição logística de bens e serviços pode ser solucionada através de ferramentas de Pesquisa Operacional, como, por exemplo, métodos de roteirização de veículos, que têm por finalidade minimizar as distâncias percorridas pelos veículos e, consequentemente, a redução dos custos logísticos. O problema das p-medianas, também chamado de problema de **clusterização**, é um problema clássico da otimização combinatória. Esse problema é um caso especial de localização de recursos, com aplicações em diversas áreas de conhecimento, como engenharia, biologia, economia, reconhecimento de padrões, entre outras.

A análise de *clusters*, ou análise de agrupamento, é uma técnica estatística multivariada usada para classificar objetos em grupos relativamente homogêneos chamados de agrupamentos ou conglomerados, onde amostras são descritas por variáveis (atributos) p -dimensionais. Seu objetivo é dividir um conjunto de objetos em grupos de forma que as características entre os objetos de cada um destes sejam muito semelhantes entre si (coesão interna do grupo), mas sejam distintas entre objetos de diferentes grupos (isolamento externo do grupo).

Algoritmos de agrupamento são recursos importantes para a análise exploratória de dados e o reconhecimento de padrões. Eles permitem validar e explorar estruturas presentes nos dados, dispondo-as em partições. Tais algoritmos empregam o aprendizado dirigido aos dados, não demandando conhecimento prévio sobre as classes ou categorias, isto é, aprendizado não supervisionado. Tal particularidade favorece o estudo de problemas com pouco ou nenhum conhecimento prévio de possíveis classes existentes nos dados. Cada algoritmo é baseado em uma definição de *cluster* e faz uso de alguma heurística para achar o melhor agrupamento para um determinado conjunto de dados. Assim, cada algoritmo de agrupamento pode apresentar um comportamento diferente dos demais, conforme especificação dos dados no espaço de atributos.

Um algoritmo pode ser mais apropriado para encontrar *clusters* hiperesféricos e outro pode encontrar *clusters* de forma arbitrária, mas que possuam a mesma densidade. Sendo assim, surge a primeira dificuldade em análise de agrupamento: mesmo que os dados estejam estruturados de acordo com uma das possíveis configurações de agrupamento, torna-se difícil escolher o algoritmo que melhor se adapte ao problema, uma vez que as características dos dados não são conhecidas previamente.

As características de similaridade ou dissimilaridade são representadas pela proximidade entre as observações ao longo das variáveis, através de uma medida de semelhança. Estas são calculadas para todos os pares de objetos, permitindo a comparação entre quaisquer objetos por meio da medida de similaridade, como também a associação dos objetos semelhantes por meio da análise de agrupamento. Os métodos de análise de agrupamento, tradicionais, demandam elevado conhecimento do domínio por parte do usuário. E em muitos casos, cabe ao usuário a definição do número de agrupamentos, que é considerada a principal desvantagem dessas técnicas. Nesse contexto, a escolha da medida de similaridade, como também da técnica de agrupamento é, em geral, subjetiva.

Mas quando o agrupamento desejado é de um conjunto de clientes espacialmente distribuídos dentro de uma cidade, estado ou no país, uma das métricas usualmente utilizadas nos métodos de agrupamento quando as variáveis são quantitativas é a distância Euclidiana, que é representada pelo comprimento do segmento de reta que une dois pontos i e j através de suas coordenadas geográficas (x, y) .

A distância Euclidiana é dada da seguinte forma:

$$d_{ij} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2} \quad (1)$$

Onde (x_i, y_i) e (x_j, y_j) são as coordenadas geográficas dos pontos i e j , respectivamente.



CASE DE SUCESSO

Da mesma forma, temos diversos recursos computacionais que trazem informações espaciais de endereços físicos, como o Google Maps® e o Open Street Map (este último em plataforma aberta).

Quando necessitamos estudar a cadeia de suprimentos, o problema de clusterização e agrupamento recebe o nome de **Problema das p-medianas**, que deseja minimizar a distância entre os pontos de uma rede ou grafo até uma das “p” medianas selecionadas como mediana.

Se a empresa possui um produto físico ou serviço (não remoto) fatalmente irá se deparar com este problema, mais dia, menos dia. A complexidade facilmente aumenta, caso o desejo seja incorporar capacidade de instalações (ou futuras instalações), demandas de clientes, capacidade de fluxo de trânsito, entre outros aspectos logísticos. Inicialmente vamos explorar o caso capacitado simples.

O problema de localização de recursos (ou **facilidades***) capacitado por ser formulado como um problema de programação linear inteira mista, com n facilidades a serem localizadas e m clientes a serem atendidos, onde:

- Conjunto de clientes: $I = \{1, \dots, m\}$;
- Conjunto de potenciais facilidades: $J = \{1, \dots, n\}$;
- Variáveis de decisão:
 - x_{ij} : fração da demanda do cliente i atendida pela facilidade j ;
 - y_j : variável para definir se a facilidade j é ou não instalada (1 em caso afirmativo e 0, caso contrário);
- Parâmetro:
 - c_{ij} : custo total de transporte da facilidade j para atender o consumidor i ;
- O modelo matemático está descrito abaixo:

$$Z = \text{Min} \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij} \quad (2)$$

$$\sum_{j=1}^n x_{ij} = 1 \quad (3)$$

$$x_{ij} \leq y_j \quad (4)$$

$$\sum_{j=1}^n y_j = p \quad (5)$$

É comum vermos o termo “facilidades”, tanto no mercado como em livros. Na verdade, o termo deveria ser “instalação”, pois vem da tradução da palavra “*facilities*”, erroneamente incorporada no mercado como facilidades. Embora isso pouco importe para os tomadores de decisão, resolver o problema das p -medianas, ou do agrupamento, pode ser uma das estratégias mais significativas na aplicação de Inteligência Artificial nos negócios.

- A função objetivo (2) minimiza o custo de transporte para atendimento da demanda de todos os consumidores associados às respectivas facilidades.
- As restrições (3) garantem que a demanda de cada cliente seja atendida.
- As restrições (4) não permitem que a capacidade de cada facilidade seja excedida.
- E a restrição (5) determina o número de p facilidades a serem encontradas.

O problema das p -medianas capacitado corresponde à separação de uma coleção de objetos em p conjuntos. No problema de p -medianas capacitado acrescenta-se um conjunto de restrições sobre a capacidade de atendimento, no qual a soma das demandas dos nós que pertencem a determinado *cluster* não pode exceder a capacidade da mediana.

O problema das p -medianas capacitado foi estudado por diversos autores acadêmicos e muitos destes apresentam um ou mais algoritmos heurísticos para a obtenção da solução do problema. Na década de 90, a metodologia de diagramas de Voronoi foi amplamente utilizada para estudar a área de abrangência de facilidades, mas as primeiras formulações do problema foram desenvolvidas – apresentando resultados essenciais na teoria da localização de facilidades e gerando interesse entre os pesquisadores – na década de 60. Diversas abordagens heurísticas e métodos de busca em árvore foram desenvolvidos para o problema de p -medianas: Teitz e Bart (1968), Jarvinen e Rajala, (1972), Neebe (1978), Christofides e Beasley (1982). O esforço computacional necessário impulsionou muitas pesquisas que utilizam técnicas de relaxação (*local branching*, *lagrangeana/surrogate*, entre outras), obtendo bons resultados, principalmente os voltados para testes em casos reais.

O problema de clusterização pertence à classe dos problemas NP-Completo. Isso significa que o grau de dificuldade (espaço de busca) cresce exponencialmente com os parâmetros do problema, isto é, o esforço computacional necessário para a sua resolução aumenta com o tamanho do problema. Visto que é difícil e custoso determinar a solução ótima deste tipo de problema, dependendo do seu tamanho e complexidade, os métodos heurísticos se mostram mais interessantes para aplicação quando se tem, no negócio, a necessidade de decisão em segundos ou até em fração de segundos.

Define-se como sendo heurísticos quaisquer métodos ou conceitos que possam encurtar o tempo utilizado na resolução de um problema ou também todo método de otimização que não se prove a convergência matemática para o ótimo. Na literatura há muitas

definições similares e complementares entre si a respeito do que é um **algoritmo heurístico**. Estes **métodos heurísticos**, quando empregados em problemas de localização, resultam em boas soluções, a partir de diversas alternativas. Ainda que os métodos heurísticos não assegurem uma solução ótima, os ganhos de tempo e memória computacional e a qualidade satisfatória de resolução são bons motivos para escolher essa abordagem na localização de armazéns, por exemplo. Os métodos heurísticos têm como objetivo evitar a obtenção de mínimos locais, mantendo provisoriamente soluções não viáveis durante as iterações, buscando soluções adjacentes, podendo encontrar soluções melhores do que as encontradas anteriormente.

As chamadas **meta-heurísticas** vêm sendo foco de pesquisas nos últimos anos e uma abordagem bastante escolhida para o mercado de trabalho. Estas são consideradas não determinísticas e não tradicionais, baseadas em sistemas especialistas, técnicas de busca e processos iterativos com alguma inteligência no método de busca. Elas têm o objetivo de evitar a convergência de mínimos locais, mantendo temporariamente soluções ruins durante as iterações, a fim de varrer o espaço de busca das soluções, podendo retornar em melhores soluções.

Uma mesma técnica utilizada em um mesmo conjunto de dados pode resultar em agrupamentos diversos, o que se deve aos agrupamentos iniciais ou ao emprego de valores distintos nos parâmetros livres. Desta forma, conseguir agrupamento de boa qualidade passa a ser um processo de otimização, que busca selecionar bons agrupamentos iniciais e descobrir os parâmetros livres que melhor se adequam. Por exemplo, os Algoritmos Genéticos (AG), que são métodos de busca local, podem ser aplicados durante o processo de otimização.

O **Algoritmo Genético** é um modelo meta-heurístico que trata da evolução de uma população de soluções ao longo de várias iterações. Propostos inicialmente pelo matemático John H. Holland (1975), baseia-se em uma técnica de busca, inspirada no processo de evolução natural dos seres vivos da teoria de Darwin. A resolução do problema é alcançada por meio de operadores aplicados sobre as soluções que permanecem a cada iteração, nas quais sobrevivem os indivíduos mais resistentes e adaptados ao ambiente. O método dos algoritmos genéticos é bastante empregado no mercado, porém ainda de forma pontual, pois possui simplicidade de operação, boa eficácia na busca de um máximo global e aplicabilidade em problemas onde não se conhece o modelo matemático e em funções lineares e não lineares.

A implementação de um Algoritmo Genético se inicia com a escolha aleatória de uma população de cromossomos (uma possível solução para o problema). Essas estruturas são, então, avaliadas e associadas a uma probabilidade de reprodução de tal forma que as maiores probabilidades são associadas aos cromossomos (soluções viáveis para o problema) que representam uma melhor solução para o problema de otimização do que aqueles que representam uma solução pior. A aptidão da solução é tipicamente definida em relação à população corrente. Os critérios de parada são estipulados de acordo com a formulação do problema, podendo ser: número de iterações, convergência das soluções, similaridades das soluções, entre outros.

Algumas aplicações para os problemas de p -medianas, p -medianas capacitado e particionamento de grafos através do método de Algoritmo Genético Construtivo vêm mostrando resultados satisfatórios na otimização dos problemas de agrupamentos em geral, sendo que em muitas instâncias o algoritmo retornou à solução ótima num espaço de tempo reduzido. Essa abordagem de algoritmos evolutivos possui numerosos exemplos de estudos científicos e suas devidas aplicações reais nos negócios.

Entre os muitos tipos de métodos que existem na literatura cabe destacar os **algoritmos de agrupamento hierárquico** e os **algoritmos de particionamento**. Estes algoritmos geralmente fazem uso de uma determinada métrica de distância ou medida de associação para determinar a distância ou similaridade entre dois elementos, respectivamente. Os métodos hierárquicos são denominados desta maneira, por criarem uma relação de hierarquia entre os grupos que se formam, e após a formação desses grupos, o usuário determina quais os grupos a serem utilizados. Em contraponto, os métodos de particionamento utilizam-se de números fixos de grupos, ou seja, se definido um número n de objetos a serem agrupados em k grupos, estes métodos buscam as k melhores partições para os n objetos.

São comuns os casos em que os k grupos obtidos pelo método de particionamento serem de melhor qualidade que os encontrados pelos modelos hierárquicos. Em função destes resultados, os métodos de particionamento têm sido mais utilizados para análise de grupos, o que tem favorecido o desenvolvimento dos modelos baseados em k -médias e no k -medoid. A compactação ou homogeneidade de um *cluster* comumente está associada a uma pequena variação intra-cluster. A otimização deste tipo de critério tende a ser mais efetiva na análise de *clusters* esféricos ou bem separados, porém pode fracassar quando utilizada em estruturas mais complexas.



EXEMPLO

Como exemplos de algoritmos que buscam clusters compactos, podemos citar: k-médias (MACQUEEN, 1967), hierárquicos com ligação média (*average-link*) (JAIN e DUBES, 1988), Redes Neurais Artificiais, *Self-Organizing Maps* (KOHONEN, 1997). Cada algoritmo pode obter composições distintas com diversos níveis de refinamento (estruturas com *clusters* de densidades diferentes e com diferentes números de *cluster*), de acordo com os valores dos parâmetros. No algoritmo k-médias, por exemplo, para cada número de *clusters* k , é definida uma estrutura diferente.

O algoritmo k-médias, proposto por MacQueen (1967), tem por objetivo particionar um conjunto de dados segundo um parâmetro de k *clusters*. A técnica empregada no algoritmo é a de **realocação iterativa**, encontrando um ótimo local. Há diversas versões do algoritmo k-médias, cada uma propondo uma nova solução para alguma deficiência do algoritmo original. Por exemplo, a distância de Mahalanobis pode ser usada em problemas de *clusters* hiper-elipsóides, já a versão original é utilizada para encontrar *clusters* hiper-esféricos. O modelo de k-médias baseia-se na utilização do ponto médio das distâncias entre os objetos como o centro do grupo (centroide), enquanto o k-medoid toma o objeto espacial mais próximo do ponto médio da distância Euclidiana dentro do grupo como o centro. O k-medoid é um modelo mais robusto que o k-médias quanto aos grupos formados, e não depende da ordem que os objetos são examinados durante a execução.

Vale ressaltar aqui uma distinção importante: o problema das p-medianas seleciona p-pontos dentre os m-candidatos à mediana ($p \leq n$) para formar o *cluster* ou agrupamento. Problema de agrupamento clássico, o centroide pode ser qualquer valor determinado pelo método abordado. Aqui, neste caso, não importa quem é o ponto referência do agrupamento, mas, sim, o agrupamento em si. Desta forma, podemos formalizar este segundo caso.



EXEMPLO

Dado um conjunto de dados X que deve ser particionado em um número k de agrupamentos, o k-médias segue a seguinte forma (JAIN et. al., 1999):

1. Selecionar k pontos como os centroides iniciais, um conjunto de k centroides $C = \{ \mu_l, l = 1, \dots, k \}$ Essa inicialização pode ser aleatória ou pode utilizar algum método heurístico.
2. Associar cada objeto $x_i \in X$ ao *cluster* com o centroide mais próximo.
3. Recalcular os centroides de cada agrupamento obtido.
4. Se o critério de parada não foi alcançado, voltar ao passo 2. O critério de parada pode ser, por exemplo, não ter mais modificação nos centroides ou um número fixo de iterações.

No algoritmo k-médias, cada grupo é associado a um centroide (ponto central), e cada ponto é atribuído ao *cluster* com o centroide mais próximo. O número de *clusters* k deve ser especificado. Centroides iniciais são muitas vezes escolhidos aleatoriamente e os clusters gerados variam de uma iteração para outra. O centroide é a média dos pontos do *cluster* e sua proximidade pode ser medida pela distância Euclidiana, pela similaridade do cosseno, por correlação, entre outras medidas (a medida de distância deve ser especificada a priori). Os centroides se movem a cada iteração e as k-médias convergirão em um determinado critério de parada. Na maioria das vezes, a convergência acontece nas primeiras iterações. Este método visa a minimizar o erro quadrático ou variância dentro do agrupamento, mostrado pela Equação (6), na qual μ_l é o centroide do *cluster* e $d(x_i, \mu_l)$ é a distância (normalmente a Euclidiana) entre x_i e μ_l . O objetivo é minimizar a distância entre cada ponto e o centroide do cluster ao qual o ponto pertence.

$$var = \sum_{l=1}^k \sum_{x_i \in C_l} d(x_i, \mu_l) \quad (6)$$

Em comparativo com a análise de variância (ANOVA), o k-médias pode ser visto como ANOVA ao contrário, pois, enquanto o teste de significação da ANOVA avalia a variabilidade entre os grupos contra a variabilidade dentro do grupo (médias são distintas umas das outras), o algoritmo k-médias procura pela menor dispersão entre os grupos e a maior diferença entre as médias dos grupos. Um ponto negativo do

algoritmo k-médias é sua dependência da definição de k e a sensibilidade à escolha da partição inicial, sendo que esta última pode fazê-lo ficar preso em mínimos locais. A utilização do algoritmo de k-médias é favorecida por dados com aglomerados esféricos, portanto, dificultando que aglomerados com outra geometria sejam encontrados.

O desempenho de um algoritmo de agrupamento depende das características e da ordem de apresentação:

1. dos dados utilizados;
2. dos valores utilizados para seus parâmetros livres, e;
3. da escolha das partições iniciais.

Em geral, não há um modelo de agrupamento que possa ser aplicado a absolutamente qualquer problema e que seja capaz de demonstrar toda a variedade de estruturas – sejam homogêneas ou heterogêneas – que poderiam estar presentes no conjunto de dados. Outro fator que dificulta a escolha do algoritmo ideal para uma dada aplicação é que a maioria deles apresenta restrições.

Alguns dos problemas comuns aos algoritmos de agrupamento são:

- Adequação a domínios e/ou conjunto de dados restritos;
- Restrição dos formatos da estrutura que pode ser encontrada;
- Necessidade de conhecimento prévio do número de clusters presentes nos dados ou o difícil ajuste de parâmetros;
- Instabilidade dos resultados obtidos.

Determinar bons arranjos para os agrupamentos, bem como funções de aptidão, operadores matemáticos e alcançar parâmetros adequados ao algoritmo de agrupamento ainda são objetos de estudo. Estabelecer previamente qual o critério de agrupamento mais apropriado para revelar uma estrutura subjacente dos dados é uma tarefa muito difícil. Além disso, um mesmo conjunto de dados pode apresentar várias estruturas relevantes, cada uma de acordo com um critério de agrupamento diferente ou em diferentes níveis de refinamento. O emprego da análise de agrupamento para explorar o conjunto de dados é direcionado à obtenção de uma única estrutura que seja mais apropriada e ajustada aos dados. A obtenção de estruturas alternativas pode proporcionar diferentes interpretações dos dados, o que é de grande valia para os especialistas do domínio. Sendo assim, não é possível afirmar que um agrupamento seja sempre melhor que outro, gerando uma

dificuldade na escolha do algoritmo a ser aplicado ao problema em específico. Contudo, existe uma diversidade de técnicas de validação, capazes de auxiliar nessa escolha. Geralmente, cada técnica possui uma tendência a favorecer um determinado algoritmo, pois é baseada no mesmo conceito que o critério de agrupamento dos algoritmos desse tipo.

Outro ponto a ressaltar referente às técnicas da análise de *cluster* é que estas são de caráter exploratório e conduzem a agrupamentos em função das variáveis utilizadas. Assim, devem ser revisadas em função de critérios diferentes, buscando aprimorar os agrupamentos. A análise de cluster é simplesmente uma ferramenta auxiliar para o pesquisador e a experiência dos peritos é fundamental nesse processo, cabendo a eles debater os agrupamentos obtidos e, principalmente, elaborar hipóteses para a classificação encontrada. Esta última, por sua vez, não é uma tarefa fácil: em inúmeros casos não é possível explicar as diferenças entre os agrupamentos ou sequer caracterizar alguns deles.

Estas características somadas dão uma maior importância a este problema de agrupamento no mundo corporativo. Conhecer o problema e utilizar as técnicas de agrupamento (exatas ou heurísticas), para problemas diversos (de dados ou geográficos) torna-se um fator chave de sucesso na aplicação das técnicas de IA nos negócios. Para aumentar a capacidade e um suporte básico na solução de um problema de agrupamento, apresentamos a seguir o **algoritmo de Teitz e Bart** para agrupamento.

O algoritmo consagrado de Teitz e Bart (1968) serve para encontrar as medianas, minimizando a distância de cada ponto a sua mediana. O algoritmo de Teitz e Bart (1968) tem como saída os agrupamentos e as medianas, isto é, são escolhidos pontos, dentre o conjunto de pontos apresentado ao algoritmo, para serem as medianas. No algoritmo de Teitz e Bart:

1. Inicialmente, escolhe-se um conjunto S formado por p pontos, considerado como uma aproximação do conjunto $\bar{v}_p$ das medianas.
2. Verifica-se se algum ponto $v_i \in V - S$ pode substituir, de acordo com o algoritmo abaixo, algum ponto $v_j \in V$, produzindo um novo conjunto S' tal que: $S' = S \cup \{v_i\} - \{v_j\}$ e $\sigma(S') < \sigma(S)$.
3. Se isto for possível, substituímos v_j por v_i e S' é considerada uma nova aproximação para o conjunto $\bar{S}$, na qual nenhuma substituição de pontos possa produzir um número de transmissão menor.

VIDEOAULA: Algoritmos heurísticos de Teitz & Bart e k-médias para obtenção da solução do problema de agrupamento.

Um exemplo de lógica é apresentado na videoaula desta semana. Nela também serão apresentados possíveis problemas operacionais dessa abordagem.



Assista no

Conclusão

Os modelos matemáticos de Programação Linear, Inteira e Mista (PLIM) para problemas de agrupamento são equivalentes ou similares aos modelos de Inteligência artificial para clusterização. Em essência eles são o mesmo problema.

Agrupar é o mesmo que classificar, mediante um ou mais critérios. Agrupar bem significa, de uma forma geral, que outros novos objetivos de estudo podem ser classificados mais rapidamente.

O agrupamento em essência serve para identificação do tipo de tratamento que cada grupo ou cluster formado deve receber. No caso de roteirização, a definição do veículo. No caso de dados financeiros, o fornecimento de crédito ou não de um cliente.

As técnicas de agrupamento podem ser adaptadas para resolver quaisquer problemas de agrupamento, para tal, o tomador de decisão precisa de muito conhecimento sobre técnica, domínio dos pressupostos que a técnica preconiza, compreensão do objetivo principal das técnicas e criatividade sobre o problema abordado.

| Referências

ANDRADE, E. L. **Introdução à pesquisa operacional**: método e modelos para análise de decisões. 5. ed. Rio de Janeiro: LTC, 2015.

ARENALES, M. **Pesquisa operacional**. São Paulo: Elsevier, 2015. [Minha Biblioteca]

COLIN, E. C. **Pesquisa operacional**: 170 aplicações em estratégia, finanças, logística, produção, marketing e vendas. 2. ed. São Paulo: Atlas, 2017.

FÁVERO, L. P. **Pesquisa operacional**: para cursos de engenharia. Rio de Janeiro: LTC, 2012. [Minha Biblioteca]

MORETTIN, P. A. **Análise de séries temporais**. São Paulo: Blucher, 2018. [Minha Biblioteca]

NORVIG, P. **Inteligência artificial**. Rio de Janeiro: LTC, 2013.

SHARPE, N. R.; VEAUX, R. D. D.; VELLEMAN, P. F. **Estatística aplicada**. Porto Alegre: Bookman, 2011. [Minha Biblioteca]

STEIN, R. et al. **Modelagem e otimização de sistemas da produção**. Porto Alegre: SAGAH, 2018. [Minha Biblioteca]



© PUCPR - Todos os direitos reservados.