



# Redes Neurais

UNIDADE 03

Rede neural convolucional (CNN )

## | Instalação do ambiente de desenvolvimento integrado (IDE)

Caso ainda não tenha o Anaconda Navigator e a IDE Spyder instaladas em seu computador, siga as instruções presentes na unidade de estudo 2 desta disciplina. Nela, estão todos os passos para a correta instalação do ambiente de desenvolvimento integrado (IDE) Spyder 5.


## | Rede Neural (CNN - Convolutional Neural Network)

### Conceitos gerais e Arquitetura

---

Uma rede neural convolucional (*Convolutional Neural Network* – CNN) é um tipo de arquitetura de rede neural profunda amplamente utilizado em tarefas de visão computacional, como reconhecimento de imagens e processamento de vídeo (Figura 1). As CNNs foram projetadas para lidar com a complexidade e alta dimensionalidade dos dados de entrada, como imagens, e apresentam uma capacidade excepcional de aprender padrões visuais complexos.

Fig. 1 – Arquitetura genérica de uma rede neural convolucional.



Autor, 2023.

Uma CNN é composta por várias camadas, cada uma desempenhando um papel específico no processo de aprendizado. As principais camadas de uma CNN incluem:

### Camada de convolução



Aplica filtros de convolução a pequenas regiões da imagem de entrada para extrair características relevantes, como bordas, texturas e formas. Utilizam Funções de Ativação que introduzem não-linearidade na rede, permitindo que a CNN aprenda relações complexas nos dados. Funções de Ativação comuns incluem a função ReLU (Rectified Linear Unit), sigmoide e tangente hiperbólica.

Em geral, uma CNN começa com uma ou mais camadas convolucionais para extrair características relevantes dos dados de entrada, com uma Matriz 3x3.

O número de camadas convolucionais pode variar dependendo da complexidade do problema e da natureza dos dados. Para problemas mais simples ou com conjuntos de dados menores, uma única camada convolucional pode ser suficiente. Problemas mais complexos ou conjuntos de dados maiores podem se beneficiar de múltiplas camadas convolutivas empilhadas em sequência para capturar características hierárquicas.

---

## Camada de Pooling



Reduz a dimensionalidade espacial das características extraídas pela camada de convolução, reduzindo a quantidade de parâmetros e tornando a rede mais eficiente.

Após as camadas convolucionais, é comum usar camadas de pooling para reduzir a dimensionalidade espacial e extrair características importantes.

As camadas de pooling ajudam a fornecer invariância nas características extraídas pelas camadas convolucionais.

Normalmente, é aplicado um downsampling de 2x2 usando o MaxPooling para reduzir a resolução espacial da matriz 3x3 (ou maior) da camada convolucional.

---

## Camada Flatten:



geralmente usada após as camadas de convolução e pooling para converter os mapas de características em um vetor unidimensional antes de serem passados para as camadas totalmente conectadas. Isso permite que as informações extraídas pelas camadas anteriores sejam tratadas como um vetor de características unidimensional, que pode ser processado pelas camadas totalmente conectadas para realizar tarefas como classificação ou regressão

## Camada Totalmente Conectada



Uma ou mais camadas de neurônios totalmente conectados que combinam as características aprendidas das camadas anteriores e produzem as saídas finais. Geralmente, a última camada totalmente conectada é seguida por uma função de ativação adequada para a tarefa específica, como a função softmax para classificação.

Após as camadas convolucionais e de pooling, é comum adicionar uma ou mais camadas totalmente conectadas para processar as características extraídas e realizar a classificação ou previsão final.

O número de camadas totalmente conectadas pode variar dependendo da complexidade do problema e da quantidade de características a serem processadas.

A camada de saída da CNN deve corresponder ao tipo de tarefa que está sendo realizada.

Para tarefas de classificação, uma camada de saída com um número de neurônios correspondente ao número de classes do problema é comumente usada.

Para tarefas de regressão, uma camada de saída com um único neurônio ou um número específico de neurônios relacionados ao número de saídas desejadas é utilizada.

Durante o treinamento de uma CNN, os pesos e os parâmetros da rede são ajustados por meio do processo de retropropagação do gradiente. Esse processo envolve a comparação da saída prevista da rede com os rótulos conhecidos dos dados de treinamento, calculando a perda e atualizando os pesos da rede de acordo com um algoritmo de otimização, como o gradiente descendente.

## Aplicações

---

As CNNs são altamente eficazes na extração de características hierárquicas e aprendizado de padrões complexos em dados de imagem. Elas demonstraram desempenho impressionante em várias tarefas, como classificação de imagens, detecção de objetos, segmentação semântica e muito mais. As CNNs revolucionaram o campo da visão computacional e continuam sendo uma ferramenta essencial para muitas aplicações que envolvem o processamento de dados visuais.

As redes neurais CNN são utilizadas principalmente para realizar trabalhos complexos que envolvem problemas como:

- Classificação: para distinguir e classificar elementos de um conjunto de dados com base em suas características individuais.
- Regressão: para realizar previsões numéricas sobre uma característica de um elemento, de acordo com outras características deste mesmo elemento.
- Reconhecimento de padrões: para identificar repetições sazonais de uma base de dados ou correlações entre variáveis que se repetem ao longo do tempo.

## | Quantidade de neurônios nas camadas da Rede Neural

Determinar o número ideal de neurônios para cada camada de uma CNN não é uma tarefa trivial, pois depende da complexidade do problema e da quantidade de dados disponíveis. No entanto, algumas diretrizes gerais podem ajudar na definição desses valores.

## Camadas Convolutivas

---

- O número de filtros (neurônios) em cada camada convolutiva geralmente aumenta à medida que avançamos nas camadas mais profundas da rede.
- Em camadas iniciais, é comum começar com menos filtros, como 32 ou 64, e aumentar gradualmente para camadas posteriores.

- Para problemas mais simples ou com conjuntos de dados menores, pode ser suficiente ter menos filtros em todas as camadas convolutivas.
- Problemas mais complexos ou conjuntos de dados maiores podem exigir um número maior de filtros em camadas convolutivas mais profundas.

## Camadas Totalmente Conectadas (Camadas Densas Ocultas e de Saída):

---

- O número de neurônios em camadas totalmente conectadas pode variar de acordo com a complexidade do problema e o tamanho do vetor de características fornecido pela camada anterior.
- É comum ter uma camada totalmente conectada intermediária com um número de neurônios entre as camadas convolutivas e a camada de saída.
- Para tarefas de classificação, o número de neurônios na camada de saída deve corresponder ao número de classes do problema.

É importante considerar a capacidade do modelo e evitar um número excessivo de neurônios, pois isso pode levar a um aumento na quantidade de parâmetros a serem aprendidos e causar problemas de *overfitting* (cenário em que um modelo se torna excessivamente ajustado aos dados de treinamento, prejudicando a capacidade de generalização para novos dados).

De qualquer forma, estas são apenas orientações gerais. A definição do número ideal de neurônios em cada camada é um processo iterativo de experimentação e ajuste a cada treinamento, dependendo do problema específico e dos dados disponíveis. O ajuste dos parâmetros é uma etapa importante no desenvolvimento de uma CNN e pode envolver técnicas como validação cruzada para encontrar a combinação ideal de valores.

## | Função de ativação

As funções de ativação são algoritmos que realizam cálculos matemáticos internos para disparar os sinais entre neurônios conectados de duas camadas.

As redes neurais CNN possuem várias e diferentes funções de ativação que podem ser utilizadas:

- **ReLU**: retorna 0 se o valor de entrada for negativo, e retorna o próprio valor de entrada em caso contrário.
- **Sigmoid**: conhecida como função logística, retorna o valor  $1 / (1 + e^{(-x)})$  para uma entrada  $x$ . Ou seja, mapeia probabilidades para o neurônio no qual foi aplicada.
- **Tangente hiperbólica**: retorna  $(e^x - e^{(-x)}) / (e^x + e^{(-x)})$  para uma entrada  $x$ , mapeando qualquer valor entre -1 e 1, assumindo valores negativos para entradas negativas e valores positivos para entradas positivas. Bastante útil para mapear entradas com valores simétricos sobre o eixo  $X$ .
- **Softmax**: mapeia vetores de números reais para vetores de probabilidades. Normalmente, é utilizada na camada de saída das redes CNN, auxiliando na identificação das classes dos elementos de entrada.

## | Função de perda

A Função de perda, também conhecida como Função Custo, verifica a discrepância entre as previsões e os dados reais de entrada, permitindo verificar a evolução do aprendizado do modelo durante o treinamento.

Alguns dos tipos mais utilizados nas redes neurais CNN são:

- **Categorical crossentropy**: amplamente usada em problemas de classificação multiclasse. Ela é adequada quando as classes são mutuamente exclusivas e cada exemplo de treinamento pertence a apenas uma classe. Essa função de perda calcula a divergência entre a distribuição de probabilidade prevista pelo modelo e a distribuição de probabilidade real dos rótulos.
- **Binary crossentropy**: usada em problemas de classificação binária. Ela é adequada quando cada exemplo de treinamento pode pertencer a apenas uma das duas classes possíveis. Essa função de perda calcula a divergência entre a probabilidade prevista pelo modelo e a probabilidade real do rótulo.
- **Mean Squared Error (MSE)**: comumente usada em problemas de regressão. Ela mede a média dos erros ao quadrado entre as previsões do modelo e os valores reais. Essa função de perda é sensível a desvios grandes entre as previsões e os valores reais, pois o erro é elevado ao quadrado.

- **Mean Absolute Error (MAE):** também é usada em problemas de regressão. Ela mede a média dos erros absolutos entre as previsões do modelo e os valores reais. Essa função de perda é menos sensível a desvios grandes, pois os erros são tratados como valores absolutos.
- **Categorical hinge:** semelhante à "categorical\_crossentropy" e é usada em problemas de classificação multiclasse. Ela é adequada quando as classes são mutuamente exclusivas. Essa função de perda é uma versão adaptada da função de perda "hinge" usada em classificação binária.
- **Logcosh:** uma aproximação suave do erro logarítmico hiperbólico. Ela é usada principalmente em problemas de regressão. Essa função de perda combina as vantagens do erro logarítmico e do erro hiperbólico, sendo menos sensível a *outliers*.

## | Otimizadores

Ao treinar uma CNN, a escolha do otimizador é uma das decisões importantes a serem tomadas. O otimizador é responsável por ajustar os pesos e o viés da rede neural durante o processo de treinamento, com o objetivo de minimizar a função de perda e melhorar o desempenho do modelo. Aqui estão algumas opções comuns de otimizadores para CNNs:

- **Adam:** uma combinação do método de otimização *RMSprop* e o algoritmo de otimização estocástica (SGD) com momentos adaptativos. Ele é amplamente utilizado em CNNs devido à sua eficiência e velocidade de convergência. O algoritmo Adam adapta a taxa de aprendizado de forma adaptativa para cada parâmetro individual, o que permite um ajuste mais rápido e eficiente dos pesos da rede.
- **Stochastic Gradient Descent (SGD):** um dos algoritmos de otimização mais simples e amplamente usados. Ele atualiza os pesos da rede com base no gradiente da função de perda em relação a esses pesos, multiplicado por uma taxa de aprendizado fixa. O SGD é conhecido por sua simplicidade, mas pode levar mais tempo para convergir em comparação com otimizadores mais avançados, como o *Adam*.
- **Root Mean Square Propagation (RMSprop):** uma variação do SGD que ajusta a taxa de aprendizado adaptativamente para cada parâmetro da rede. Ele utiliza uma média móvel exponencial dos gradientes recentes para ajustar a taxa de aprendizado, permitindo uma convergência mais rápida e estável.
- **Adadelta:** uma extensão do RMSprop que melhora a taxa de aprendizado adaptativa, controlando a taxa de aprendizado de forma mais localizada. Ele não requer uma taxa de aprendizado inicial definida e ajusta automaticamente a taxa de aprendizado durante o treinamento. O *Adadelta* é eficaz em lidar com problemas de convergência lenta, especialmente quando a taxa de aprendizado precisa ser ajustada com cuidado.

- **Adagrad**: adapta a taxa de aprendizado para cada parâmetro individual com base na soma dos gradientes passados. Ele atribui uma taxa de aprendizado maior para parâmetros menos frequentes e uma taxa de aprendizado menor para parâmetros mais frequentes. O *Adagrad* é eficiente para problemas em que certos parâmetros requerem ajustes significativos, mas pode ter problemas de convergência em problemas de otimização a longo prazo.
- **Adamax**: uma variante do *Adam* que utiliza a norma infinita em vez da norma L2 para atualizar os pesos da rede. Ele pode ser mais adequado para problemas em que a escala dos gradientes varia consideravelmente entre diferentes dimensões.
- **Nadam**: uma combinação do otimizador *Nesterov Accelerated Gradient* (NAG) e o *Adam*. Ele incorpora o NAG para atualizações dos parâmetros e o algoritmo Adam para ajustar a taxa de aprendizado de forma adaptativa. O *Nadam* é conhecido por sua eficácia em lidar com gradientes esparsos e problemas de convergência.

A escolha do otimizador depende do problema específico, do tamanho do conjunto de dados, da arquitetura da CNN e de outras considerações. É recomendado experimentar diferentes otimizadores e ajustar seus hiperparâmetros para encontrar a combinação mais adequada para obter um melhor desempenho do modelo.

## | Métricas de desempenho

Ao avaliar o desempenho de uma rede neural convolucional (CNN), é necessário definir uma métrica que quantifique a qualidade das previsões do modelo. Aqui estão três métricas comuns usadas para avaliar o desempenho de redes neurais CNN:

- **Accuracy (Acurácia)**: métrica amplamente utilizada para avaliar a performance de classificação de uma CNN. Ela mede a proporção de previsões corretas em relação ao total de previsões. Em outras palavras, a acurácia indica a taxa de acertos do modelo em classificar corretamente as amostras de teste.
- **Mean Squared Error (erro quadrático médio – MSE)**: métrica comumente usada para problemas de regressão, onde o objetivo é prever valores contínuos em vez de classificações discretas. O MSE calcula a média dos quadrados das diferenças entre as previsões da CNN e os valores reais. Quanto menor o valor do MSE, mais próximas as previsões do modelo estão dos valores reais.
- **Mean Absolute Error (erro absoluto médio – MAE)**: também é uma métrica comumente usada para problemas de regressão. Ele calcula a média das diferenças absolutas entre as previsões da CNN e os valores reais. O MAE fornece uma medida da magnitude média do erro entre as previsões e os valores reais, independentemente da direção.

A escolha da métrica de desempenho depende da natureza do problema que está sendo resolvido. Se o problema envolver classificação, a acurácia é geralmente a métrica preferida. Por outro lado, para problemas de regressão, como prever valores contínuos, o MSE ou o MAE são métricas mais adequadas.

## | Épocas e tamanho do lote (Amostras) para treinamento

As épocas e o tamanho do lote (amostras) são dois hiperparâmetros importantes que afetam o treinamento de uma rede neural convolucional (CNN). Aqui está um texto explicando cada um desses conceitos:


- **Épocas:** em um contexto de treinamento de uma CNN, uma época refere-se a uma passagem completa de todo o conjunto de treinamento pelos neurônios da rede. Durante uma época, cada amostra do conjunto de treinamento é apresentada à rede, e os pesos são ajustados com base no erro entre as previsões e os rótulos verdadeiros. O número de épocas define a quantidade de vezes que o conjunto de treinamento será percorrido durante o treinamento da CNN. Treinar por mais épocas pode permitir que o modelo aprenda padrões mais complexos, mas também pode levar a um ajuste excessivo (*overfitting*) se o modelo começar a se adaptar demais aos dados de treinamento.
- **Tamanho do lote (amostras):** também conhecido como número de amostras ou *batch size*, refere-se à quantidade de amostras de treinamento que são processadas em paralelo antes de atualizar os pesos da CNN. Em vez de atualizar os pesos após cada amostra, o treinamento em lotes permite realizar atualizações mais eficientes usando várias amostras ao mesmo tempo. Um tamanho de lote maior pode acelerar o treinamento, pois mais amostras são processadas simultaneamente. No entanto, também requer mais memória para armazenar os gradientes calculados. Um tamanho de lote menor pode levar a uma atualização de pesos mais frequente, o que pode ajudar a evitar mínimos locais, mas também pode tornar o treinamento mais lento.

A escolha adequada do número de épocas e do tamanho do lote depende da complexidade do problema, do tamanho do conjunto de dados, dos recursos computacionais disponíveis e de outras considerações específicas. Geralmente, é recomendado experimentar diferentes configurações e ajustar

estes parâmetros para encontrar o equilíbrio entre eficiência de treinamento e desempenho do modelo.

## | VIDEOAULA (REDE NEURAL CNN)

Nesta videoaula, vamos abordar de forma breve o funcionamento referente ao treinamento de uma rede neural CNN, considerando os parâmetros ajustáveis da arquitetura do modelo.



Com as informações apresentadas até aqui, você estará apto para seguir em frente com as implementações dos modelos de redes neurais CNN, para a resolução de problemas específicos.

Agora, sua vez!

Realize a atividade formativa proposta para esta semana e aprofunde seu conhecimento.

## | Conclusão

Nesta unidade de estudo, exploramos diversos aspectos relacionados à construção e treinamento de CNNs. Vimos a importância de dividir os dados em conjuntos de treinamento e teste, e em seguida abordamos a definição das funções de ativação, otimizadores e funções de perda, destacando suas características e o impacto na performance da CNN.

Também, discutimos sobre o número de neurônios e camadas ideais para uma CNN, considerando a complexidade do problema e o equilíbrio entre capacidade de aprendizado e evitar *overfitting*. Além disso, vimos sobre a escolha das métricas de desempenho, como a acurácia, o erro quadrático médio e o erro absoluto médio, para avaliar a qualidade das previsões do modelo.

Por fim, abordamos os conceitos de épocas e tamanho do lote (amostras) no treinamento de uma CNN, explorando a importância de ajustar adequadamente estes parâmetros para obter um treinamento eficiente e evitar problemas como *overfitting*.

Em resumo, o conteúdo desta unidade de estudo proporcionou uma visão abrangente sobre os principais elementos envolvidos na construção e treinamento de redes neurais convolucionais. Cada aspecto discutido desempenha um papel fundamental na criação de modelos precisos e eficientes. Ao compreender esses conceitos e considerar as melhores práticas, você poderá otimizar suas CNNs e alcançar resultados mais satisfatórios em tarefas de visão computacional e processamento de imagens.

Nos vemos na sequência.

Um forte abraço, até lá!

## | Referências

FACELI, K. *et al.* **Inteligência artificial**: Uma abordagem de aprendizagem de máquina. Rio de Janeiro, RJ: LTC, 2011.

HAYKIN, S. **Redes neurais**: Princípios e prática. 2. ed. Porto Alegre, RS: Bookman, 2007.

