



Redes Neurais

Comparativo de desempenho entre rede neural MLP e rede neural convolucional

Vamos explorar o comparativo entre duas arquiteturas de rede neural amplamente utilizadas: a rede neural **MultiLayer Perceptron** (MLP) e a rede neural convolucional (CNN). Utilizaremos o conjunto de dados MNIST, composto por imagens com dígitos de 0 a 9, para realizar a classificação. O objetivo principal é permitir que você altere parâmetros ajustáveis dos modelos em Python, como função de ativação, função de perda, número de camadas, número de neurônios e tipos de otimizadores etc.

Relembrando conceitos sobre as arquiteturas

Rede neural MLP: é uma rede neural *feedforward*, em que os neurônios são organizados em camadas. Cada neurônio em uma camada está conectado a todos os neurônios da camada seguinte, formando uma estrutura densamente conectada. É uma arquitetura adequada para problemas de classificação simples.

Rede neural convolucional (CNN): é especialmente projetada para processamento de imagens. Ela utiliza camadas de convolução para extrair características importantes das imagens e camadas de *pooling* para reduzir a dimensionalidade. É uma arquitetura adequada para problemas de classificação de imagens.

Pré-processamento dos dados

Antes de iniciar o treinamento dos modelos, é necessário realizar o pré-processamento dos dados. No caso do MNIST, podemos realizar o redimensionamento das imagens para um tamanho-padrão e a normalização dos valores de *pixel* para facilitar o treinamento dos modelos.

Configuração do modelo de Rede Neural MLP

O MLP é um modelo simples que consiste em uma ou mais camadas ocultas densamente conectadas. Os alunos podem modificar o número de camadas ocultas, o número de neurônios em cada camada, a função de ativação e a função de perda. É importante escolher funções de ativação não lineares para permitir que o modelo aprenda relações complexas nos dados.

- Definição da quantidade de neurônios das camadas.
- Definição das funções de ativação.
- Definição da função de perda.
- Definição do otimizador.
- Definição da métrica de desempenho.
- Definição do percentual do conjunto de dados de teste.
- Definição do número de épocas e número de amostras.

Configuração do modelo de Rede Neural Convolutacional (CNN)


A CNN é particularmente eficaz para processar dados de imagens. Os alunos podem experimentar diferentes configurações de camadas convolucionais, camadas de *pooling*, número de filtros, tamanho dos filtros e funções de ativação. Além disso, é possível adicionar camadas totalmente conectadas no final da CNN para realizar a classificação.

- Definição do percentual de dados para treinamento.
- Definição das funções de ativação.
- Definição da estrutura da rede.
 - Definição do tamanho das matrizes de convolução.
 - Definição do número de neurônios das camadas.
- Definição do otimizador.
- Definição da função de perda.
- Definição da métrica de desempenho.
- Definição do número de épocas e número de amostras.

| Treinamento e avaliação dos modelos

Após a configuração dos modelos, eles devem ser treinados usando os dados de treinamento. Você pode escolher diferentes otimizadores, como o gradiente descendente estocástico (SGD) ou o Adam, e experimentar diferentes tamanhos de lote (*batch size*) e número de épocas. Durante o treinamento, os modelos serão ajustados aos dados para minimizar a função de perda escolhida. Ao final do treinamento, é importante avaliar o desempenho dos modelos usando os dados de teste e analisar as métricas de desempenho e perda.

Para complementar nossos estudos e te ajudar com a atividade somativa dessa semana, vamos ver a videoaula.



Nesta unidade, vimos a importância do ajuste correto dos parâmetros nas arquiteturas das redes neurais MLP e CNN. Esses parâmetros possuem papel fundamental no desempenho e na capacidade de generalização das redes.

| Conclusão

Para a rede MLP, é essencial definir adequadamente o número de camadas ocultas, o número de neurônios em cada camada, a taxa de aprendizado e o algoritmo de otimização. A escolha inadequada desses parâmetros pode levar a problemas como *overfitting* (sobreajuste), comprometendo a capacidade da rede de aprender e generalizar a partir dos dados.

Da mesma forma, a CNN também requer um ajuste cuidadoso de parâmetros. A seleção apropriada do tamanho e número de filtros, o tamanho dos passos da convolução, a função de ativação e a configuração das camadas de *pooling* são fatores cruciais para o desempenho da CNN. Um ajuste inadequado desses parâmetros pode resultar em uma perda de informações relevantes nas imagens ou em uma extração ineficiente de características.

Em ambos os casos, o ajuste dos parâmetros envolve experimentação e otimização. É necessário realizar uma análise sistemática dos parâmetros, ajustando-os de acordo com as características do problema e do conjunto de dados específico. O uso de técnicas como validação cruzada e otimização Bayesiana pode ajudar a encontrar a combinação ideal de parâmetros que maximize o desempenho da rede.

Portanto, o ajuste correto dos parâmetros é essencial para se obter resultados satisfatórios e garantir a capacidade das redes neurais MLP e CNN de aprender e generalizar adequadamente os dados de entrada. Uma configuração otimizada dos parâmetros permite que as redes aproveitem todo o potencial dos dados e alcancem o desempenho máximo na tarefa de classificação, melhorando assim a aplicabilidade em diversos cenários.

| Referências

HAYKIN, S. **Redes neurais: Princípios e prática**. 2. ed. Porto Alegre, RS: Bookman, 2007.

SILVA, F. M. *et al.* **Inteligência artificial**. Porto Alegre, RS: SAGAH, 2019.

FACELI, K. *et al.* **Inteligência artificial: Uma abordagem de aprendizagem de máquina**. Rio de Janeiro, RJ: LTC, 2011.

