



Redes Neurais

UNIDADE 05

Rede Neural Competitiva (RNC)

| Definição

As Redes Neurais Competitivas (RNCs), também conhecidas como mapa auto-organizável ou rede de Kohonen, são um tipo especial de arquitetura de redes neurais artificiais que se baseiam em princípios de competição entre neurônios. Elas são usadas para tarefas de agrupamento, classificação e reconhecimento de padrões. Nesta unidade, vamos explorar os conceitos e princípios básicos da RNC, seu funcionamento e suas aplicações práticas.

Princípios básicos

- **Competição:** em uma rede neural competitiva, os neurônios competem entre si para se tornarem ativados em resposta a estímulos externos. Cada neurônio na camada competitiva tenta se tornar o neurônio mais ativado em relação a um determinado estímulo de entrada.
- **Aprendizado não supervisionado:** diferentemente de outros tipos de redes neurais, as redes neurais competitivas não requerem um conjunto de treinamento rotulado. Elas são capazes de aprender de forma não supervisionada, ou seja, a partir dos próprios padrões presentes nos dados de entrada.
- **Auto-organização:** a principal capacidade das redes neurais competitivas é a auto-organização. Elas são capazes de identificar e mapear as relações e estruturas presentes nos dados de entrada, criando uma representação compacta e ordenada dessas informações.
- **Vizinhança topológica:** em uma rede neural competitiva, os neurônios estão organizados em uma topologia espacial, como uma grade bidimensional. Neurônios próximos na grade têm maior probabilidade de serem ativados juntos, o que permite a formação de agrupamentos e a identificação de padrões adjacentes.
- **Ajuste dos pesos sinápticos:** durante o treinamento da rede, os pesos sinápticos são ajustados para que neurônios vizinhos na grade respondam de maneira semelhante a padrões de entrada semelhantes. Isso ocorre por meio de uma competição cooperativa, em que neurônios ativados influenciam seus vizinhos e vice-versa.

- **Mapeamento de entradas para neurônios:** cada neurônio na camada competitiva possui um vetor de pesos sinápticos que define sua sensibilidade a diferentes características do padrão de entrada. Durante a ativação, o neurônio com pesos mais próximos ao padrão de entrada é escolhido.
- **Generalização e reconhecimento de padrões:** uma vez treinada, uma RNC pode ser usada para reconhecer padrões semelhantes aos padrões de entrada vistos durante o treinamento.

| Arquitetura e Componentes de uma Rede Neural Competitiva

- **Neurônios de entrada:** recebem os dados brutos ou pré-processados que são fornecidos à rede. Cada neurônio de entrada representa uma característica ou atributo dos dados de entrada. Por exemplo, em uma RNC aplicada a reconhecimento de padrões em imagens, cada neurônio de entrada pode representar a intensidade de um pixel específico.
- **Neurônios competitivos:** são a principal característica da RNC. Eles são responsáveis por competir entre si para ativar quando a entrada é apresentada à rede. Cada neurônio competitivo possui um vetor de pesos associado, que define sua posição no espaço de entrada. Durante o processo de treinamento, os neurônios competitivos ajustam seus pesos com base nas entradas recebidas, de forma a se tornarem especializados em regiões específicas do espaço de entrada.
- **Neurônios de saída:** representam a organização espacial da RNC. Eles formam uma grade bidimensional ou multidimensional, conhecida como mapa de saída, em que cada neurônio de saída está associado a uma posição específica nesse mapa. Os neurônios de saída são ativados com base na similaridade entre seus pesos e as entradas apresentadas à rede.
- **Conexões entre neurônios:** permitem a comunicação e o aprendizado entre eles. Em uma RNC, os neurônios de entrada estão conectados a todos os neurônios competitivos, e os neurônios competitivos estão conectados aos neurônios de saída. Durante o treinamento, as conexões são ajustadas de acordo com as regras de aprendizado da RNC, como a atualização dos pesos dos neurônios competitivos com base na distância entre eles e a entrada apresentada.

| Algoritmo de Treinamento da Rede Neural Competitiva

O treinamento de uma RNC envolve o ajuste dos pesos sinápticos dos neurônios para criar uma organização eficiente dos dados de entrada. O algoritmo de treinamento mais usado para RNC é o algoritmo de Kohonen, também conhecido como mapas auto-organizáveis (Self-Organizing Maps – SOMs).

Processo de aprendizado

- 1) **Inicialização dos pesos:** os pesos sinápticos são inicializados com valores aleatórios pequenos, geralmente entre 0 e 1.
- 2) **Apresentação dos dados de entrada:** os dados de entrada são apresentados à rede, um por vez.
- 3) **Competição entre neurônios:** para cada dado de entrada, os neurônios da camada de entrada competem entre si para determinar qual neurônio será ativado com base na similaridade entre o dado de entrada e os pesos sinápticos de cada neurônio.
- 4) **Atualização dos pesos sinápticos:** o neurônio vencedor, ou seja, o neurônio mais similar ao dado de entrada, e seus neurônios vizinhos na rede são atualizados de acordo com o algoritmo de treinamento. Isso envolve o ajuste dos pesos sinápticos desses neurônios para ficarem mais próximos do dado de entrada.
- 5) **Atualização dos pesos dos neurônios vizinhos:** durante a atualização dos pesos sinápticos, os neurônios vizinhos ao neurônio vencedor também são atualizados, mas com uma intensidade decrescente à medida que a distância em relação ao neurônio vencedor aumenta. Essa propriedade de atualização gradual é responsável pela organização topológica dos neurônios na rede.
- 6) **Repetição do processo:** os passos 2 a 5 são repetidos para cada dado de entrada, ou seja, para cada época de treinamento, a fim de ajustar os pesos sinápticos e otimizar a organização da rede.

| Implementação de uma Rede Neural Competitiva em Python

Antes de treinar uma RNC em Python, é importante realizar a preparação dos dados. Esta etapa envolve o pré-processamento dos dados e a aplicação de técnicas de normalização e escalonamento. O objetivo é garantir que os dados estejam em um formato adequado para o treinamento da rede.

Pré-processamento dos Dados

- Remoção de ruídos e *outliers*: é recomendado realizar uma análise exploratória dos dados para identificar e remover ruídos ou outliers que possam afetar o desempenho da rede.
- Tratamento de valores ausentes: caso existam valores ausentes nos dados, é necessário decidir como lidar com eles. Pode-se optar por removê-los, preenchê-los com valores médios ou utilizar outras técnicas de imputação de dados.


Normalização e Escalonamento

- Normalização: a normalização é uma técnica que visa a colocar as variáveis em uma escala comum, geralmente entre 0 e 1, para evitar que uma variável com uma faixa de valores maior influencie de forma desproporcional o treinamento da rede. Alguns métodos comuns de normalização incluem a normalização min-max e a normalização z-score.
- Escalonamento: o escalonamento é utilizado quando as variáveis possuem diferentes unidades de medida e escalas. Ele ajusta as variáveis para uma escala específica, permitindo que sejam comparadas de forma adequada. Uma técnica comum de escalonamento é a padronização, que transforma os dados para terem média zero e desvio-padrão igual a um.

Definição da Arquitetura da Rede

A arquitetura da RNC é composta por três principais componentes: a camada de entrada, a camada competitiva e a camada de saída. A Figura 1 apresenta esta arquitetura.

Fig. 1 – Arquitetura básica de uma RNC



Fonte: Autor, 2023.

- Camada de entrada: é a primeira camada da RNC, responsável por receber os dados de entrada. Cada neurônio nessa camada representa uma dimensão dos dados de entrada. Por exemplo, se os dados de entrada têm 10 dimensões, a camada de entrada terá 10 neurônios.
- Camada competitiva: é a camada central da RNC, composta pelos neurônios competitivos. Cada neurônio na camada competitiva é responsável por representar um grupo ou um cluster de dados. Durante o treinamento, os neurônios competem entre si para determinar qual neurônio será ativado em resposta a um determinado estímulo.
- Camada de saída: é a última camada da RNC e é composta pelos neurônios de saída. Cada neurônio de saída representa uma classe ou categoria. Eles são ativados com base na ativação dos neurônios competitivos correspondentes na camada competitiva.

Implementação dos Neurônios e Conexões

A implementação da RNC envolve a criação dos neurônios e a definição das conexões entre os neurônios.

- **Neurônios competitivos:** cada neurônio competitivo possui uma matriz de pesos sinápticos, que representa a codificação do grupo de dados que ele representa. Durante o treinamento, os pesos sinápticos são ajustados para se aproximarem dos dados de entrada. É comum utilizar a distância euclidiana ou similaridade do cosseno para calcular a similaridade entre os neurônios competitivos e os dados de entrada.
- **Conexões:** as conexões entre os neurônios são estabelecidas com base na topologia desejada. Pode-se usar uma grade bidimensional, em que os neurônios estão organizados em uma estrutura de matriz, ou uma topologia personalizada, dependendo da aplicação específica da RNC.

Treinamento e Avaliação da Rede

Após a construção da RNC, o próximo passo é realizar o treinamento da rede e avaliar seu desempenho. Nesta seção, vamos abordar a implementação do algoritmo de treinamento e as técnicas para avaliar a eficácia da rede.

Implementação do algoritmo de treinamento: o algoritmo de treinamento de uma RNC, como o algoritmo de Kohonen, é responsável por ajustar os pesos sinápticos dos neurônios competitivos com base na competição entre eles e nos dados de entrada. A implementação do algoritmo de treinamento pode variar dependendo da biblioteca ou framework escolhido. Geralmente, envolve a iteração sobre os dados de treinamento, apresentando-os à rede e atualizando os pesos sinápticos dos neurônios competitivos de acordo com a similaridade entre os dados de entrada e os neurônios.

Avaliação do desempenho da RNC: pode ser feita de diferentes maneiras, dependendo da aplicação específica da rede. Aqui estão duas técnicas comuns:

- **Análise dos grupos formados:** os grupos formados pelos neurônios podem ser analisados para verificar a similaridade dos dados dentro de cada grupo e a dissimilaridade entre os grupos.
- **Teste com novos dados:** testar a capacidade da RNC de generalizar para novos dados, apresentados à rede para que a resposta dos neurônios seja observada.

Essas são as principais características de implementação de um modelo de RNC. Com tais informações, e observando e analisando o código em Python disponibilizado para o exercício desta unidade, você será capaz de generalizar o modelo para outras aplicações e solução de outros tipos de problema.

Além disso, no código fornecido há também a aplicação de regressão linear no conjunto de dados, para que o resultado seja utilizado como suporte no momento da análise dos resultados, bem como permitir que se faça previsão de novos valores para a variável Y, de acordo com valores informados para a variável X.

Portanto, realize a atividade formativa proposta e verifique toda a estrutura do modelo e quais são os parâmetros que podem ser ajustados, tanto para a rede neural quanto para a regressão linear, para que o modelo apresente, após o treinamento, o melhor desempenho possível.

Bons estudos!

| Conclusão

Esta unidade teve como objetivo fornecer a você uma compreensão sólida dos fundamentos das redes neurais competitivas e capacitar a aplicação desses conhecimentos em diferentes domínios.

Com o conhecimento do conteúdo apresentado, você estará apto a utilizar redes neurais competitivas em projetos práticos com uma base sólida para explorar pesquisas mais avançadas nessa área.

| Referências

HAYKIN, S. **Redes neurais**: Princípios e prática. 2. ed. Porto Alegre, RS: Bookman, 2007.

FACELI, K. et al. **Inteligência artificial**: Uma abordagem de aprendizagem de máquina. Rio de Janeiro, RJ: LTC, 2011.

