



Redes Neurais

UNIDADE 08

REDE NEURAL COMPETITIVA E REDE NEURAL TEMPORAL – CONTINUAÇÃO

| Treinamento com múltiplas variáveis

Nesta unidade, seguiremos utilizando os mesmos modelos de Rede Neural Competitiva (RNC) e Rede Neural Temporal (RNT), porém, abordando um treinamento triplo para a RNC e um novo formato de treinamento e aplicação da RNT.

RNC: no treinamento duplo, criamos uma estrutura para agrupamento de elementos de uma base de dados, relacionando cilindradas (em litros) e eficiência (em km/L) de veículos automotores, além de cilindradas e emissão de CO2. Entretanto, nesta unidade, veremos que é possível utilizar a mesma estrutura do modelo já desenvolvido para obter informações de um novo par de variáveis (eficiência e emissão de CO2), e utilizar configurações de parâmetros dentro de um mesmo código para realizar o treinamento de três modelos ao mesmo tempo, apresentando resultados e métricas de desempenho conjuntas, durante a fase de teste.

RNT: da mesma forma, para a RNT, utilizaremos o modelo já criado na unidade de estudo 7, alterando, entretanto, o formato de treinamento e testes. No modelo da unidade de estudo 7, utilizamos a estrutura, alterando parâmetros ajustáveis, para realizar o treinamento e previsões de teste sobre uma base de dados relacionada à cotação do dólar (em reais), dentro de um determinado período. No modelo desta unidade, iremos treiná-lo e salvá-lo em nosso computador, para que assim possamos realizar previsões futuras sem a necessidade de um novo treinamento.

| Implementação dos modelos

RNC: as linhas a seguir (em linguagem Python) mostram como podemos selecionar as três colunas de interesse da base de dados e montar três ou mais combinações de para realizar testes e análises sobre os dados. Na sequência, ao carregar o arquivo da atividade avaliativa na IDE Spyder, você verá o código completo, e as alterações que foram realizadas para permitir um triplo treinamento dentro do mesmo arquivo, gerando informações pertinentes à mesma base de dados.

Concatenar os dados combinados em um único array

```
# Cilindrada x Eficiência
```

```
combinacao1 = np.column_stack((cilindrada, eficiencia))
```

```
inshape1 = combinacao1.shape[1]
```

```
# Cilindrada x CO2
```

```
combinacao2 = np.column_stack((cilindrada, co2))
```

```
inshape2 = combinacao2.shape[1]
```

```
# Eficiencia x CO2
```

```
combinacao3 = np.column_stack((eficiencia, co2))
```

```
inshape3 = combinacao2.shape[1]
```


RNT: para o modelo da RNT, foram realizadas alterações na estrutura do código, alterando o formato de treinamento e teste. Agora, o modelo é treinado e salvo no computador. Para a realização de testes e aplicações futuras do modelo, precisamos carregá-lo num novo arquivo em Python (disponibilizado para a atividade avaliativa desta unidade). A maior vantagem é que, uma vez treinado, o modelo pode ser aplicado futuramente sem a necessidade de se repetir o treinamento, agilizando a utilização. Entretanto, para a etapa de treinamento, os parâmetros listados a seguir devem continuar sendo configurados de forma correta.

- Janela de previsão.
- Função de perda.
- Otimizador.

- Número de neurônios da camada LSTM.
- Número de neurônios da camada densa.
- Épocas de treinamento.
- Tamanho do lote de dados utilizado em cada época de treinamento.

| Videoaula - Redes neurais competitivas e redes neurais temporais - Parte 2

Vamos seguir explorando nosso tema e preparando para a atividade avaliativa.



Nesta unidade, encerramos a disciplina com a aplicação dos conceitos e arquiteturas das redes neurais RNC e RNT.

| Conclusão

Vimos a versatilidade de se treinar dois ou mais modelos que compartilham a mesma base de dados, utilizando apenas uma estrutura de código.

Abordamos também a eficiência de salvar um modelo treinado para aplicações futuras, sem a necessidade de repetir o treinamento.

Com tais conhecimentos, espero que você consiga desenvolver modelos ainda mais complexos, treiná-los de maneira adequada e resolver problemas diversos no ambiente industrial e tecnológico.

| Referências

FACELI, K. et al. **Inteligência artificial**: Uma abordagem de aprendizagem de máquina. Rio de Janeiro, RJ: LTC, 2011.

HAYKIN, S. **Redes neurais**: Princípios e prática. 2. ed. Porto Alegre, RS: Bookman, 2007.

SILVA, I. N.; SPATTI, D. H.; FLAUZINO, R. A. **Redes neurais artificiais**: Para engenharia e ciências aplicadas. São Paulo, SP: Artliber, 2010. p. 399.



© PUCPR - Todos os direitos reservados.