



Técnica em Graph Mining

UNIDADE 01

Introdução à Teoria dos Grafos

| Introdução à teoria dos Grafos

Seja bem-vindo à nossa primeira semana de estudos da disciplina Graph Mining!

Você sabia que os conceitos de grafos estão presentes em muitas atividades do seu cotidiano? Só para citar alguns exemplos, o seu círculo de amizades, o sistema de transporte da sua cidade, a rede de computadores da sua universidade e a própria internet são cenários que podemos representar computacionalmente utilizando os conceitos de grafos. Isso porque os grafos constituem uma importante ferramenta para representar e compreender as relações entre diferentes elementos que podem ser pessoas, cidades, dispositivos, entre outros. Nesta semana vamos estudar os conceitos introdutórios de Teoria dos Grafos que formarão a base para a compreensão dos demais temas da disciplina de Graph Mining.

Nesta Unidade, vamos trabalhar os conceitos introdutórios, definições básicas e a terminologia utilizada em Teoria dos Grafos que serão essenciais ao longo de toda a disciplina. Também vamos conhecer as origens da Teoria dos Grafos com Leonhard Euler, que há três séculos iniciou o estudo deste importante tema da matemática e, atualmente, também da computação. Vamos discutir exemplos de aplicações cotidianas que são modeladas a partir da representação de grafos e ter uma visão geral do que é a mineração de grafos e suas aplicações.

Ao final desta Unidade de Aprendizagem, você deve apresentar os seguintes aprendizados:

- *Identificar os conceitos básicos de grafos*
- *Reconhecer a representação de grafos e seus diferentes tipos*
- *Relacionar a representação de grafos com problemas reais do cotidiano.*

Conceitos básicos e terminologia


Antes de sermos capazes de utilizar grafos e técnicas de mineração de dados para a análise e descoberta de conhecimento em aplicações e problemas complexos envolvendo muitas relações como redes sociais ou dados de tráfego aéreo, é preciso entender os conceitos básicos e a terminologia adotada na área de teoria dos grafos. A teoria dos grafos é um ramo da matemática que estuda desde meados de 1700 as relações entre os objetos de um determinado conjunto. Para isso, são empregadas estruturas chamadas de *grafos*.

De acordo com Goldbarg e Goldbarg (2013), um grafo **G** é uma estrutura matemática formada por dois conjuntos. O primeiro conjunto, que chamaremos de **V**, é o conjunto de vértices (ou nós) e representam os objetos de um determinado problema. O segundo conjunto, que chamaremos de **E**, é o conjunto de arestas (do inglês, *edges*) e representam as relações entre os pares de objetos. Cada aresta conecta no máximo dois vértices. Assim, se dois vértices v e w do conjunto **V** estão relacionados, diremos que existe entre eles uma aresta representada pelo par (v,w) e que pertence ao conjunto **E**. Em alguns casos, podemos ter mais de uma aresta conectando o mesmo par de vértices. Nestes casos, elas são chamadas de *arestas paralelas*. Quando uma aresta conecta um vértice a ele mesmo, ela é chamada de *laço*.

De acordo com as definições apresentadas acima, podemos representar matematicamente o grafo de um dado problema como $G = (V,E)$, em que **V** é conjunto de vértices e **E** é o conjunto de arestas.

Os grafos possuem uma representação gráfica intuitiva por meio de diagramas que facilitam a sua interpretação e análise. Neste diagrama, os vértices são comumente representados por círculos ou quadrados, enquanto as arestas são representadas por linhas ou setas (curvas ou segmentos de reta) entre vértices. No interior dos vértices, é comum que seja apresentado um texto para a sua identificação única. A Figura 1 ilustra os principais elementos que compõem o diagrama de um grafo.

Elementos que compõem um grafo



Fonte: Goldbarg e Goldbarg (2012).


Para melhor entendimento de quem são os vértices e arestas de um grafo, considere o aplicativo de mensagens instantâneas do seu celular. Os vértices do grafo podem ser os contatos cadastrados no aplicativo, enquanto as arestas podem ser definidas de acordo com as relações entre estes contatos. Por exemplo, podemos estabelecer uma aresta (conexão) entre os contatos A e B, se eles possuem algum grau de parentesco ou se eles se conhecem pessoalmente ou se trocaram mensagens de texto ou se já realizaram uma chamada de vídeo e assim por diante. Neste simples exemplo, é possível entender que o grafo será totalmente diferente de acordo com as relações que queremos observar entre os objetos.

Outro aspecto importante deste exemplo é em relação a direção das arestas, que podem ser dirigidas ou não dirigidas. Como vimos na Figura 1, as arestas podem ser representadas por segmentos de retas ou por setas. Quando utilizamos setas, temos um *grafo orientado*, *grafo dirigido* ou simplesmente *digrafo*. No exemplo anterior, uma aresta dirigida com origem no vértice V1 e destino no vértice V2, poderia ser utilizada para indicar quem enviou uma mensagem de texto (vértice V1) e quem recebeu a mensagem (vértice V2). Por outro lado, quando utilizados segmentos de reta, temos um *grafo não orientado* ou *grafo não dirigido*. Neste caso, assume-se que a direção da aresta entre os vértices é equivalente em ambas as direções. Por exemplo, no caso da relação de parentesco familiar, o vértice A será parente do vértice B e vice-versa. Ainda, temos os *grafos mistos*, que possuem tanto arestas dirigidas quanto não dirigidas em um mesmo grafo.


Um grafo não direcionado que não contém laços ou arestas paralelas é chamado de *grafo simples*. Quando um grafo simples possui uma aresta entre todos os possíveis pares de vértices, ele é também denominado de grafo completo. Um grafo não dirigido que possui no mínimo duas arestas paralelas e não contém laços é denominado *multigrafo*. Um grafo que contém no mínimo um laço, podendo ter arestas paralelas ou

não, é denominado *pseudografo*. Os grafos também podem ser conexos ou desconexos. Um grafo é dito conexo se existir pelo menos um caminho entre cada par de vértices do grafo. Caso contrário, o grafo será chamado de desconexo. Quando um grafo conexo não possui nenhum ciclo entre os seus vértices, é denominado de *árvore*. Um ciclo é um caminho dentro de um grafo que visita ao menos três vértices, sendo possível que o último vértice visitado seja igual ao primeiro vértice do caminho. Estes conceitos são ilustrados nos exemplos apresentados na Figura 2 com oito diferentes grafos.


Figura 2. Exemplos dos diferentes tipos de grafos.




a) Grafo dirigido ou digrafo




b) Grafo não dirigido




c) Grafo misto




d) Multigrafo




e) Pseudografo



f) Grafo completo



g) Grafo desconexo



h) Árvore

A Tabela 1 apresenta um resumo das principais características de diferentes tipos de grafos de acordo com o tipo das arestas. É importante destacar que os tipos e categorias estudados na Teoria dos Grafos não se limitam aos listados nesta tabela ou ilustrados na Figura 2, já que diferentes critérios podem ser utilizados para categorizar os grafos.

Tabela 1. Diferentes tipos de grafos e suas principais características.

Tipo do grafo	Arestas	Permite laços?	Permite arestas paralelas?
Grafo simples	Não dirigidas	Não	Não
Grafo completo	Não dirigidas	Não	Não
Digrafo	Dirigidas	Não	Não
Grafo não dirigido	Não dirigidas	Não	Não
Grafo misto	Dirigidas e não dirigidas	Não	Não
Multigrafo	Não dirigidas	Não	Sim
Multigrafo dirigido	Dirigidas	Não	Sim
Pseudografo	Não dirigidas	Sim	Sim



SAIBA MAIS

Você já conhece os elementos que compõem um grafo, como vértices e arestas e como representá-los matematicamente e visualmente. Também já percebeu que os grafos são categorizados em diferentes tipos de acordo com as características das suas conexões. Em um primeiro momento pode ser difícil entender tantos conceitos e associar novos termos. Por isso, o vídeo abaixo pode esclarecer suas dúvidas e ajudar a fixar este novo conhecimento!



Entendendo os conceitos principais e os diferentes tipos de g
PUCPR Online



0:04 / 6:46



Mais vídeos



Ordem e Tamanho

Dado um grafo $G=(V,E)$, denomina-se *ordem* a cardinalidade de seu conjunto de vértices, também representado por $|V|$. Em outras palavras, é a quantidade de vértices do grafo. Já o *tamanho* de um grafo é dado pela cardinalidade de seu conjunto de arestas ($|E|$) ou a quantidade de arestas. Por exemplo, o dígrafo G1 da Figura 2 é de ordem 4 e tamanho 5. O grafo G5, que apresenta um laço e representa um pseudografo, é de tamanho 3 e ordem 4, enquanto o grafo G8, que é uma árvore, é de ordem 7 e tamanho 6.

Grafos e redes complexas



Ao longo desta disciplina e na leitura de outros materiais, você irá se deparar com os termos: grafos e redes complexas. Embora em alguns casos estes termos sejam utilizados como sinônimos, existem algumas diferenças nas suas definições. Como vimos anteriormente, um grafo é uma representação matemática utilizada para representar as relações entre vértices e arestas. Por outro lado, redes complexas são um tipo de grafo que apresentam propriedades particulares que não são encontradas em grafos mais simples. Assim, uma rede complexa é um grafo, mas nem todo grafo é uma rede complexa. As propriedades que caracterizam um grafo como uma rede complexa é tema de estudos de muitos pesquisadores, mas algumas das propriedades são conhecidas. Por exemplo, de acordo com Gabardo (2015), redes complexas possuem vértices fortemente conectados que formam grupos de vértices chamados de comunidades, além da presença de vértices em que os seus graus seguem uma determinada distribuição de probabilidades (lei de potência). Para que isso fique mais claro, vamos discutir a seguir o que é o grau de um vértice e distribuição de graus de um grafo.

Grau de um vértice

O grau de um vértice (do inglês, *degree*) ou conectividade, representa o número de conexões que um vértice possui (Simões-Pereira, 2013). Em outras palavras, a quantos outros vértices ele está conectado. Os graus dos vértices e a distribuição dos graus de um grafo, como será discutido a seguir, constituem uma das mais importantes métricas utilizadas na análise de redes complexas e pelas técnicas de *graph mining*. Considere o grafo não dirigido ilustrado na parte esquerda da Figura 3, composto pelos vértices A, B, C, D, E. O vértice A se conecta aos vértices B e D,

possuindo grau 2 ($K=2$). O vértice B se conecta aos vértices A, D, E possuindo grau 3 ($K=3$). O vértice C possui grau 0 ($K=0$), já que não possui conexões. O vértice D é de grau 3 ($K=3$), se conectando aos vértices A, B, E. Por fim, o vértice E possui grau 2 ($K=2$), já que se conecta aos vértices B e D. A parte direita da Figura 3 apresenta a distribuição de graus dos vértices deste exemplo. Este conceito será discutido em breve na próxima seção.

Figura 3. Grafo com cinco vértices e seis arestas e a sua distribuição de graus dos vértices.




Fonte: Autor

No caso de grafos dirigidos, além do grau, também se pode calcular o grau de entrada (*indegree*) e o grau de saída (*outdegree*) dos vértices. O grau de entrada diz respeito ao número de conexões que o vértice recebe, enquanto o grau de saída representa o número de conexões que um vértice faz ou em outras palavras, quantas arestas tem origem neste vértice. Na Figura 4, são ilustrados cinco vértices com diferentes graus. O vértice A possui somente arestas dirigidas e apresenta grau de entrada (*indegree*) igual a 3, já que 3 arestas incidem neste vértice e grau de saída (*outdegree*) igual a zero já que nenhuma aresta tem origem neste vértice. Por fim, o grau do vértice A é igual a 3, sendo contabilizada

todas as arestas do vértice. Por sua vez, o vértice B possui somente duas arestas de saída e, portanto, tem grau e grau de saída iguais a 2. O vértice C possui tanto arestas dirigidas quanto não dirigidas, sendo que duas arestas dirigidas incidem o vértice (grau de entrada igual a 2), uma aresta dirigida sai do vértice (grau de saída igual a 1), além de possuir uma aresta não dirigida que contribui para que o grau do vértice C seja igual a 4. Por fim, o vértice D de grau 3 possui somente arestas não dirigidas e, por isso, não possui grau de entrada e de saída.

Figura 4. Cinco vértices com diferentes graus de entrada e saída.



Fonte: Autor

Distribuição de graus




Ao realizar medições de diversas naturezas, é comum analisar a distribuição dos dados para sua melhor compreensão. Por exemplo, podemos calcular a distribuição da altura de homens adultos de um determinado país e fazer comparações com os dados observados em diferentes grupos, como mulheres do mesmo país ou homens de outros países. Podemos calcular a distribuição da velocidade dos carros em uma determinada rodovia ou a nota dos estudantes na disciplina de *graph mining*. Com grafos, não é diferente. A partir do cálculo do grau de cada vértice, é possível obter a distribuição de graus dos vértices para analisar a topologia do grafo. Em outras palavras, a distribuição de graus de um grafo representa a quantidade de vértices que possuem um determinado grau.

A distribuição de graus é comumente representada por meio de histogramas. Esse tipo de gráfico consiste em um gráfico de barras, em que a base de cada uma das barras representa uma classe (no nosso caso, o grau dos vértices) e a altura representa a quantidade de vezes que o valor ocorre para aquela classe. Para o grafo da Figura 3, representamos o seu respectivo histograma com a distribuição dos graus dos vértices na parte direita da figura com os valores 1, 0, 2, 2, referentes ao número de vértices de cada grau. Ou seja, para o grau 0 temos o vértice C, para o grau 1 não temos nenhum vértice, para o grau 2 temos os vértices A e E, para o grau 3 temos os vértices B e D.

Para muitos problemas que envolvem fenômenos aleatórios, como os exemplificados no início desta seção com medições da altura das pessoas, velocidades dos automóveis em uma rodovia ou as notas dos estudantes, a distribuição dos valores segue uma *distribuição Gaussiana*, também chamada de distribuição normal. Neste tipo de distribuição, o gráfico possui um formato de sino em que os valores são distribuídos de maneira simétrica em torno de uma média. Entretanto, na maioria das redes reais e em redes complexas, as conexões entre os vértices não ocorrem de maneira aleatória e, por isso, a distribuição dos graus é bem diferente de uma distribuição Gaussiana. Em redes complexas, a distribuição de graus segue uma *lei de potência* em que a distribuição dos valores possui um formato de cauda longa onde os valores decaem de maneira exponencial chegando a zero para grandes valores (GABARDO, 2015). De maneira simplificada, podemos dizer que em uma distribuição de lei de potência, a observação de pequenas ocorrências é extremamente comum, enquanto a observação de grandes ocorrências é rara. No cenário de redes complexas, podemos interpretar que a probabilidade de vértices com poucas conexões é muito maior que a probabilidade de vértices com muitas conexões. Para exemplificar este comportamento, vamos considerar uma rede complexa representando uma rede social (por exemplo, Twitter) onde os vértices são os usuários da rede e uma aresta é estabelecida entre dois usuários sempre que um deles passa a acompanhar as publicações do outro. Nesta rede com centenas de milhões de usuários, a grande maioria é composta por usuários comuns que possuem um número pequeno de seguidores, enquanto uma pequena parcela composta por celebridades possui milhões de seguidores e absolutamente nenhum usuário possui todos os membros da rede como seguidores.

A Figura 5 ilustra dois diferentes grafos com 300 vértices e a sua respectiva distribuição de graus dos vértices. No exemplo da esquerda, podemos observar uma distribuição de graus seguindo uma distribuição Gaussiana, comum em redes sintéticas geradas de maneira aleatória. No exemplo do lado direito, temos uma distribuição que segue a lei de potência, comum em redes complexas que representam problemas reais, como redes sociais, internet, redes de colaboração entre pesquisadores, conexões neurais do cérebro, entre outros exemplos.

Figura 5. Dois exemplos de grafos com 300 vértices cada um e suas respectivas distribuições de graus. A distribuição de graus do grafo da esquerda segue uma distribuição Gaussiana, enquanto a da direita segue a lei de potência.




Fonte: Autor

Pesos das arestas

Além de direção, as arestas de um grafo podem possuir um peso para representar o custo do caminho entre os vértices ou a importância da conexão. Neste caso, o grafo é designado como *grafo valorado* ou *ponderado* e passa a ser definido como $G=(V,E,W)$, em que V é um conjunto de vértices, E é um conjunto de arestas e W é o conjunto de pesos das arestas. Um exemplo bastante intuitivo de grafo valorado é a representação de um sistema de transporte, em que os pesos das arestas correspondem às distâncias entre diferentes cidades, conforme ilustrado na Figura 6 com a distância em quilômetros entre algumas cidades vizinhas da capital do Paraná, Curitiba.

Figura 6. Exemplo de grafo valorado. Cada vértice corresponde a uma cidade e os valores das arestas correspondem à distância em quilômetros entre as cidades.



Fonte: Autor

Ao longo da disciplina, iremos abordar diferentes métricas que podem ser extraídas dos grafos para descrevê-los ou para serem utilizados pelos algoritmos de mineração de dados. Em ambos os casos, os pesos das arestas influenciam diretamente em muitas destas métricas. Caso as arestas não apresentem pesos, como nos exemplos discutidos até aqui, assume-se o mesmo peso, normalmente 1, para todas as arestas.

Grafos estáticos e grafos dinâmicos

Até aqui, você já entendeu que grafos constituem uma ferramenta valiosa para analisar problemas envolvendo muitos objetos e suas relações. Entretanto, não é difícil pensar em problemas em que surgem novos objetos ou que antigas conexões são desfeitas ao longo do tempo. Por exemplo, é provavelmente que as atuais conexões da sua rede social sejam significativamente diferentes de 2 anos atrás, que por sua vez são diferentes da rede de 5 anos atrás, devido a novas amizades ou amigos que abandonaram a rede. Por isso, uma importante característica que deve ser levada em consideração durante a construção e análise da rede é o intervalo de tempo em que os eventos ocorrem.


Por facilidade, o mais usual é representar um determinado intervalo de tempo utilizando um grafo estático que agrupa todos os eventos ocorridos no período. Entretanto, para representar o dinamismo do problema em tempo real, também pode-se utilizar grafos dinâmicos que representam o estado atual do problema e apresentam as interações entre os vértices e suas conexões de maneira precisa, assim que ocorrem. Embora pareça mais vantajoso utilizar grafos dinâmicos, esta abordagem exige um alto custo computacional para manter a rede e o cálculo de suas propriedades constantemente atualizados. Uma alternativa simples para esse problema é construir uma sequência de grafos estáticos dentro de um período de tempo, exigindo um número menor de atualizações.

| Origens da Teoria dos Grafos

A Teoria dos Grafos tem origem em 1736 quando o matemático Leonhard Euler publicou um trabalho propondo a resolução de um problema conhecido como as setes pontes de Königsberg. Königsberg era uma cidade da antiga Prússia, que hoje se chama Kaliningrad e faz parte da Rússia (SIMÕES-PEREIRA, 2013). A cidade ainda hoje é cortada pelo rio Pregolia em quatro regiões e, na época, sete diferentes pontes ligavam

estas regiões, conforme ilustrado na Figura 7. O problema consiste em encontrar um caminho que seja possível atravessar todas as pontes sem cruzar nenhuma delas duas vezes e retornar ao ponto inicial.

Figura 7. Representação das sete pontes de Königsberg.




Fonte: Autor

Euler propôs representar as quatro regiões utilizando vértices e as sete pontes que ligam as regiões utilizando arestas, dando origem à Teoria dos Grafos. O multigrafo construído para representar o problema é ilustrado na Figura 8.

Figura 8. Problema das sete pontes de Königsberg representado como um multigrafo.

Com o auxílio do grafo ilustrado na Figura 8, Euler demonstrou matematicamente que seria impossível encontrar um caminho com as restrições impostas. A partir das análises de Euler para este problema, surgiu o conceito de *grafo euleriano*. Um grafo euleriano é aquele que possui um *ciclo euleriano*. Por sua vez, um ciclo euleriano é um caminho em um grafo que visita cada aresta exatamente uma vez, iniciando e terminando no mesmo vértice, assim como a definição do problema das sete pontes de Königsberg. Euler concluiu que este tipo de grafo possui algumas propriedades particulares. No caso de grafos não dirigidos, ele será euleriano se e somente se todos os seus vértices possuírem grau par. No caso de grafos dirigidos, ele só será euleriano se todos os vértices tiverem grau de entrada igual ao seu grau de saída. Desse modo, o multigrafo da Figura 8 não é euleriano, pois o grau do vértice A é 5 e dos vértices B, C, D é 3. Assim, nenhum dos vértices possui grau par.



| Aplicações envolvendo grafos e redes complexas

Ao longo desta unidade de estudo, buscamos relacionar os conceitos e definições relacionados à Teoria dos Grafos com problemas e aplicações do mundo real, como redes sociais, sistemas de transportes, entre outros. Entretanto, é importante ressaltar que os grafos e redes complexas são amplamente utilizados nas mais variadas aplicações e não se limitam aos problemas aqui citados. Newman (2010) apresenta uma divisão do uso de redes complexas em quatro grandes categorias: redes tecnológicas, redes de informação, redes biológicas e redes sociais. A seguir, apresentamos um panorama geral destas categorias com o objetivo de demonstrar o grande número de aplicações que as redes podem ser utilizadas e inspirar o seu uso em novas aplicações que possam surgir no futuro.

- **Redes tecnológicas.** Redes tecnológicas são redes construídas pelo homem, muitas vezes constituídas por equipamentos físicos, que visam melhorar a distribuição de algum recurso. Um exemplo são as redes de computadores presentes em empresas e universidades composta por servidores e computadores (vértices) e as suas ligações por cabos ou *wireless* (arestas). De maneira similar, as redes telefônicas também são um exemplo de redes tecnológicas. Outro exemplo são as redes de distribuição de energia composta por subestações de alta tensão (vértices) e linhas de transmissão (arestas) que se estendem por uma região de um país ou mesmo entre países. É interessante notar que neste tipo de rede, a residência de um cliente final da rede desempenha apenas o papel de receptor do recurso. Entretanto, em muitos países tem se popularizado nos últimos anos o conceito dos clientes desempenharem os papéis tanto de receptor como gerador de recursos de energia a partir do uso de painéis solares. Assim, além da necessidade de alterações na estrutura física da rede, percebe-se que a modelagem do problema também deverá ser modificada. Redes de transporte compostas por rotas aéreas, rodovias e linhas de trem também exemplificam as redes tecnológicas. Nestes casos, os aeroportos, cidades e estações representam os vértices, enquanto as rotas, sejam elas terrestres ou aéreas, representam as arestas da rede.
- **Redes de informação.** Este tipo de rede, também conhecida como redes de conhecimento, são caracterizadas por compartilhar informações entre os componentes da rede. Dois exemplos de redes de informação são as redes de páginas web que compõem a internet e as redes de citações acadêmicas. Nas redes de páginas web, os vértices são compostos pelas *webpages*, enquanto os *links* que redirecionam os usuários para outras páginas são as arestas. O estudo deste tipo de rede permite, por exemplo, o desenvolvimento de buscadores que retornam as páginas mais relevantes de acordo com a pesquisa de termos dos usuários. No segundo exemplo sobre redes de citações acadêmicas, os artigos científicos são os vértices da rede e uma conexão é estabelecida entre dois artigos sempre que um faz citação ao outro por meio de referências. A partir da análise dessas redes é possível identificar tanto artigos como pesquisadores relevantes em uma determinada área de conhecimento ou problema de pesquisa. A análise da estrutura da rede também pode ajudar a identificar práticas antiéticas realizadas por algum veículo científico, como a exigência de citações à trabalhos publicados em uma determinada revista científica.
- **Redes biológicas.** A Biologia é uma das áreas em que o uso de redes complexas é mais popular. Isso porque, dados biológicos são vastos e a descoberta de relações e padrões neste tipo de dado é uma importante informação para a compreensão de inúmeros problemas. Alguns exemplos de redes biológicas são as conexões entre células cerebrais, relações entre diferentes espécies em ecossistemas, interação entre proteínas, redes de expressão gênica, entre outros.

- **Redes sociais.** Embora atualmente o termo rede social seja atribuído às redes geradas por conexões virtuais na internet em plataformas como *Facebook*, *Twitter* ou *Instagram*, o estudo das relações entre pessoas e grupos de pessoas utilizando grafos surgiu em 1930 em estudos de sociologia (MORENO, 1930). Entretanto, é inegável que as novas tecnologias são responsáveis pela geração de uma quantidade massiva de dados para a construção de grandes redes de maneira facilitada e que seriam impossíveis de construir no passado. Neste tipo de rede, pode-se estabelecer conexões entre pessoas ou empresas de diferentes maneiras. Por exemplo, de acordo com laços de amizade, laços de parentesco, relações profissionais, comunicação ou relações comerciais. Este é um campo tão vasto, que somente a análise de redes sociais constituem uma área de intensa pesquisa na área da computação.

| Visão geral das tarefas de **Graph Mining**

Graph mining ou mineração de grafos, corresponde ao uso de técnicas de Inteligência Artificial para extrair conhecimento de dados que estão representados no formato de grafos, visando explorar as relações e associações entre estes dados. A partir de uma grande quantidade de dados, estas técnicas permitem encontrar de maneira automática, padrões inesperados que dificilmente seriam encontrados a partir de uma análise manual ou que seriam encontradas de maneira dispendiosa, custando tempo e esforço de especialistas. A partir do conhecimento extraído, diferentes tarefas de mineração de dados podem ser realizadas.


As tarefas de mineração de dados podem ser divididas em dois grandes grupos: tarefas preditivas e tarefas descritivas. Nas tarefas preditivas, o conhecimento extraído dos dados é utilizado para prever valores desconhecidos ou prever os valores de exemplos futuros. Já nas tarefas descritivas, a ideia é utilizar o conhecimento extraído para explicar o comportamento dos dados de maneira simples. A seguir, é apresentada uma visão geral das tarefas de *graph mining* que serão exploradas ao longo desta disciplina (GOLDSCHMIDT; PASSOS; BEZERRA, 2015): análise de centralidade, detecção de comunidades e predição de conexões.

- **Análise de centralidade.** Ao analisar uma rede utilizando métodos descritivos, uma das tarefas mais relevantes é identificar os vértices mais importantes ou centrais dentro da estrutura da rede. Estes vértices podem representar, por exemplo, uma página da internet que possui muitos visitantes ou a pessoa mais influente em uma rede social. Nesse sentido, diferentes medidas de centralidade podem ser

utilizadas para quantificar a importância dos vértices, cada uma com uma perspectiva diferente. Podemos considerar que um vértice é importante se possui muitas conexões (centralidade de grau), se está próximo de outros vértices (centralidade de proximidade) ou se faz parte de muitos caminhos (centralidade de intermediação).

- **Detecção de comunidades.** Em muitos problemas modelados utilizando grafos, é comum a existência de grupos de vértices com maior número de conexões entre si em comparação com outros vértices da rede. Por exemplo, em redes sociais grupos de usuários possuem interesses em comum, como a preferência por um estilo musical, programa de TV ou esporte e, por isso, podem apresentar um número maior de interações entre si. Estes grupos são chamados de comunidades e constituem uma importante informação para a análise do comportamento dos membros da rede. Existem diferentes abordagens e algoritmos de mineração de dados que visam encontrar estas comunidades de maneira eficiente. A Figura 9 ilustra três comunidades em uma rede, onde é possível observar o maior número de conexões entre os vértices de um mesmo grupo.

Figura 9. Exemplo de rede com três comunidades.



Fonte: Autor

- **Predição de conexões.** A predição de conexões visa estimar a probabilidade da existência de uma aresta entre dois vértices da rede que não estejam conectados. Essa tarefa é importante em dois cenários diferentes. No primeiro cenário, a predição de conexões pode ser utilizada para recuperar conexões que possam ter sido eventualmente perdidas durante o processo de construção da rede devido à restrições de acesso aos dados ou perda de informação. No segundo cenário, o objetivo é prever conexões que poderão existir no futuro devido a evolução da rede com o tempo. O processo de predição de conexões pode se basear tanto em informações obtidas dos membros da rede como em informações estruturais (topológicas) da rede. A predição de conexões pode ser utilizada nas mais variadas aplicações, como predição de colaboração entre profissionais, recomendação de produtos para clientes, análise e compreensão de epidemias e personalização de notícias para usuários.

Conclusão

Nesta unidade, fizemos uma introdução à Teoria dos Grafos, um importante ramo da matemática que estuda a utilização de grafos para representar problemas complexos que envolvem muitas relações entre seus elementos. Os conceitos discutidos formam a base inicial para a compreensão das diferentes tarefas de mineração de dados utilizando grafos ou simplesmente, *graph mining*. A seguir, é apresentado um

resumo do que foi estudado nesta unidade.

- **Conceitos básicos.** Você aprendeu sobre os principais elementos que compõem os grafos, como representá-los visualmente e como alguns problemas do nosso cotidiano podem ser representados por grafos. Os elementos principais dessa abstração matemática são os vértices ou nós e as arestas, que podem ser dirigidas ou não dirigidas, valoradas ou não valoradas, laços e paralelas;
- **Terminologia.** A Teoria dos Grafos é repleta de terminologias e nesta unidade você aprendeu algumas que dizem respeito à categorização dos grafos em relação aos tipos de arestas presentes. Por exemplo, grafo simples, grafo completo, digrafo ou grafo dirigido, grafo não dirigido, multigrafo, pseudografo, grafo misto, grafo conexo e desconexo, árvore, grafo valorado ou ponderado, grafos estáticos e grafos dinâmicos;
- **Propriedades básicas.** Ao longo desta disciplina, serão exploradas inúmeras propriedades que podem ser extraídas da estrutura (topologia) de um grafo. Nesta unidade, foram introduzidas duas propriedades básicas importantes para a caracterização de um grafo e o cálculo de outras métricas que serão estudadas futuramente, que dizem respeito ao grau de um vértice e a distribuição de graus dos vértices do grafo. A partir destas propriedades, é possível, por exemplo, compreender as diferenças entre um grafo e uma rede complexa;
- **Origens da Teoria dos Grafos.** Conhecer as origens de uma área de conhecimento é sempre importante para compreender a motivação dos problemas abordados na área e visualizar a sua evolução ao longo do tempo. O mundo atual é muito diferente do que era em 1736 quando Euler iniciou os primeiros estudos na Teoria dos Grafos, mas os seus fundamentos ainda são essenciais para modelar e compreender problemas atuais utilizando uma vasta quantidade de dados e soluções computacionais;
- **Exemplos de aplicações.** Ao longo desta unidade, foi possível perceber que grafos são fortemente relacionados à muitas aplicações reais. Para uma compreensão mais ampla sobre as inúmeras possibilidades de seu uso, foram discutidos exemplos de aplicações em quatro diferentes categorias: redes tecnológicas, redes de informação, redes biológicas e redes sociais;
- **Visão geral sobre *graph mining*.** Por fim, foi apresentada uma visão geral sobre as tarefas de mineração de dados em grafos que serão exploradas ao longo da disciplina, como análise de centralidade, detecção de comunidades e predição de conexões.

Referências Bibliográficas

GABARDO, A. C. *Análise de redes sociais: uma visão computacional*. São Paulo: Novatec, 2015. ISBN 9788575224175,

GOLDBARG, M.; GOLDBARG, E. *Grafos: conceitos, algoritmos e aplicações*. Rio de Janeiro: Editora LTC - Grupo GEN, 2012. ISBN 9788595155756. [Minha Biblioteca]. Disponível em: <https://integrada.minhabiblioteca.com.br/#/books/9788595155756/>

GOLDSCHMIDT, R.; PASSOS, E.; BEZERRA, E. *Data Mining: Conceitos, técnicas, algoritmos, orientações e aplicações*. 2 ed. Rio de Janeiro: Editora LTC - Grupo GEN, 2015. ISBN 9788595156395. [Minha Biblioteca]. Disponível em: <https://integrada.minhabiblioteca.com.br/#/books/9788595156395/>

NEWMAN, M. E. J. *Networks: An Introduction*. Oxford: Oxford University Press, 2010.

MORENO, J., JENNINGS, H. *Who shall survive? A new approach to the problem of human interrelations*. Washington: Nervous and Mental Disease Publishing, 1934.

ROSEN, K. H. *Matemática discreta e suas aplicações*. 6. ed. Porto Alegre: AMGH, 2010.

SIMÕES-PEREIRA, J. M. S. *Grafos e redes: teoria e algoritmos básicos*. Rio de Janeiro: Editora Interciência, 2013. ISBN 9788571933316. [Biblioteca Virtual Universitária]. Disponível em: <https://plataforma.bvirtual.com.br/Acervo/Publicacao/42049>



© PUCPR - Todos os direitos reservados.