



Técnica em Graph Mining

UNIDADE 06


Detectando grupos e comunidades em redes complexas

| Detecção de Comunidades

O que são comunidades e a importância da sua detecção

No contexto de grafos e redes complexas, comunidades, grupos ou *clusters* são subgrafos do grafo original, de modo que os objetos de cada subgrafo são de alguma maneira similares entre eles (GOLDSCHMIDT, PASSOS, BEZERRA, 2015). Em outras palavras, uma comunidade em um grafo G é um subconjunto de vértices de G que estão densamente conectados entre si, mas esparsamente conectados aos demais vértices de G . Para ilustrar melhor essa definição, a Figura 1 apresenta um exemplo com três comunidades identificadas como C_1 , C_2 e C_3 . Essas comunidades estão destacadas por círculos pontilhados, em que podemos observar que os vértices dentro de cada círculo possuem um número maior de conexões entre eles quando comparado com as conexões entre os vértices de comunidades diferentes. Essas comunidades podem ser, por exemplo, empresas que realizam transações entre si, havendo uma maior interação entre determinados grupos de empresas devido aos seus ramos de atividade.

Figura 1. Exemplo de rede com três comunidades



Ao identificar comunidades na rede, pode-se assumir que os vértices pertencentes a uma mesma comunidade compartilham propriedades em comum ou desempenham papel semelhante na rede. Desse modo, a detecção de comunidades é uma importante tarefa que auxilia na compreensão da estrutura da rede, fornece informações sobre grupos de vértices importantes para a rede e informações sobre o problema representado pelo grafo.

De acordo com Faceli et al. 2021, o estudo sobre as estruturas de comunidades em redes tem uma longa história em duas áreas de conhecimento distintas ainda na década de 70. A tarefa de detecção de comunidades é relacionada, por exemplo, com o problema de particionamento de grafos estudado na Teoria dos Grafos com aplicação na Computação. Por outro lado, a tarefa também é relacionada ao problema de agrupamento hierárquico estudado na área de Sociologia. O problema de particionamento de grafos estudado na Teoria dos Grafos foi motivado pela necessidade de encontrar a melhor forma de alocar tarefas a processadores visando minimizar a comunicação entre eles e otimizar a computação paralela. Já na Sociologia, a principal motivação foi simplificar a análise de fenômenos sociais por meio de agrupamentos dos atores sociais de acordo com o seu grau de semelhança. Independente da área ou a sua motivação, em ambos os casos o propósito é descobrir grupos de vértices relacionados tendo por base somente a informação fornecida pela topologia da rede.

Aplicações

No caso de redes sociais, a formação de comunidades pode ser composta por pessoas que formam grupos com algo em comum, como família, círculos de amizade, local de trabalho, cidades, preferências musicais, posicionamento político, entre outras formas de agrupamento. A detecção de comunidades nesse cenário pode ser utilizada para recomendar novas amizades, recomendar uma vaga de emprego ou as músicas de um artista. Embora a estrutura de comunidades seja natural e comum em redes sociais, é importante destacar que a presença destes grupos não se limita a este tipo de problema e a detecção de comunidades é uma tarefa útil para diferentes domínios de aplicação.

No comércio eletrônico, a detecção de comunidades pode ser utilizada tanto para a recomendação de produtos para clientes com perfil de consumo similar, como para o direcionamento de ações de *marketing* mais eficientes para um grupo reduzido de possíveis clientes. Em aplicações de segurança, a detecção de comunidades pode ser utilizada para a descoberta de grupos de terroristas ou criminosos a partir de suas atividades e interações. De maneira similar, pode-se identificar *bots* maliciosos na web. Em uma rede de computadores, a detecção de comunidades pode ser utilizada para agrupar servidores de acordo com o fluxo de informações na rede, permitindo gerar tabelas de roteamento compactas que tornam a comunicação mais eficiente. Em redes de colaboração científica, pode-se utilizar a detecção de comunidades para identificar grupos de pesquisadores que trabalham em temas de pesquisa em comum em um determinado país. Na área de

Biologia, a detecção de comunidades pode ser utilizada em redes metabólicas. Por exemplo, em redes de interação de proteínas, pode-se encontrar grupos de proteínas que desempenham funções similares na célula. Na análise de epidemias, pode-se utilizar a detecção de comunidades para estudar a dinâmica de grupos de pessoas de acordo com fatores sociais ou comorbidades.

Algoritmos para detecção de comunidades


Existem diversas abordagens algorítmicas para a identificação de grupos ou comunidades em redes complexas, como os métodos espectrais, métodos locais e métodos de otimização de modularidade. Entretanto, os métodos aglomerativos e divisivos, que seguem a abordagem de agrupamento de dados hierárquico, são os mais populares. Os métodos aglomerativos iniciam o seu processo de detecção considerando que cada vértice da rede compõe uma comunidade e ao longo das iterações, os vértices semelhantes vão se aglomerando nas mesmas comunidades. Já os métodos divisivos iniciam considerando todos os vértices da rede como uma única comunidade que irá se dividindo ao longo das iterações de acordo com determinados critérios. Em geral, o funcionamento destes métodos se dá a partir da remoção ou inclusão de arestas entre os vértices de maneira iterativa para a formação das comunidades.

Você deve ter percebido que a ideia por trás de ambas as abordagens considera que as comunidades podem estar ordenadas de maneira hierárquica. De fato, em muitos problemas reais podemos considerar diferentes níveis de organização destes grupos. Por exemplo, em uma rede social, podemos ter em um grande grupo composto por todas as pessoas que moram em um mesmo país. Dentro deste grupo, podemos organizar as pessoas de acordo com as cidades em que vivem. Nas cidades, podemos organizá-las de acordo com a empresa que trabalham. E dentro da empresa, podemos organizá-las de acordo com os departamentos dentro da empresa. Note que em cada grupo há um nível maior de granularidade da informação, partindo de um grande grupo composto por um número grande de pessoas (toda a rede), chegando a grupos reduzidos de pessoas (comunidades).

Para melhor compreensão das abordagens aglomerativas e divisivas para a detecção de comunidades e como elas consideram a hierarquia dos grupos, considere o exemplo apresentado na Figura 2. Nesta imagem, é utilizado um dendrograma para representar um grafo com cinco vértices e diferentes níveis de hierarquia que podem ser considerados para a definição das comunidades a partir do agrupamento de conjuntos de vértices. Cada linha horizontal tracejada representa um diferente nível para a divisão dos vértices em comunidades, também chamado de ponto de corte onde cortes mais próximos à base resultam em um maior número de comunidades formadas por poucos vértices. Por exemplo,

quando considerado o primeiro nível (mais próximo dos vértices), são criados 5 grupos, onde cada grupo será composto por um único vértice. No segundo nível, serão criados 3 grupos C_1 , C_2 e C_3 , em que $C_1 = \{A, B\}$, $C_2 = \{C\}$ e $C_3 = \{D, E\}$. No terceiro nível, serão criados 2 grupos $C_1 = \{A, B\}$ e $C_2 = \{C, D, E\}$. Por fim, no quarto nível será criado um único grupo $C_1 = \{A, B, C, D, E\}$. Conforme discutido anteriormente, métodos aglomerativos iniciam o seu processo de descoberta de comunidades a partir da parte de baixo da hierarquia, enquanto os métodos divisivos tem início no topo da hierarquia.

Figura 2. Dendrograma para ilustrar o agrupamento de cinco vértices de um grafo.



Fonte: Autor

Dentro destes dois grupos de abordagens, se encontram dezenas de algoritmos para a detecção de comunidades, onde cada algoritmo define diferentes critérios para considerar a similaridade entre os vértices que estarão juntos ou separados em uma mesma comunidade. A seguir, são apresentados alguns dos principais algoritmos da literatura.

Métodos divisivos

Algoritmo *Edge Betweenness* de Girvan-Newman

Um dos algoritmos de detecção de comunidades mais populares é o algoritmo *Edge Betweenness* ou algoritmo Girvan-Newman, desenvolvido por Girvan e Newman (2002). Este algoritmo segue a abordagem divisiva, desconstruindo a rede original a partir da remoção das arestas de maneira progressiva formando pequenas partes conectadas. Este processo é repetido até o ponto em que não é possível remover mais arestas e cada vértice representa uma única comunidade.

A remoção das arestas não é realizada de maneira aleatória, esse processo segue um critério com o objetivo de formar grupos coesos de vértices com ligações esparsas entre os diferentes grupos. Para isso, o critério adotado pelo algoritmo é a medida de intermediação da aresta ou *edge betweenness*. Na unidade de estudo anterior, foi discutida a medida de centralidade de intermediação, em que se mede a importância de um vértice de acordo com a proporção de vezes que o vértice faz parte dos caminhos mínimos da rede. Conforme discutido, essa é uma medida para avaliar a importância de um vértice. Entretanto, é possível calcular esta medida de maneira similar para verificar a importância de uma aresta entre um par de vértices, obtendo-se assim a centralidade de intermediação de aresta. A escolha dessa medida é justificada pela seguinte razão: como o número de arestas conectando duas comunidades é pequeno, todos os caminhos mínimos que ligam os vértices em comunidades diferentes passam por essas arestas com um alto valor de centralidade de intermediação. Em outras palavras, as arestas com um alto valor de intermediação representam “pontes” entre grupos de vértices e a sua remoção faz com que esses grupos sejam mais isolados, levando a descoberta das comunidades da rede.

O funcionamento do algoritmo de Girvan-Newman pode ser resumido em 4 passos principais, conforme apresentado a seguir:

1. Calcule os valores de centralidade de intermediação de todas as arestas da rede;
2. Remova da rede a aresta com maior valor de intermediação;


3. Recalcule os valores de intermediação para as demais arestas da rede;
4. Volte para o Passo 2.

Estes passos são repetidos até que todas as arestas do grafo tenham sido removidas. O algoritmo recebe como entrada a rede composta por vértices e arestas, retornando como saída uma estrutura hierárquica dos vértices, mais especificamente, um dendrograma conforme anteriormente ilustrado na Figura 2. Com este dendrograma, pode-se realizar a análise das comunidades encontradas a partir do corte em diferentes níveis da hierarquia, em que cada nível irá apresentar diferentes partições de dados.


Usualmente na análise dos dados, utiliza-se o dendrograma para identificar quem são as comunidades e, posteriormente, pode-se desenhar a rede com seus vértices e arestas, alterando-se a cor dos vértices de acordo com a comunidade a qual pertence. Na Figura 3, apresentamos o exemplo de uma rede com 34 vértices e 78 arestas. A primeira imagem a esquerda representa a rede original sem a indicação das comunidades. Nas imagens seguintes, apresentamos a rede com os vértices coloridos de acordo com as comunidades encontradas pelo algoritmo Girvan-Newman. Em cada imagem, indicamos em qual nível da hierarquia os dados foram separados em comunidades. Pode-se notar que com um corte no nível 1 da hierarquia, tem-se apenas duas comunidades. Na última imagem da figura, onde realizou-se o corte do dendrograma no nível 7, nota-se a presença de 8 grupos sendo alguns deles compostos por um único vértice.

Figura 3. Comunidades detectadas pelo algoritmo Girvan-Newman dado diferentes níveis de corte na hierarquia.


Grafo original




Nível = 1




Nível = 2




Nível = 3




Nível = 4




Nível = 5



Nível = 6



Nível = 7



Fonte: Autor

É importante destacar que por ser baseado no conceito de intermediação, o algoritmo de Girvan-Newman possui um custo computacional elevado, sendo inviável em rede muito grandes. Somente o cálculo da centralidade de intermediação das arestas de uma rede possui complexidade $O(MN^2)$ em um grafo com M arestas e N vértices. Entretanto, esse cálculo deve ser feito a cada remoção de aresta.

Métodos aglomerativos

Algoritmo de Clauset, Newman e Moore (CNM)

O algoritmo de Clauset, Newman e Moore ou simplesmente CNM (CLAUSET, NEWMAN e MOORE, 2004), é um algoritmo aglomerativo baseado no conceito de modularidade (NEWMAN e GIRVAN, 2004). A modularidade é uma medida amplamente utilizada para avaliar a qualidade das comunidades encontradas pelos algoritmos de detecção e pode também ser utilizada para encontrar tais comunidades. A medida de modularidade é definida de acordo com a equação a seguir, dado um conjunto de K comunidades:

$$Q = \sum_i^K (e_{ii} - a_i^2)$$


Nesta equação, i representa uma comunidade, e_{ii} é a fração de arestas que estão inteiramente na comunidade i e a_i é a fração de arestas que possuem pelo menos um extremo na comunidade i . Desse modo, a modularidade assume um valor entre -1 e 1, em que 1 indica melhores estruturas de comunidade na rede.

Por ser um método aglomerativo, o algoritmo CNM inicialmente considera que cada vértice constitui uma comunidade. Assim, dada uma rede com N vértice, tem-se inicialmente N comunidades. A cada iteração do algoritmo, as comunidades são unidas levando em consideração os pares de comunidades que irão resultar no maior ganho (ou na menor perda) da medida de modularidade Q com a sua união. O processo é repetido até exista uma única comunidade que abrange todos os vértices da rede. Ao final, é gerado um dendrograma que revela a estrutura de comunidades. Como se tem um valor de modularidade para cada nível do dendrograma, pode-se realizar o corte no nível que apresentar o maior valor.


Por vezes, este algoritmo é denominado de *greedy* em algumas bibliotecas. Na Figura 4, é apresentado o grafo anteriormente discutido na Figura 3, mas com as comunidades detectadas pelo algoritmo CNM, onde pode-se observar a detecção de três comunidades distintas das identificadas pelo algoritmo de Girvan-Newman.

Figura 4. Comunidade identificadas pelo algoritmo CNM

Grafo original



Grafo com comunidades



Fonte: Autor

O tempo de execução do algoritmo em uma rede com N vértices e M arestas é $O(Md \log N)$, onde d é a profundidade do dendrograma. Embora sua complexidade seja menor em relação ao algoritmo de Girvan-Newman no caso médio, seu tempo depende da quantidade de arestas da rede, podendo ser computacionalmente custoso em redes densamente conectadas.

Algoritmo de Louvain

O algoritmo de Louvain também utiliza a modularidade como métrica para a detecção de comunidades a partir de uma abordagem aglomerativa (BLONDEL, et al., 2008). O método é dividido em duas fases. Na primeira fase, inicialmente o algoritmo considera que cada vértice é uma comunidade. Em seguida, para cada vértice i , verifica-se para cada um de seus vizinhos j , qual seria o ganho de modularidade se o vértice i fosse removido de sua comunidade e inserido na comunidade de j . Após verificar todos os vizinhos, o vértice i é inserido na comunidade onde


é alcançado o maior valor de modularidade. Porém, o vértice é inserido somente se este ganho for positivo, já que a modularidade varia entre -1 e 1. Caso contrário, o vértice permanece em sua comunidade. Este processo se repete até que não seja mais possível melhorar a modularidade das comunidades com a inclusão de um vértice.

Na segunda fase, é construída uma nova rede onde os vértices são as comunidades da primeira fase. Ou seja, os diferentes vértices de uma comunidade são agregados em um único vértice. Nesta fase, atribui-se pesos às arestas que conectam as diferentes comunidades. Estes pesos são definidos de acordo com a soma da quantidade de conexões entre as duas comunidades ligadas pela aresta. Além disso, cada vértice recebe um laço (ou *loop*) com um peso referente a duas vezes a quantidade de conexões entre os vértices da mesma comunidade. Ao terminar a segunda fase, a primeira fase é reaplicada na nova rede e todo o processo é repetido até que não seja mais possível obter um ganho na medida de modularidade.


A Figura 5 ilustra as fases dos algoritmos de Louvain para a detecção de comunidades uma rede com 15 vértices. Cada execução da primeira e segunda fases são chamadas de *passos*. No primeiro passo, após o término da Fase 1, são encontradas quatro comunidades de acordo a otimização da medida de modularidade. Na Fase 2, cada uma das comunidades é agregada em um único vértice, formando o grafo ponderado com quatro vértices ilustrado na terceira coluna da imagem. O vértice azul deste grafo possui um laço com peso 2, já em sua comunidade tem-se apenas 1 conexão entre os vértices 11 e 13, e em laços considera-se o dobre da quantidade de conexões. O peso da aresta que liga o vértice azul com o vértice verde é igual a 3, já que existem três conexões que conectam ambas as comunidades, sendo entre os vértices 8-11, 10-11 e 10-13. No segundo passo, a Fase 1 é repetida considerando o grafo anterior. Nesta iteração são encontradas 2 comunidades, as quais são posteriormente agregadas por um vértice cada um na Fase 2. Assim, ao final de dois passos são detectadas duas comunidades.

Figura 5. Passos e fases realizados pelo algoritmo Louvain de detecção de comunidades.

1º Passo



2º Passo




O algoritmo possui complexidade $O(N \log N)$ de acordo com o número N de vértices da rede, o que o torna adequado para redes de tamanhos variados, sendo capaz de processar redes com até 100 milhões de vértices e milhares de milhões de arestas. Além disso, o método obtém melhores valores de modularidade em comparação aos obtidos por algoritmos como Girvan-Newman e CNM, discutidos anteriormente.


Na Figura 6, apresentamos o mesmo grafo discutido anteriormente na Figura 3 e na Figura 4, com as comunidades identificadas pelo algoritmo Louvain. Para este exemplo, o algoritmo detectou um total de quatro comunidades.

Figura 6. Comunidades identificadas pelo algoritmo Louvain

Grafo original



Grafo com comunidades



Fonte: Autor.

Algoritmo de Propagação de Rótulos (Label Propagation)

O algoritmo de propagação de rótulos ou *label propagation* (RAGHAVAN, ALBERT e KUMARA, 2007), detecta comunidades utilizando somente a estrutura da rede sem utilizar uma função objetivo que se busca otimizar, como o valor de modularidade considerado por outros algoritmos.


O algoritmo inicia atribuindo um rótulo de maneira aleatória para cada vértice da rede indicando a qual comunidade ele pertence. Ao longo das iterações do algoritmo, esses rótulos se propagam pela rede, de modo que em cada iteração cada vértice atualiza o seu rótulo para aquele que é um consenso entre a maioria dos seus vértices vizinhos. A escolha da ordem dos vértices que serão verificados em cada iteração do algoritmo ocorre de maneira aleatória. Casos de empate são definidos também de maneira aleatória. O algoritmo encerra quando cada vértice possui o mesmo rótulo da maioria de seus vizinhos, não havendo mais possibilidades de alterações. Desta maneira, grupos densamente conectados formam um consenso em seus rótulos, indicando que eles participam da mesma comunidade. Embora exista a possibilidade de ser formada uma única comunidade em toda a rede e esta comunidade satisfaça o critério de parada do algoritmo, os autores alegam que o processo de competição entre os vértices desencoraja esse resultado.

Nas primeiras iterações do algoritmo, quando cada vértice possui o seu próprio rótulo atribuído de maneira aleatória, pouco consenso é estabelecido entre os vizinhos. No entanto, conforme aumenta o número de iterações, pequenos grupos começam a se formar e passam a ganhar influência na rede, sendo responsáveis por alterar o rótulo de seus vizinhos.


A Figura 7 ilustra as três comunidades detectadas pelo algoritmo de Propagação de Rótulos no grafo discutido ao longo desta unidade. No exemplo, nota-se a presença de comunidades pequenas e pouco coesas, como é o caso dos vértices marcados em verde e azul. Ao final, a maior parte dos vértices pertence a uma mesma comunidade, indicada em vermelho na imagem.

Figura 7. Comunidades identificadas pelo algoritmo de Propagação de Rótulos (Label Propagation)

Grafo original



Grafo com comunidades



Fonte: Autor.

Por sua estratégia de decisão simples, o algoritmo de Propagação de Rótulos é rápido e indicado para redes de larga escala. No caso de grafos aleatórios com conexões homogêneas, o algoritmo identifica toda a rede como uma única comunidade. Também é importante destacar que devido as várias decisões aleatórias do algoritmo, como a ordem de visita dos vértices e casos de desempate de rótulos, principalmente nas primeiras iterações, cada execução do algoritmo irá gerar um resultado diferente, mesmo que as condições iniciais sejam as mesmas. Algoritmos que apresentam esse tipo de comportamento são chamados de *não determinísticos*. Para evitar este problema, muitas bibliotecas computacionais que oferecem o algoritmo de Propagação de Rótulos consideram o mesmo *seed* em diferentes execuções, ou seja, consideram sempre as mesmas escolhas dos valores aleatórios em diferentes execuções de um mesmo conjunto de dados.

Conclusão

A estrutura de comunidade é uma das características mais investigadas em redes complexas e o desenvolvimento de soluções para a detecção destas comunidades em redes complexas é foco de estudo de muitos pesquisadores. A importância de identificar estas comunidades se dá pelo fato de que vértices de uma mesma comunidade tem maiores chances de compartilharem propriedades e desempenharem funções similares na rede. Deste modo, a detecção de comunidades é uma tarefa essencial para a obtenção de informações importantes de grupos de vértices e ajudam especialistas a analisar e compreender o problema representado por meio de grafos.

Nesta unidade, foi discutido que os principais algoritmos de detecção de comunidades podem ser inseridos em dois grupos de abordagens: aglomerativos e divisivos. Entretanto, é importante notar que existem centenas de algoritmos propostos na literatura e muitos deles não seguem exatamente uma destas abordagens. Especificamente, discutimos quatro algoritmos, a saber:

- Algoritmo *Edge Betweenness*. Este algoritmo segue uma abordagem divisiva, em que a rede é desconstruída a partir da remoção de arestas de maneira progressiva com o objetivo de evidenciar as comunidades da rede. Para a escolha das arestas a serem removidas, utiliza-se um critério baseado na medida de intermediação de aresta (medida baseada nos caminhos mínimos da rede) para a remoção de arestas que representam "pontes" entre as diferentes comunidades;
- Algoritmo de Clauset, Newman e Moore (CNM). O algoritmo CNM considera uma abordagem aglomerativa em que inicialmente cada comunidade é composta por um único vértice. Ao longo das iterações, pares de comunidades são agrupados levando em consideração a maximização de uma medida de modularidade que indica a qualidade das comunidades em termos de coesão interna e separação com os demais grupos;
- Algoritmo de Louvain. O algoritmo de Louvain também considera a medida de modularidade para encontrar comunidades, mas seu funcionamento é dividido em duas fases. Na primeira fase, a modularidade é considerada para realizar a formação de comunidades entre vértices vizinhos. Na segunda fase, uma nova rede é construída considerando cada comunidade encontrada na primeira fase como um único vértice da rede e então o processo de descoberta de comunidades considerando a medida de modularidade é repetida com esta nova rede;
- Algoritmo de Propagação de Rótulos (*Label Propagation*). Este algoritmo considera que inicialmente cada vértice possui um rótulo que indica uma comunidade. Ao longo das iterações é realizado um processo de propagação de rótulos pela rede. Em outras palavras, os

vértices alteram o seu rótulo para aquele utilizado pela maioria dos seus vizinhos. Ao final do processo, grupos densamente conectados formam um consenso em seus rótulos e formam uma comunidade.

Entre os principais desafios dos algoritmos de detecção de comunidades está o alto custo computacional. Muitos tem a sua complexidade de tempo relacionada ao número de arestas da rede, que pode superar em muitas vezes a quantidade de vértices, principalmente nas redes densamente conectadas, em que cada vértice possui inúmeras conexões. Assim, o uso de alguns algoritmos de detecção de comunidades é inviável em redes de larga escala.

Na maioria dos problemas, não se sabe de antemão qual é o número e o tamanho das comunidades que se está buscando. Assim, também é um desafio avaliar a qualidade das comunidades encontradas pelos algoritmos. Em geral, utiliza-se uma medida que considera a modularidade da rede, ou seja, o quão separadas estão as comunidades identificadas. Entretanto, do ponto de vista de análise de uma rede por um especialista, o resultado com maior valor de modularidade não é uma garantia de que o resultado de um algoritmo é mais interessante que o resultado de outro algoritmo com menor valor de modularidade. Por isso, existem vários algoritmos na literatura, onde cada um considera diferentes critérios para a detecção das comunidades e cabe ao especialista do domínio, avaliar e escolher os algoritmos mais adequados à sua análise de acordo com o problema estudado.

Todos os algoritmos abordados nesta unidade de estudo, consideram que os vértices pertencem exclusivamente a uma única comunidade. Porém, existem algoritmos que consideram partições com sobreposição, de modo que um vértice pode estar em mais de uma comunidade. De fato, em muitos problemas reais essa é uma característica presente, como nas redes sociais, em que as pessoas fazem parte de inúmeras comunidades.

Referências Bibliográficas

BLONDEL, V. D., GUILLAUME, J. L, LAMBIOTTE, R. LEFEBVRE, E. Fast unfolding of communities in large networks. Journal of statistical mechanics: theory and experiment, v. 2008, n. 10, p. P10008, 2008.

CLAUSET, A., NEWMAN, M. E. J., MOORE, C. Finding community structure in very large networks. Physical review E, v. 70, n. 6, p. 066111, 2004.

FACELI, K., LORENA, A. C., GAMA, J., ALMEIDA, T. A., CARVALHO, A. C. P. L. F. Inteligência Artificial - Uma Abordagem de Aprendizado de Máquina. Segunda Edição. Rio de Janeiro: Editora LTC - Grupo GEN, 2021. ISBN 9788521637509. [Minha Biblioteca]. Disponível em: <https://integrada.minhabiblioteca.com.br/#/books/9788521637509/>.

GIRVAN, M., NEWMAN, M. E. J. Community structure in social and biological networks. Proceedings of the national academy of sciences, v. 99, n. 12, p. 7821-7826, 2002.

GOLDSCHMIDT, R.; PASSOS, E.; BEZERRA, E. Data Mining: Conceitos, técnicas, algoritmos, orientações e aplicações. Segunda Edição. Rio de Janeiro: Editora LTC - Grupo GEN, 2015. ISBN 9788595156395. [Minha Biblioteca]. Disponível em: <https://integrada.minhabiblioteca.com.br/#/books/9788595156395/>.

RAGHAVAN, U. N., ALBERT, R., KUMARA, S. Near linear time algorithm to detect community structures in large-scale networks. Physical review E, v. 76, n. 3, p. 036106, 2007.

NEWMAN, M. E. J., GIRVAN, M. Finding and evaluating community structure in networks. Physical review E, v. 69, n. 2, p. 026113, 2004.

