



Técnica em Graph Mining

Previendo novas conexões na rede

Olá, seja bem-vindo a mais uma unidade de estudo!

Com certeza você já deve ter recebido uma sugestão de amizade na sua rede social, a recomendação de um filme na sua plataforma de streaming favorita ou a indicação de um produto em um site de comércio eletrônico. Você já parou para pensar como estas sugestões são feitas? Em muitos casos, a tarefa de mineração de dados por trás destes sistemas de recomendação é a predição de conexões ou predição de links. Nesta tarefa, um algoritmo considera informações sobre a rede e informações sobre outros componentes da rede com um comportamento ou papel semelhante ao seu para predizer uma conexão! Nessa unidade de estudo, iremos explorar os principais métodos para a predição de links em redes complexas.

Bons estudos!

| Apresentação da Unidade

Nesta unidade vamos conhecer uma das tarefas mais populares e importantes na mineração de grafos que é a predição de conexões. A unidade foca na apresentação dos métodos baseados em similaridade, que são os métodos mais difundidos para a predição de links devido a sua simplicidade e bons resultados preditivos. Estes métodos utilizam índices locais e globais, cada um com vantagens e desvantagens que serão discutidas ao longo da unidade. Por fim, também são discutidos quais são os principais desafios da tarefa de predição de links, como custo computacional de determinadas abordagens, uso de peso das arestas e temporalidade do surgimento de novas conexões.

Ao final desta unidade você deverá apresentar os seguintes aprendizados:

- Identificar cenários de aplicações reais em diferentes domínios que realizam a tarefa de predição de conexões;
- Compreender como o problema de predição de links é definido e como o resultado de um algoritmo de predição pode ser avaliado;
- Compreender os principais algoritmos de predição de links baseados em similaridade;

- Distinguir índices locais e índices globais utilizados pelos métodos baseados em similaridade e identificar as vantagens e desvantagens de cada abordagem;
- Conhecer os principais desafios da tarefa de predição de links;
- Capacidade de utilizar a biblioteca NetworkX de maneira autônoma para a predição de links em redes complexas utilizando diferentes algoritmos.


| Predição de conexões

Definição da tarefa

Em redes complexas, uma das principais tarefas de mineração de dados é a predição de conexões ou a predição de links. O objetivo desta tarefa é estimar a probabilidade de existir uma conexão futura entre os componentes da rede, ou seja, prever o estabelecimento de uma aresta entre dois vértices que até então não estão conectados. Essa estimativa é realizada com base em informações dos atributos dos vértices e das demais conexões existentes na rede. Em redes sociais, um exemplo típico de predição de links é a sugestão de amizade entre usuários. Com base nas similaridades entre os atributos dos usuários (como preferências em comum, local de trabalho, participação em comunidades, etc.) e com base em outras conexões existentes na rede (como as amizades dos seus amigos), pode-se sugerir uma conexão de amizade entre dois membros da rede. Outros exemplos de aplicações de domínios variados serão discutidos na próxima seção.

Nessa tarefa, o aspecto temporal é uma informação que deve ser levada em consideração, já que o estabelecimento de novas conexões ocorre ao longo do tempo com a evolução da rede. Assim, pode-se considerar o estado atual de conexões de uma rede no tempo t e buscar prever quais conexões serão adicionadas nesta rede entre o tempo t e um tempo futuro $t + 1$. A Figura 1 exemplifica a tarefa de predição de links, considerando uma rede inicialmente com 12 vértices e 11 conexões entre os vértices no tempo t . Para o tempo futuro $t + 1$, foram preditas a inclusão de 4 novas conexões, indicadas pelas linhas tracejadas na imagem. Em geral, um algoritmo de predição de links recebe como entrada uma rede e um conjunto de pares de vértices que serão verificados a probabilidade de conexão no futuro. Como saída, são retornadas as probabilidades de existir uma conexão entre cada par de vértices.

Figura 1. Ilustração da tarefa de predição de links.



Fonte: Autor

Uma tarefa relacionada à predição de links é a predição de links faltantes, em que o objetivo é verificar quais conexões deixarão de existir no futuro ou quais conexões poderiam ter sido perdidas durante o processo de construção da rede. Esta é uma tarefa útil para muitos tipos de redes, como redes de computadores e de equipamentos. Neste tipo de rede, a predição destes links poderia ser utilizada para o planejamento de manutenções visando a prevenção de problemas nestes equipamentos que acarretariam a perda da conexão.

Como não é possível prever o futuro para avaliar a qualidade de uma predição, ou seja, se a conexão prevista entre dois vértices de fato se concretizou ou não no futuro, são utilizadas metodologias e medidas de avaliação que visam verificar se a predição está correta e medir o desempenho do algoritmo de predição. Para isso, remove-se arestas relevantes da rede e se verifica se o algoritmo de predição foi capaz de identificar as arestas removidas, além de medir os erros no processo de predição.

Os acertos na identificação destas arestas são chamados de *verdadeiros positivos*. Um outro tipo de acerto é quando o algoritmo não prediz uma conexão entre dois vértices que de fato não irá ocorrer, chamado de *verdadeiro negativo*. Neste cenário, o algoritmo de predição pode cometer dois tipos de erros: prever uma conexão que não irá ocorrer entre dois vértices (*falso positivo*) e deixar de prever a conexão entre dois vértices (*falso negativo*). A partir destas taxas de erros e acertos, é possível calcular diferentes medidas para avaliar a qualidade das predições dos links, como as medidas de precisão, revocação e área sob a curva (AUC) (FACELI et. al, 2021).

Em linhas gerais, podemos interpretar a medida de precisão de acordo com seguinte pergunta: *a partir das arestas que foram indicadas, quantas delas realmente existiam antes de serem removidas?* De maneira similar, a medida de revocação pode ser interpretada de acordo com a seguinte pergunta: *a partir das arestas que foram removidas, quantas delas foram identificadas corretamente?* Para que fique ainda mais claro a interpretação das medidas, as equações utilizadas para o seu cálculo são apresentadas a seguir, considerando as taxas discutidas anteriormente.

$$\text{Precisão} = \frac{\text{Verdadeiros positivos}}{\text{Verdadeiros positivos} + \text{falsos negativos}}$$

$$\text{Revocação} = \frac{\text{Verdadeiros positivos}}{\text{Verdadeiros positivos} + \text{falsos negativos}}$$

A medida área sob a curva ou *Area Under Curve* (AUC) é uma medida que leva em consideração os valores obtidos na curva ROC (*Receiver Operating Characteristic Curve*). Por sua vez, a curva ROC é um gráfico que permite avaliar a taxa de verdadeiros positivos pela taxa de falsos positivos.

Aplicações

A tarefa de predição de links pode ser aplicada em uma ampla variedade de aplicações provenientes de diferentes domínios. A seguir, apresentamos algumas das aplicações mais populares.

- **Redes sociais.** Conforme discutido anteriormente, a predição de links é comumente utilizada para a predição de novos relacionamentos em redes sociais e, possivelmente, é a aplicação com maior representatividade da tarefa de predição de links, devido a sua popularidade, fácil compreensão e por ser um tipo de problema comumente modelo utilizando redes complexas. Entretanto, é importante notar que as redes sociais não se resumem somente às redes de amizades, como as populares Facebook e Instagram. Na comunidade científica, um importante tipo de rede social é a de co-autoria, em que é possível analisar as colaborações científicas entre pesquisadores na publicação de trabalhos acadêmicos ou participação em projetos de pesquisa. Desse modo, a tarefa de predição de links é capaz de sugerir colaborações entre pesquisadores ou recomendar artigos de determinados pesquisadores que possuem colaborações em comum;
- **Sistemas de recomendação.** A tarefa de predição de links é popularmente utilizada em inúmeros sistemas comerciais de recomendação, desde a recomendação de produtos de um catálogo para potenciais clientes, recomendação de serviços, recomendação de conteúdo como notícias, músicas, filmes e vídeos, entre outros. Estes sistemas visam contribuir para que os usuários consigam lidar com um alto volume de itens disponível direcionando as suas escolhas, além de aumentar as oportunidades de consumo. As recomendações para um usuário se baseiam tanto nas suas preferências, obtidas a partir do seu histórico de navegação e de consumo, como no comportamento de outros usuários com características similares;
- **Propagação de doenças.** Durante a ocorrência de surtos ou epidemias de doenças virais como AIDS, febre amarela, dengue ou Coronavírus, a predição de links pode ser uma importante ferramenta epidemiológica tanto para a compreensão da propagação da doença, como para o planejamento de ações de controle e combate. Neste tipo de rede de contágio, os vértices representam os indivíduos (que podem estar contaminados ou não) e as arestas indicam por onde a doença transitou. Desse modo, é possível prever com antecedência a partir da predição de links, os caminhos mais prováveis que a doença irá avançar no futuro. Com base nesse tipo de informação pode-se buscar soluções que visam evitar estas conexões, como o isolamento destes indivíduos ou a sua vacinação;
- **Estruturação de redes criminosas.** Em alguns problemas não se tem o conhecimento da estrutura completa da rede, como nas redes formadas por terroristas, já que seus membros ocultam intencionalmente as suas informações e conexões. Desse modo, a identificação da estrutura completa da rede pode ser obtida a partir da tarefa de predição de conexões com base em informações parciais da rede. Estas informações sobre a estrutura da rede podem auxiliar autoridades tanto na resolução como na prevenção de crimes como ataques;

Além dos exemplos discutidos acima, a predição de links está presente em muitas outras aplicações, como em redes biológicas para a predição de interações entre proteínas, em aplicações médicas para a predição de sintomas de um determinado medicamento ou a descoberta de novos usos para medicamentos existentes.

Também é importante destacar que em muitos destes problemas, podemos ter *redes heterogêneas*. Neste tipo de rede, os componentes da rede podem ser de natureza diferente. Assim, existem relacionamentos entre pessoas e eventos, músicas, filmes, produtos, etc. Em redes chamadas de *homogêneas*, todos os vértices desempenham a mesma função na rede.

Abordagens e índices de similaridade

Para lidar com a tarefa de predição de links, diferentes métodos têm sido propostos nos últimos anos e utilizados nos mais variados problemas reais. De acordo com Lü e Zhou (2011), estes métodos podem ser divididos em três grandes grupos: *i)* métodos baseados em similaridade, *ii)* métodos baseados na máxima verossimilhança e *iii)* modelos probabilísticos. Além destas abordagens, também existem os métodos híbridos que combinam ideias dos grupos citados anteriormente. Nesta unidade de estudo, serão abordados os métodos baseados em similaridade, devido a sua efetividade e simplicidade em relação às demais abordagens. Além disso, estes métodos são os mais difundidos e utilizam informações topológicas que são independentes do problema, podendo ser aplicados em qualquer tipo de rede (REBAZA, 2013). Em Rebaza, 2013 é apresentada uma revisão completa dos demais métodos de predição.


Os métodos baseados em similaridade se baseiam em informações estruturais obtidas da rede para realizar as predições de links. Estas informações são representadas por meio de índices de similaridade, que podem ser tanto locais como globais. Os índices locais consideram as informações de um par de vértices e sua vizinhança, enquanto os índices globais consideram informações topológicas de toda a rede. Desse modo, para cada par de vértices da rede é atribuída uma pontuação de acordo com um índice de similaridade. Os pares de vértices com maior pontuação são tidos como links com alta probabilidade de existência.

Conforme discutido anteriormente, os índices de similaridade local se baseiam em informações de pares de vértices e sua vizinhança, enquanto os índices de similaridade global consideram informações de toda a rede ou de maior parte da rede. Dessa maneira, índices globais são computacionalmente mais custosos de serem obtidos em relação aos índices locais. Entretanto, em muitos casos os índices globais

apresentam um maior poder preditivo. A seguir, são apresentados os principais índices de similaridade utilizados na tarefa de predição de links. Em nossa discussão, somente os dois últimos índices (Índice de Katz e Índice SimRank) são globais, enquanto os demais são índices locais.

Para os índices discutidos a seguir, considere que $N(v)$ é o conjunto de vértices vizinhos do vértice v . Por exemplo, considere o grafo representado na Figura 2. Neste grafo, as linhas sólidas representam arestas existentes entre os vértices e as linhas tracejadas representam possíveis arestas que podem ser preditas. Neste exemplo, $N(B) = \{A, C, E\}$, $N(C) = \{A, B, D, E\}$, $N(D) = \{C, E\}$, $N(E) = \{B, C, D\}$, e assim por diante.

Figura 2. Exemplo de grafo onde as linhas sólidas representam as arestas estabelecidas entre os vértices, enquanto as linhas tracejadas representam possíveis arestas que podem ser estabelecidas no futuro e alvo dos algoritmos de predição de links



Fonte: Autor

Vizinhos Comuns (Common Neighbors)

Um dos índices locais mais simples de ser calculado para a predição de links é o de Vizinhos Comuns. Neste índice, dois vértices x e y tem maior probabilidade de se conectarem no futuro se possuírem muitos vizinhos em comum. Formalmente, a pontuação de similaridade entre os vértices x e y é calculada da seguinte maneira considerando o Índice de Vizinhos Comuns:

$$S(x,y) = |\Gamma(x) \cap \Gamma(y)|$$

Na equação acima, é realizada uma contagem considerando a intersecção dos vizinhos dos vértices x e y . Por exemplo, considerando o grafo da Figura 2, vamos calcular o índice de vizinhos comuns para os potenciais pares de vértices (A,D), (A,E), (B,D) e (C,D), que são as arestas representadas por linhas tracejadas na imagem. Na Tabela 1, apresentamos quem são os vizinhos de cada vértice do par a ser verificado e calculamos o valor da medida na última coluna. Com base nos valores da última medida, os pares de vértices com maiores valores são aqueles que possuem maior probabilidade de possuírem uma aresta entre eles. No exemplo, a maior probabilidade é de existir uma aresta entre os vértices A e E.

Tabela 1. Cálculo do Índice de Vizinhos Comuns.

Par de vértices	$\Gamma(x)$	$\Gamma(y)$	$S_{x,y}$
(A, D)	{B, C}	{E}	0
(A, E)	{B, C}	{B, C, D}	2
(B, D)	{A, C, E}	{E}	1
(C, D)	{A, B, E}	{E}	1

Em geral, o resultado deste índice sugere o efeito de fechamento de triângulos entre os vértices do grafo. No exemplo, a inclusão da aresta predita entre os vértices A e E faria com que fosse formado o triângulo composto pelos vértices A, B, E. O fechamento de triângulos é similar a um comportamento social frequente no mundo real, em que o amigo do meu amigo tem grande probabilidade de também ser meu amigo. Embora bastante simples, esse índice é efetivo para uma série de problema superando índices mais complexos, além de ser computacionalmente barato. Este índice também é a base de muitos outros índices, alguns discutidos a seguir.

Índice de Jaccard

Uma limitação do Índice de Vizinhos Comuns é que em muitas redes, determinados vértices podem ter uma quantidade elevada de vizinhos (por exemplo, celebridades em redes sociais), fazendo com que o índice apresente um alto valor mesmo que os pares de vértices não sejam similares. Nesse sentido, o Índice de Jaccard corrige esta limitação a partir da normalização considerando a união dos vizinhos de ambos os vértices. O índice é definido de acordo com a equação apresentada a seguir:

$$S_{x,y} = \frac{|\Gamma(x) \cap \Gamma(y)|}{|\Gamma(x) \cup \Gamma(y)|}$$

No Índice de Jaccard, se o denominador for um valor grande comparado ao numerador, então os vértices não apresentam grande similaridade. Na Tabela 2, são apresentados os valores obtidos pelo Índice de Jaccard considerando o grafo da Figura 2. Novamente, a aresta com maior probabilidade de existir é a que conecta os vértices A e E.

Tabela 2. Cálculo do Índice de Jaccard.

Par de vértices	$\Gamma(x)$	$\Gamma(y)$	$S_{x,y}$
(A, D)	{B, C}	{E}	0
(A, E)	{B, C}	{B, C, D}	0,666
(B, D)	{A, C, E}	{E}	0,333
(C, D)	{A, B, E}	{E}	0,333

Índice de Salton

Assim como o Índice de Jaccard, o Índice de Salton também é baseado no Índice de Vizinhos Comuns, mas realiza o processo de normalização de maneira diferente. No Índice de Salton, a normalização é baseada no grau dos vértices. Assim, pares de vértices com maior grau terão um valor mais baixo de similaridade. Considerando que k_x é o grau do vértice x , o Índice de Salton é definido de acordo com a expressão abaixo:

$$S_{x,y} = \frac{|\Gamma(x) \cap \Gamma(y)|}{\sqrt{k_x \times k_y}}$$

Considerando a equação apresentada acima, podemos calcular o Índice de Salton do grafo da Figura 2 de acordo com os valores apresentados na Tabela 2.

Tabela 3. Cálculo do Índice de Salton.

Par de vértices	$\Gamma(x)$	k_x	$\Gamma(y)$	k_y	$S_{x,y}$
(A, D)	{B, C}	2	{E}	1	0
(A, E)	{B, C}	2	{B, C, D}	3	0,8165
(B, D)	{A, C, E}	3	{E}	1	0,5774
(C, D)	{A, B, E}	3	{E}	1	0,5774

Índice de Conexão Preferencial (Preferential Attachment)

O Índice de Conexão Preferencial leva em consideração um fenômeno anteriormente discutido sobre as características de redes complexas chamado de *rich get richer* ou os ricos ficam mais ricos, em que se discute que vértices com um elevado número de conexões tem maior probabilidade de terem novas conexões. Essa característica que faz com que redes reais possuam uma distribuição de graus que segue uma lei de potência, onde poucos vértices possuem muito mais conexões que os demais vértices da rede. Desse modo, o Índice de Conexão Preferencial considera a influência dos vértices da rede, a partir do cálculo de seu grau, para predizer se existirá uma aresta entre eles. O índice é calculado a partir da seguinte expressão, onde k_x representa o grau do vértice.

$$S_{x,y} = k_x \times k_y$$

A partir da equação acima, nota-se que a probabilidade de existir um link entre dois vértices é proporcional ao produto do número de vizinhos que cada vértice possui. A Tabela 4 apresenta os resultados obtidos para o cálculo do Índice de Conexão Preferencial considerando o exemplo apresentado na Figura 2.

Tabela 4. Cálculo do Índice de Conexão Preferencial

Par de vértices	k_x	k_y	$S_{x,y}$
(A, D)	2	1	2
(A, E)	2	3	6
(B, D)	3	1	3
(C, D)	3	1	3

Uma vantagem importante deste índice é que ele não precisa de informações da vizinhança de cada vértice, tornando o seu custo computacional bastante reduzido.

Índice de Alocação de Recursos (Resource Allocation)

Este índice é motivado por um processo chamado *alocação de recursos* que ocorre em redes complexas. Este processo considera que um determinado recurso pode ser transmitido entre dois vértices que não estão diretamente conectados, a partir de seus vizinhos. Durante o processo de transmissão do recurso, cada vértice da vizinhança obtém uma unidade do recurso e a distribui igualmente para seus vizinhos. A quantidade de recursos recebido por ao final do processo pode ser considerada a similaridade entre os vértices .

O Índice de Alocação de Recursos ou *Resource Allocation*, é definido de acordo com a seguinte equação:

$$S_{x,y} = \sum_{w \in \Gamma(x) \cap \Gamma(y)} \frac{1}{(|\Gamma(w)|)}$$

Nesta equação, são os vértices que estão no conjunto de intersecção que considera os vizinhos de x e y . Na Tabela 5 são apresentados os principais passos para o cálculo do Índice de Alocação de Recursos considerando o grafo da Figura 2. Note que na quinta coluna da tabela, são apresentados os principais passos para o cálculo do valor final do índice, indicado na última coluna.

Tabela 5. Cálculo do Índice de Alocação de Recursos.

Par de vértices	$\Gamma(x)$	$\Gamma(y)$	$\Gamma(x) \cap \Gamma(y)$	$S_{x,y}$	$S_{x,y}$
(A, D)	{B, C}	{E}	$\emptyset$	0	0
(A, E)	{B, C}	{B, C, D}	{B, C}	$\frac{1}{ \Gamma(B) } + \frac{1}{ \Gamma(C) }$	0,666
(B, D)	{A, C, E}	{E}	{E}	$\frac{1}{ \Gamma(E) }$	0,5
(C, D)	{A, B, E}	{E}	{E}	$\frac{1}{ \Gamma(E) }$	0,5

Índice de Adamic-Adar

O Índice de Adamic-Adar é bastante similar ao Índice de Alocação de Recursos. Entretanto, o peso do conjunto de vizinhos de (i) é suavizado pela aplicação do logaritmo da quantidade de vizinhos do vértice, como apresentado na equação a seguir:

$$S_{x,y} = \sum_{w \in \Gamma(x) \cap \Gamma(y)} \frac{1}{\log |\Gamma(w)|}$$

Com base na equação do Índice de Adamic-Adar apresentada acima, a Tabela 6 ilustra os passos e resultados obtidos a considerando o grafo da Figura 2.

Tabela 6. Cálculo do Índice de Adamic-Adar.

Par de vértices	$\Gamma(x)$	$\Gamma(y)$	$\Gamma(x) \cap \Gamma(y)$	$S_{x,y}$	$S_{x,y}$
(A, D)	{B, C}	{E}	$\emptyset$	0	0
(A, E)	{B, C}	{B, C, D}	{B, C}	$\frac{1}{\log \Gamma(B) } + \frac{1}{\log \Gamma(C) }$	1,8205
(B, D)	{A, C, E}	{E}	{E}	$\frac{1}{\log \Gamma(E) }$	1,4427
(C, D)	{A, B, E}	{E}	{E}	$\frac{1}{\log \Gamma(E) }$	1,4427

Índice de Katz

Os índices apresentados anteriormente são chamados de índices de similaridade locais, pois levam em consideração somente informações da vizinhança dos vértices em que se está calculando a probabilidade de existir uma aresta. Entretanto, índices chamados de globais, que levam em consideração informações de toda a rede ou da maior parte da rede possuem um alto poder preditivo, apesar do custo computacional elevado. Entre os índices de similaridade globais, o Índice de Katz se destaca entre os principais.

O Índice de Katz considera a soma do tamanho de todos os caminhos possíveis entre dois vértices para calcular a tendência deles se conectarem, ponderado pelo tamanho dos caminhos e atribuindo maior peso para caminhos mais curtos. O índice é definido de acordo com a expressão abaixo:

$$S_{x,y} = \sum_{l=1}^{\infty} \beta^l \times |\text{caminhos}_{s,y}^{(l)}|$$

Na expressão acima, o termo $\text{caminhos}_{s,y}^{(l)}$ representa o conjunto de todos os caminhos de tamanho l que tem s como vértice inicial e y como vértice final. $\beta \in (0,1)$ é um parâmetro utilizado para controlar o peso dos caminhos de acordo com o seu tamanho, de modo que valores próximos de 1 aumentam a influência de caminhos longos.

Índice SimRank

O índice global denominado SimRank considera que dois vértices são similares se seus vizinhos também são similares. Mais precisamente, os vértices a e b são similares se eles são vizinhos dos vértices c e d e, respectivamente. Por sua vez, c e d também são similares. O cálculo do índice é obtido a partir da seguinte expressão recursiva:

$$S_{x,y} = \gamma \times \frac{\sum_{a \in \Gamma(x)} \sum_{b \in \Gamma(y)} S_{a,b}}{|\Gamma(x)| \times |\Gamma(y)|}$$

Na expressão acima, c é uma constante e s , ou seja, a similaridade entre um vértice e ele mesmo é igual a 1 (similaridade máxima). Em sua proposta original, os autores sugerem um valor c e um número de iterações igual a 5.

Conclusão

A predição de novas conexões em uma rede complexa tem aplicação nos mais diversos domínios, como em sistemas de recomendação, comércio eletrônico, biologia, segurança, entre outros. O objetivo principal da tarefa é prever qual a probabilidade de existir uma conexão entre dois vértices no futuro, considerando que estes vértices não estão conectados. O exemplo mais popular da aplicação desta tarefa é visto em redes sociais quando recebemos uma sugestão de amizade.

Existem diferentes abordagens para a predição de links. Nesta unidade, foram discutidos os métodos baseados em similaridade. Estes métodos são os mais difundidos e possuem vantagens importantes como depender somente das informações da rede, o que permite que sejam aplicados em redes de qualquer domínio de aplicação. Estes métodos se baseiam no cálculo de índices de similaridade dos vértices, que podem ser locais ou globais.

Os índices globais extraem informações topológicas de toda a rede ou da maior parte da rede. Por essa razão, são computacionalmente mais custosos e podem ser proibitivos em redes de larga escala. Além disso, é importante destacar que nem sempre temos acesso a todas as informações da rede, o que pode ser uma restrição ao uso de índices globais nestas ocasiões. Entretanto, os métodos de predição de links baseados em índices globais apresentam melhores resultados preditivos. Entre os diferentes índices globais, nesta unidade de estudo foram apresentados o Índice de Katz e o Índice SimRank.

Por outro lado, os índices locais se baseiam no cálculo de informações da vizinhança do par de vértices que se está verificando a possibilidade de existência de uma aresta no futuro. Embora estes métodos apresentem um menor desempenho preditivo em comparação com os índices globais, o seu custo computacional é reduzido e não exige que se tenha informações de toda a rede. Nesta unidade, foram discutidos os seguintes índices locais: Vizinhos Comuns, Jaccard, Salton, Conexão Preferencial, Alocação de Recursos e Adamic-Adar.

Assim como outras tarefas envolvendo redes complexas, um dos principais desafios na predição de links é o alto custo computacional associado às soluções que necessitam verificar a maior parte das arestas da rede. Neste sentido, os métodos baseados em similaridade que utilizam índices locais são indicados para lidar com redes de larga escala.

Os métodos abordados nesta unidade consideram que as arestas são não valoradas (sem peso). Em um primeiro momento, podemos supor que o uso dos pesos das arestas auxilie nas predições, já que são informações adicionais sobre as conexões. Entretanto, ainda é um desafio de pesquisa como utilizar estes pesos de maneira efetiva para obter melhores predições, de modo que alguns trabalhos mostram que conexões com pesos maiores são mais relevantes, enquanto outros trabalhos mostram que conexões com menor peso são mais significativas para a tarefa de predição (REBAZA, 2013).

Além de identificar quantos e quais links irão surgir na rede no futuro, um outro desafio da tarefa é identificar quando estes links irão surgir. Em geral, assume-se o estado atual da rede no tempo t e realiza-se a predição de um conjunto de links em um tempo futuro $t + \Delta t$. Entretanto, estas conexões não surgem ao mesmo tempo, mas de maneira gradual entre os tempos t e $t + \Delta t$. Além disso, estas informações de temporalidade do surgimento dos links também podem ser informações relevantes para os métodos de predição de links.

Referências Bibliográficas

FACELI, K., LORENA, A. C., GAMA, J., ALMEIDA, T. A., CARVALHO, A. C. P. L. F. Inteligência Artificial - Uma Abordagem de Aprendizado de Máquina. Segunda Edição. Rio de Janeiro: Editora LTC - Grupo GEN, 2021. ISBN 9788521637509. [Minha Biblioteca]. Disponível em:

<https://integrada.minhabiblioteca.com.br/#/books/9788521637509/>

LÜ, L., ZHOU, T. Link prediction in complex networks: a survey. Physica A: Statistical Mechanics and its Applications, v. 390, n. 6, pp. 1150-1170, 2011.

REBAZA, J. C. V. Predição de links em redes complexas utilizando informações de estruturas de comunidades. 2013. Dissertação (Mestrado em Ciências de Computação e Matemática Computacional) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2013. doi: 10.11606/D.55.2013.tde-05062013-104308. Acesso em: 2021-06-29.



© PUCPR - Todos os direitos reservados.