

IA Aplicada à Computação Forense

UNIDADE 06

Auxílio da IA nas etapas da Computação Forense – parte 2

Nesta unidade, vamos explorar os fundamentos da visão computacional e o funcionamento das redes neurais convolucionais, compreendendo como imagens são transformadas em dados interpretáveis por máquinas.

Na sequência, vamos abordar desde a extração de características por convoluções até as etapas de *flattening* e classificação. Além disso, vamos discutir sobre o uso de *datasets*, treinamento de modelos e aplicações práticas.

O objetivo é entender como sistemas computacionais aprendem a “ver” e a tomar decisões com base em imagens. Por fim, vamos ver como são criteriosos os processos para um levantamento e uma análise forense voltados para dispositivos móveis e portáteis.

DOCUMENTOS

DetectorDeObjetosComYOLO.ipynb

Exemplo_Visao_Computacional_Deteccao_de_Bordas_V2.ipynb

Visão computacional: uma introdução de sua abordagem

A visão computacional é uma subárea da inteligência artificial e da ciência da computação dedicada ao desenvolvimento de sistemas capazes de interpretar imagens e vídeos de forma semelhante à visão humana. Seus primeiros estudos surgiram na década de 1960, quando pesquisadores passaram a investigar como computadores poderiam extrair informações estruturadas com base em dados visuais.

Em 1966, ocorreu um marco histórico, quando Marvin Minsky propôs, no MIT, um experimento aparentemente simples: fazer um computador reconhecer objetos em imagens. Isso acabou revelando a complexidade do problema e impulsionou o surgimento da área moderna de visão computacional.

Nos anos seguintes, a área foi fortemente influenciada pelos trabalhos de David Marr, que propôs a visão como um processo hierárquico, passando da detecção de bordas à construção de representações tridimensionais dos objetos. Sua obra, chamada Vision, tornou-se referência ao estruturar conceitualmente o processamento visual e orientar o desenvolvimento de algoritmos por décadas. Paralelamente, avanços no processamento digital de imagens, consolidados nos modelos matemáticos apresentados por Gonzalez e Woods, forneceram técnicas fundamentais como filtragem, segmentação e realce de imagens, que formaram a base da visão computacional tradicional.

Com o avanço do aprendizado profundo, especialmente a partir dos anos 2010, a área passou por uma transformação significativa. **As redes neurais convolucionais (CNNs)** demonstraram capacidade superior para reconhecimento de padrões visuais, superando abordagens clássicas em tarefas como classificação de imagens, detecção de objetos e análise de cenas. Modelos como LeNet e AlexNet marcaram essa virada, possibilitando aplicações sofisticadas em áreas como saúde, veículos autônomos, segurança e indústria.

A inspiração para esses sistemas vem diretamente do funcionamento da visão humana. No sistema biológico, a retina capta estímulos visuais e os envia ao córtex visual, no qual neurônios processam e interpretam as informações com base em características como formas, contornos e relações espaciais. Assim, mesmo diante de variações, como objetos parcialmente ocultos ou mal iluminados, o cérebro humano consegue reconhecer padrões com grande robustez. Essa capacidade de abstração serve como referência conceitual para a visão computacional moderna.

De forma análoga, as CNNs processam imagens como matrizes de *pixels* e aplicam filtros convolucionais para extrair características básicas, como bordas e texturas. Ao longo das camadas da rede, essas informações são combinadas e refinadas, formando representações cada vez mais abstratas, até que as camadas finais realizem a classificação ou a identificação do objeto. Esse processo envolve operações matemáticas complexas, otimização de pesos e grandes volumes de dados, conforme descrito em *deep learning.*

Portanto, compreender a visão computacional implica entender tanto as suas bases históricas quanto a analogia com a visão humana. Conceitos como convolução, *pooling*, normalização e funções de ativação são essenciais para explicar como sistemas artificiais conseguem aprender, generalizar e interpretar informações visuais, tornando essa área um dos pilares centrais da inteligência artificial contemporânea.

Seleção das imagens para treinamento da CNN

Para que o treinamento de uma rede neural convolucional apresente bons resultados, o conjunto de imagens utilizado deve ser numeroso, diverso e representativo do problema a ser resolvido. Isso implica reunir exemplos do mesmo objeto sob diferentes condições, como variações de posição, cor, iluminação, ângulo e contexto. Quanto maior a diversidade do *dataset*, maior tende a ser a capacidade de generalização do modelo, permitindo que a rede reconheça corretamente o objeto mesmo quando ele aparece de forma distinta daquelas observadas durante o treinamento.

As bases de dados consagradas na área de visão computacional evidenciam a importância dessa diversidade:

+ **ImageNet**

  É um dos *datasets* mais influentes da área e reúne milhares de categorias de objetos. Somente a classe “gato” contém mais de 1.800 imagens capturadas em ambientes, enquadramentos e situações bastante distintas. Essa variedade é

determinante para que modelos de aprendizagem profunda alcancem elevados níveis de desempenho no reconhecimento visual.

+ MNIST

Reúne dezenas de milhares de imagens de dígitos manuscritos. Cada número aparece em diferentes estilos de escrita, espessuras de traço e imperfeições naturais da caligrafia humana. Essa multiplicidade de formas permite que a rede aprenda a reconhecer os dígitos não como padrões rígidos, mas como um conjunto amplo de variações possíveis, aproximando o modelo do cenário real de uso.

#ParaTodosVerem

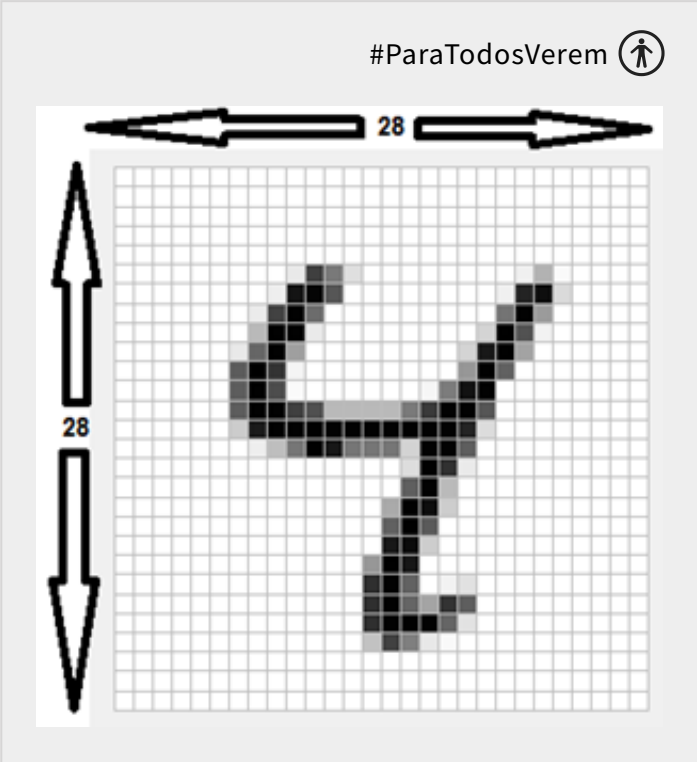


Fonte: Wikipedia.

Os *datasets* robustos como esses são essenciais para evitar problemas comuns no treinamento de redes neurais, como *overfitting*, baixa capacidade de generalização e erros recorrentes de classificação. No entanto, nem sempre é possível dispor de um volume tão grande de imagens. Nesses casos, técnicas de aumento de dados (*data augmentation*) tornam-se uma alternativa eficaz. Por meio de operações como rotação, espelhamento, inclinação, *zoom*, deslocamento e pequenas distorções geométricas, é possível gerar novas amostras com base nas imagens originais, ampliando artificialmente o conjunto de treinamento e tornando o modelo mais resistente a variações naturais do ambiente.

Além disso, outro fator técnico relevante é a padronização do tamanho das imagens, uma vez que as redes neurais exigem entradas com dimensões fixas. Computacionalmente, cada imagem é representada como uma matriz de *pixels*, na qual cada elemento corresponde a um valor numérico que indica a intensidade de cor. Em imagens em tons de cinza, cada *pixel* é descrito por um único valor; em imagens coloridas, utilizam-se três valores associados aos canais vermelho, verde e azul (RGB).

Na próxima figura, também extraída do MNIST, observa-se um exemplo do dígito manuscrito “4”. Nesse *dataset*, todas as imagens possuem dimensão de 28 × 28 *pixels*, formando uma matriz numérica em que valores mais claros representam o fundo e valores mais escuros correspondem às regiões do traço do número. Essa estrutura matricial é o ponto de partida para a aplicação dos filtros convolucionais durante a etapa de extração de características.



Fonte: Eunguru.

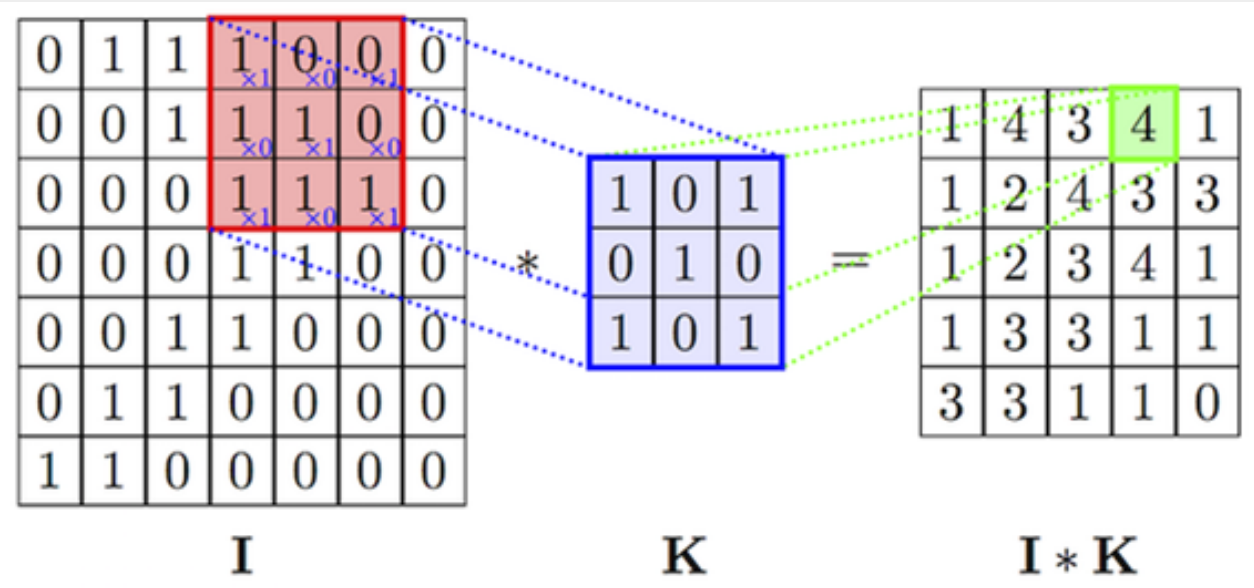
A combinação de *datasets* variados, a padronização das imagens e o uso de técnicas de aumento de dados é fundamental para melhorar o desempenho das redes neurais convolucionais, reduzir o risco de *overfitting* e garantir que o modelo aprenda características visuais relevantes mesmo quando o conjunto inicial de imagens é limitado.

Extração de características

No sistema visual humano, a identificação de objetos ocorre com base no reconhecimento de elementos, como contornos, formas, texturas e relações espaciais, que permitem distinguir e classificar aquilo que é observado. De maneira semelhante, as redes neurais convolucionais (CNNs) realizam a extração de informações relevantes das imagens por meio de mecanismos matemáticos que capturam padrões visuais significativos.

Nesse contexto, os filtros, também chamados de *kernels*, desempenham papel central. Eles consistem em pequenas matrizes numéricas que percorrem a imagem de entrada, analisando regiões locais de *pixels*. À medida que esses filtros se deslocam pela imagem, aplicam uma operação matemática que combina os valores dos *pixels* com os valores do filtro, gerando uma nova representação conhecida como *feature map*. Essa operação, representada pelo produto I * K, corresponde ao processo de convolução, ilustrado na figura a seguir, e é responsável por evidenciar características como bordas, contornos e variações de intensidade.

#ParaTodosVerem

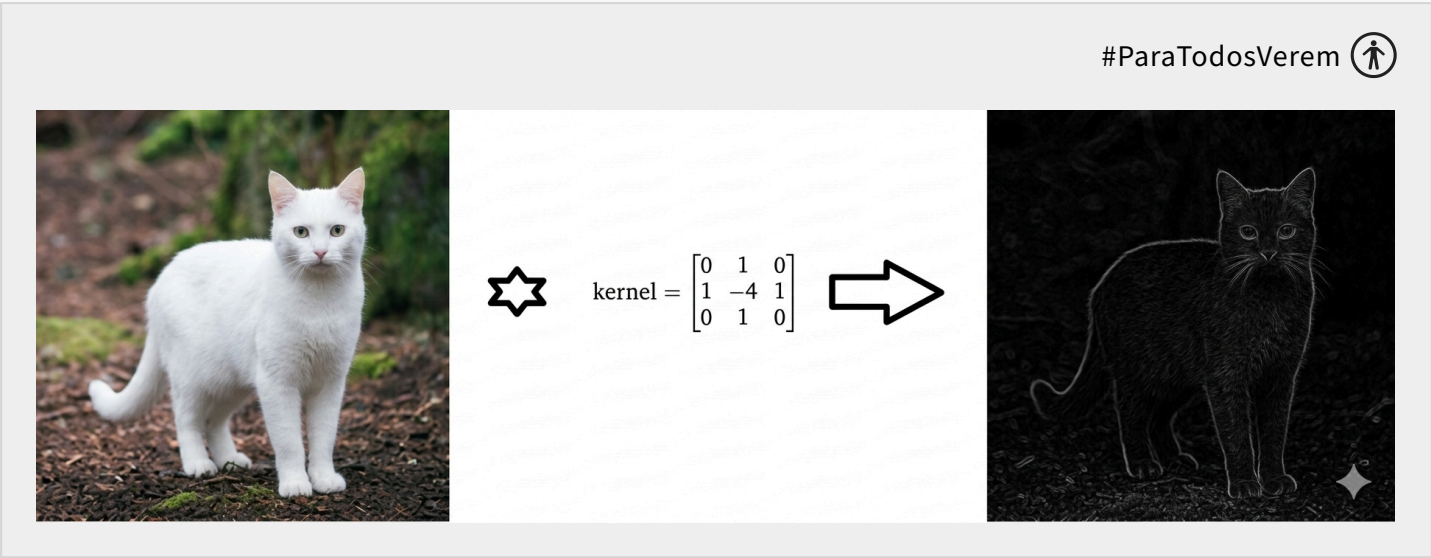


Fonte: Eunguru.

A convolução é o principal mecanismo das CNNs, pois permite que padrões visuais sejam identificados independentemente da sua posição na imagem. Um mesmo filtro pode responder a uma característica específica, como uma borda horizontal ou vertical, em qualquer região. Ao combinar múltiplos filtros e várias camadas convolucionais, a rede passa a extrair informações cada vez mais complexas, evoluindo de características simples para estruturas visuais mais elaboradas, como partes de objetos e, posteriormente, o objeto completo.

Os *feature maps* gerados por cada filtro formam, em conjunto, uma representação rica da imagem original. Essa representação é utilizada pelas camadas seguintes da rede para realizar tarefas como classificação ou detecção. Graças a esse processo hierárquico de extração de características, as CNNs alcançam elevado desempenho em aplicações como reconhecimento facial, identificação de objetos e análise de imagens médicas.

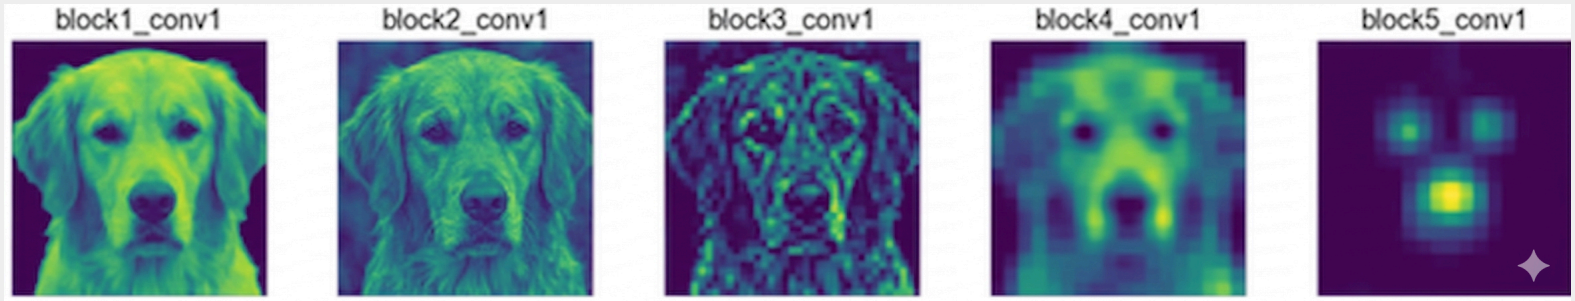
Na prática, o filtro percorre toda a imagem de entrada, deslocando-se *pixel* a *pixel* ou em passos definidos, denominados *strides*. Em cada posição, o resultado da convolução indica o grau de presença de determinada característica naquela região. O resultado dessa varredura é o mapa de características, que evidencia visualmente os padrões identificados pelo filtro, conforme exemplificado na figura a seguir. Esses mapas servem como base para as etapas subsequentes do processamento na CNN.



© O autor - gerado com auxílio de IA – IA – Gemini.

Esse procedimento pode ser repetido em diversas camadas, utilizando diferentes conjuntos de filtros. A cada nova camada convolucional, os *feature maps* tornam-se mais abstratos e informativos, conforme ilustrado na figura a seguir. Esse empilhamento de convoluções possibilita que a rede transite de padrões visuais simples, como bordas e texturas, para representações de maior nível, adequadas à tarefa final de reconhecimento ou classificação.

#ParaTodosVerem



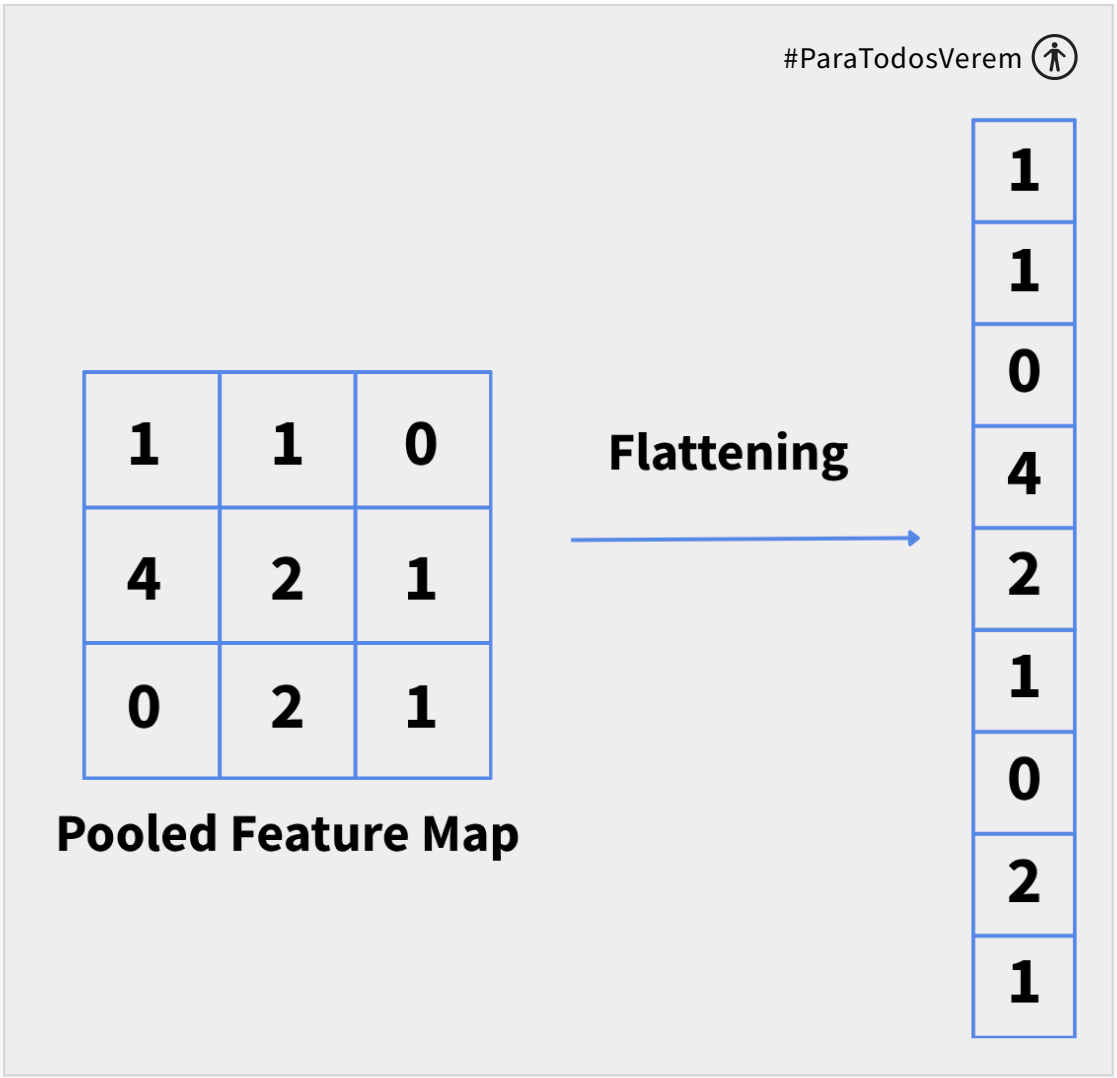
© O autor - gerado com auxílio de IA – Gemini.

Durante esse processo, técnicas auxiliares são frequentemente aplicadas para aprimorar o aprendizado da rede. O *pooling* reduz a dimensionalidade dos *feature maps*, tornando o modelo mais eficiente e menos sensível a pequenas variações locais. O *padding* é utilizado para preservar o tamanho da imagem ao longo das convoluções, evitando a perda de informações nas bordas. Por sua vez, as funções de ativação introduzem não linearidades no modelo, permitindo que padrões visuais mais complexos sejam aprendidos.

Um dos principais desafios para o cientista de dados está na configuração adequada dessas camadas, filtros e parâmetros. Definir a profundidade da rede, a quantidade de filtros, as funções de ativação e as estratégias complementares requer tanto embasamento teórico quanto experimentação prática. Além disso, arquiteturas distintas podem responder de maneira diferente aos mesmos ajustes, tornando esse processo iterativo e essencial para alcançar o melhor desempenho possível em tarefas de visão computacional.

Flattening

Após a geração dos *feature maps* pelas camadas de convolução e *pooling*, aplica-se a etapa denominada *flattening*, conforme ilustrado na próxima figura. Esse procedimento tem como objetivo converter a estrutura resultante, geralmente formada por múltiplas matrizes bidimensionais, em um único vetor unidimensional, organizado em uma coluna com N elementos. Essa transformação é necessária porque as camadas densas (*fully connected layers*), responsáveis pela classificação, operam exclusivamente com entradas lineares.



Fonte: adaptado de Brandizzi (2020).

Nessa fase da rede, as características extraídas nas etapas anteriores são reorganizadas de forma adequada para que possam ser combinadas pelos neurônios da camada densa. Nesse estágio, o modelo integra as informações aprendidas ao longo das convoluções, aplicando pesos e funções de ativação para determinar a classe mais provável associada à imagem de entrada.

Dessa forma, o *flattening* funciona como um elo entre a extração de características e o processo de decisão do modelo, garantindo que todo o conhecimento capturado pelos filtros seja efetivamente utilizado na etapa final de predição, contribuindo para a eficiência e a precisão da rede neural convolucional.

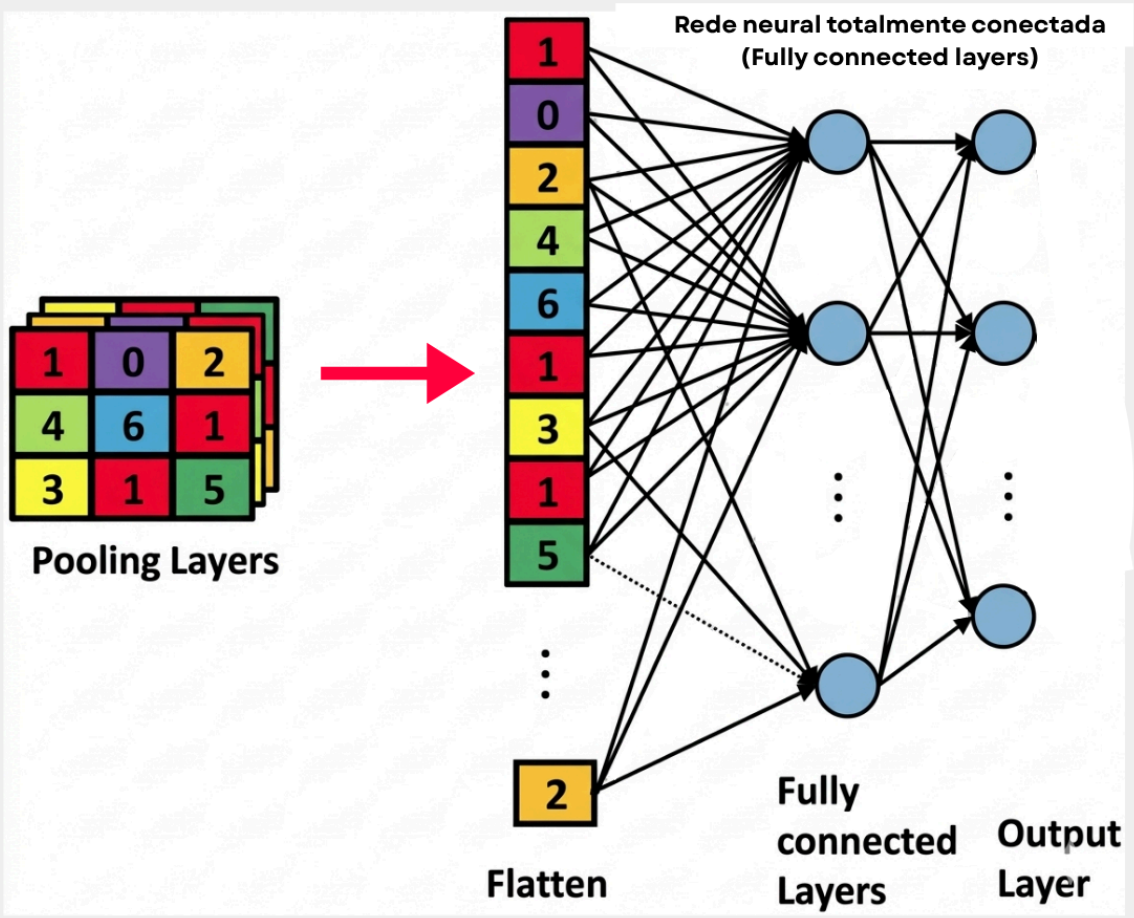
Camada densa

A camada densa representa a etapa final de uma rede neural convolucional e corresponde a uma rede neural totalmente conectada (*fully connected layer*), responsável por realizar a classificação propriamente dita. Nessa estrutura, cada neurônio recebe como entrada todos os valores do vetor unidimensional gerado após o processo de *flattening*, possibilitando a combinação das características extraídas nas etapas anteriores e a identificação dos padrões que diferenciam uma classe das demais.

O número de neurônios presentes nessa camada varia de acordo com a complexidade do problema tratado, sendo comum a utilização de mais de uma camada densa para ampliar a capacidade de representação do modelo. Para melhorar o desempenho e reduzir o risco de *overfitting*, podem ser aplicadas técnicas específicas, como o *dropout*, que consiste em desativar aleatoriamente uma fração dos neurônios durante o treinamento. Essa estratégia força a rede a aprender representações mais generalizáveis, evitando dependência excessiva de conexões individuais.

Dessa forma, a camada densa atua como o estágio final de tomada de decisão, consolidando todas as informações obtidas ao longo das convoluções e produzindo a predição da classe associada à imagem analisada.

#ParaTodosVerem



Fonte: adaptado de Brandizzi, 2020.

O ajuste dos pesos internos da rede durante o treinamento é realizado por meio do algoritmo de *backpropagation*, cujo objetivo é minimizar o erro gerado na camada de saída. Esse mecanismo permite que a rede aprenda progressivamente com os dados, ajustando seus parâmetros a cada iteração para melhorar o desempenho da classificação. A importância do *backpropagation* é tão significativa que ele é considerado o principal fator viabilizador do treinamento eficiente de redes neurais profundas.

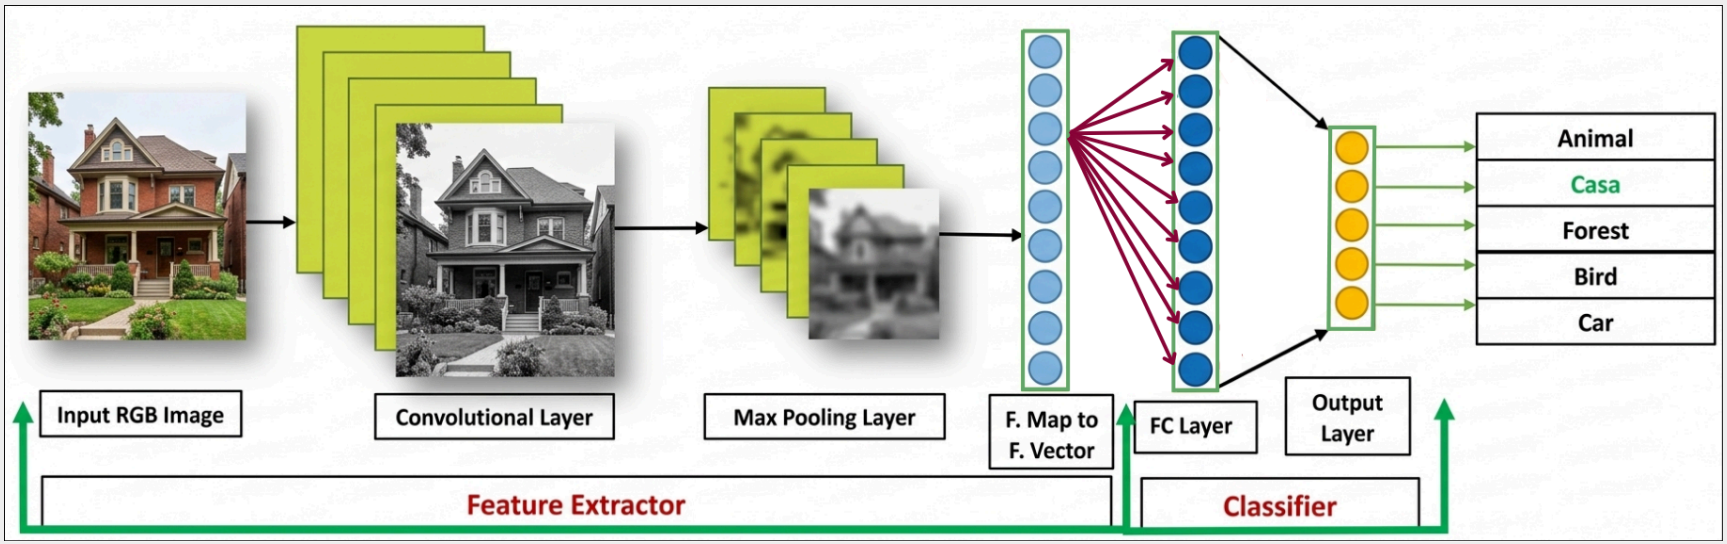
De forma geral, o algoritmo opera em duas fases complementares:

- No *forward pass*, os dados de entrada percorrem a rede camada por camada até a produção de uma saída.
- Em seguida, no *backward pass*, o erro é calculado com base na função de perda e propagado de volta pelas camadas por meio da regra da cadeia, permitindo a atualização dos pesos e a redução do erro nas iterações seguintes.

Esse ciclo é repetido inúmeras vezes até que a rede encontre um conjunto de parâmetros que minimize o erro global. Para tornar esse processo mais rápido e estável, o *backpropagation* pode ser combinado com diferentes métodos de otimização, como *gradient descent*, *momentum* e Adam, que auxiliam na convergência do treinamento.

De maneira sintética, uma rede neural convolucional é composta por camadas convolucionais, camadas de *pooling*, operações de normalização, funções de ativação, etapa de *flattening* e, por fim, camadas densas totalmente conectadas, responsáveis pela decisão final do modelo.

#ParaTodosVerem



Fonte: adaptado de Brandizzi, 2020.

Após o treinamento, o modelo obtido é capaz de reconhecer padrões visuais e aplicar esse conhecimento em diferentes contextos práticos. Exemplos incluem veículos autônomos interpretando placas de trânsito, sistemas de vigilância baseados em reconhecimento facial ou aplicações agrícolas que identificam tipos de plantas para otimizar irrigação e monitoramento. Em todos esses cenários, a rede utiliza o aprendizado adquirido para classificar novas imagens de forma rápida e precisa.

Por fim, cabe destacar que essa descrição apresenta apenas uma visão geral de um dos métodos mais difundidos da visão computacional: as redes neurais convolucionais. Apesar da aparente simplicidade conceitual, essas redes se apoiam em fundamentos matemáticos, estatísticos e computacionais complexos, envolvendo conceitos como gradientes, funções de ativação, otimização, álgebra linear, cálculo diferencial e probabilidade.

Além disso, o avanço das CNNs está diretamente ligado à evolução do poder computacional, especialmente das GPUs, e à disponibilidade de grandes volumes de dados, fatores que consolidaram essa tecnologia como um dos pilares da visão computacional moderna.

A análise em dispositivos móveis e dispositivos portáteis

A análise forense em dispositivos móveis e dispositivos portáteis é um dos ramos mais relevantes e desafiadores da computação forense contemporânea. *Smartphones*, *tablets*, *notebooks* leves, *smartwatches* e outros dispositivos portáteis concentram uma grande quantidade de informações pessoais, profissionais e sensíveis, o que os torna fontes críticas de evidências em investigações criminais, cíveis, corporativas e acadêmicas. Realizar corretamente esse tipo de análise exige metodologia rigorosa, respeito a princípios legais, domínio técnico e cuidado com a preservação da integridade dos dados.

O primeiro ponto fundamental é o **planejamento** da análise forense. Antes mesmo de qualquer contato técnico com o dispositivo, o perito deve compreender o contexto da investigação, os objetivos da perícia e o escopo autorizado legalmente. Isso envolve verificar a existência de mandado judicial, autorização do proprietário ou enquadramento legal que permita a coleta de dados. Nessa etapa, define-se quais informações são relevantes, como mensagens, registros de chamadas, dados de localização, arquivos multimídia, aplicativos, histórico de navegação ou metadados, evitando coletas excessivas que possam violar direitos fundamentais.

Em seguida, inicia-se a fase de **identificação** e **preservação da evidência.** Ao lidar com dispositivos móveis, a preservação é especialmente crítica devido à volatilidade dos dados. Um simples desbloqueio, conexão à internet ou desligamento inadequado pode alterar informações importantes. Sempre que possível, o dispositivo deve ser isolado de redes externas, utilizando-se técnicas como o modo avião ou bolsas de isolamento eletromagnético (Faraday). Além disso, deve-se registrar detalhadamente o estado inicial do dispositivo: modelo, fabricante, número de série, sistema operacional, nível de bateria, data e hora, condições físicas e quaisquer telas exibidas no momento da apreensão.

A cadeia de custódia é um princípio central em toda a análise forense. Desde o primeiro contato até a apresentação do laudo, deve haver documentação contínua de quem teve acesso ao dispositivo, quando, por qual motivo e sob quais condições. Em dispositivos portáteis, isso é ainda mais importante, pois a defesa pode questionar facilmente a integridade da evidência alegando manipulação indevida ou alteração de dados.

Após a preservação, passa-se à **aquisição dos dados**, que é uma das etapas mais técnicas e sensíveis do processo. Em dispositivos móveis, a aquisição pode ocorrer de diferentes formas, dependendo do nível de acesso permitido pelo sistema e das proteções implementadas pelo fabricante. Entre as principais abordagens estão a aquisição lógica, a aquisição física e, em casos específicos, a aquisição por meio de *backups*.

+ **Aquisição lógica**

  Permite extrair dados acessíveis por meio das interfaces do sistema operacional, como contatos, mensagens, registros de chamadas e alguns arquivos de aplicativos.

+ **Aquisição física**

  Busca obter uma cópia *bit a bit* da memória do dispositivo, permitindo acesso mais profundo, inclusive a dados apagados. Contudo, essa abordagem é mais complexa e pode exigir técnicas avançadas, pois nem sempre é possível

usá-la devido à criptografia, aos bloqueios de *hardware* e às atualizações constantes dos sistemas móveis. Em todos os casos, a geração de *hashes* criptográficos é indispensável para comprovar a integridade dos dados coletados.

Com os dados devidamente adquiridos, inicia-se a fase de **análise forense** propriamente dita. Nessa etapa, o perito examina as informações extraídas em busca de padrões, eventos relevantes, correlações temporais e evidências que respondam às questões da investigação. Em dispositivos móveis, a análise costuma abranger diferentes categorias de dados: comunicações (SMS, mensagens instantâneas, *e-mails*), registros de chamadas, dados de geolocalização, histórico de aplicativos, arquivos multimídia, documentos, registros do sistema e metadados associados.

A análise deve ser conduzida de forma sistemática e orientada por hipóteses investigativas.



EXEMPLO

Por exemplo: em um caso de fraude, pode-se buscar evidências de comunicação entre envolvidos, instalação de aplicativos suspeitos ou transferências de arquivos. Em um caso de violência ou ameaça, mensagens, áudios, imagens e registros de localização podem ser decisivos. Por sua vez, em contextos corporativos, o foco pode estar em vazamento de informações, uso indevido de aplicativos ou acesso não autorizado a sistemas internos.

Além disso, outro aspecto crucial é a **interpretação contextual dos dados**. Informações extraídas de dispositivos móveis raramente são autoexplicativas, pois o perito deve considerar o contexto temporal, o comportamento do usuário, o funcionamento dos aplicativos e as limitações técnicas da coleta:

- Dados de localização, por exemplo, podem ser gerados por GPS, redes Wi-Fi ou torres de telefonia, cada um com níveis distintos de precisão.
- Mensagens podem ter sido apagadas, editadas ou sincronizadas com serviços em nuvem, exigindo cautela na análise e na conclusão.

Além disso, é fundamental lidar adequadamente com dados apagados e artefatos residuais. Muitos sistemas móveis não removem imediatamente as informações da memória, mantendo fragmentos que podem ser recuperados. A identificação desses artefatos pode fornecer evidências valiosas, mas exige cuidado para evitar interpretações equivocadas, uma vez que nem sempre é possível determinar com precisão quando ou como determinado dado foi criado ou excluído.

A etapa seguinte é a **documentação** e a **elaboração do laudo pericial**. Todo o processo deve ser descrito de forma clara, objetiva e tecnicamente fundamentada. O laudo deve apresentar a metodologia adotada, as ferramentas utilizadas, os procedimentos de preservação e aquisição, e os resultados da análise. Em dispositivos móveis, é especialmente importante explicar limitações encontradas, como dados inacessíveis devido à criptografia ou às falhas de aquisição, garantindo transparência e credibilidade ao trabalho pericial.

Por fim, a análise forense em dispositivos móveis exige **atualização constante** do perito. Sistemas operacionais, modelos de dispositivos, mecanismos de segurança e aplicativos evoluem rapidamente, tornando obsoletas técnicas que eram eficazes há poucos anos. Assim, o profissional deve manter-se atualizado, testar metodologias, compreender novas formas de armazenamento e sincronização de dados e agir sempre de acordo com princípios éticos e legais.

A análise forense em dispositivos móveis e portáteis deve ser conduzida de forma metodológica, cuidadosa e juridicamente respaldada. Desde o planejamento inicial até a apresentação do laudo, cada etapa deve preservar a integridade da evidência, garantir a confiabilidade dos resultados e respeitar os limites legais da investigação. Diante da centralidade desses dispositivos na vida moderna, sua correta análise tornou-se indispensável para a produção de provas digitais robustas e tecnicamente defensáveis.

SAIBA MAIS

O YOLO (*you only look once*) é um modelo de detecção de objetos baseado em redes neurais convolucionais, desenvolvido para identificar e localizar objetos em imagens ou vídeos de forma rápida e eficiente. Esse método revolucionou a detecção de objetos ao realizar a identificação e a localização em uma única passagem pela imagem, tornando o processo extremamente rápido. Diferentemente de abordagens tradicionais, ele trata a detecção como um problema de regressão,

analisando toda a cena de uma só vez. Por essa razão, o YOLO é amplamente utilizado em aplicações em tempo real, como carros autônomos, drones e sistemas de vigilância.

Questões reflexivas

EXERCÍCIO

Questão 1:

A visão computacional levanta reflexões importantes sobre até que ponto máquinas devem interpretar e tomar decisões com base em imagens do mundo real. Quando um sistema erra uma classificação, quem é responsável pelas consequências desse erro: o algoritmo, os dados ou o ser humano que o projetou?

Questão 2:

Sistemas de visão computacional são amplamente utilizados em áreas sensíveis, como segurança pública, diagnóstico médico e veículos autônomos. Considerando esses contextos, quais riscos podem surgir quando decisões importantes dependem exclusivamente de classificações automáticas realizadas por algoritmos?

Questão 3:

A qualidade dos dados utilizados para treinar modelos de visão computacional influencia diretamente o desempenho do sistema. De que forma a escolha e a preparação desses dados pode impactar os resultados obtidos pelos algoritmos?

Resposta

Questão 1:

Sugestão de resposta:

Embora o algoritmo execute a tarefa de classificação, a responsabilidade final geralmente recai sobre os seres humanos envolvidos no desenvolvimento e implantação do sistema. Isso inclui quem projetou o modelo, selecionou os dados de treinamento e decidiu aplicá-lo em determinado contexto. Além disso, erros podem surgir de dados enviesados, limitações do modelo ou uso inadequado da tecnologia. Dessa forma, é fundamental que sistemas de visão computacional sejam desenvolvidos com transparência, validação rigorosa e supervisão humana. Pensar esses limites é essencial para o uso ético e responsável da visão computacional na sociedade.[CP1]

Questão 2:

Sugestão de resposta:

Quando decisões críticas dependem apenas de algoritmos, existe o risco de erros de classificação, vieses nos dados de treinamento e falta de interpretação adequada dos resultados. Em contextos sensíveis, como medicina ou segurança, um erro pode gerar consequências graves, como diagnósticos incorretos ou identificação equivocada de pessoas. Por isso, é importante que esses sistemas funcionem como ferramentas de apoio à decisão, e não como substitutos completos da análise humana.

Questão 3:

Sugestão de resposta:

Se os dados de treinamento forem incompletos, enviesados ou pouco representativos da realidade, o modelo poderá aprender padrões incorretos ou limitados. Isso pode levar a classificações imprecisas quando o sistema for aplicado em situações reais. Portanto, a seleção cuidadosa, a diversidade das imagens e o processo de validação dos dados são fundamentais para garantir modelos mais robustos, confiáveis e justos.

Ligando conceitos

Ao integrar convoluções, *pooling*, *flattening* e camadas densas, percebemos que a visão computacional é um processo contínuo de abstração da informação visual. Cada etapa contribui para transformar *pixels* em conhecimento utilizável.

A conexão entre teoria, modelos matemáticos e aplicações reais evidencia como decisões automatizadas emergem de dados visuais. Compreender essa cadeia completa é essencial para desenvolver soluções eficazes e responsáveis em visão computacional.

Referências

BRANDIZZI, L. **Visão computacional**: o que é? como funciona? Brasília: Serviço Federal de Processamento de Dados (SERPRO), 7 abr. 2020. Disponível em: https://www.serpro.gov.br/menu/noticias/noticias-2020/o-que-eh-visao-computacional. Acesso em: 25 mar. 2026.

EASTTOM, C. **An in-depth guide to mobile device forensics**. 1. ed. Boca Raton: CRC Press, 2021.

GONZALEZ, R. C.; WOODS, R. E. **Digital Image Processing**. 4. ed. New York: Pearson, 2018.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. Cambridge: MIT Press, 2016.

JAMES, J. E. Foundations of mobile forensics: an academic approach. **Issues in Information Systems**, v. 25, n. 3, p. 94–108, 2024.

SZELISKI, R. **Computer Vision**: Algorithms and Applications. 2. ed. London: Springer, 2022.



© PUCPR - Todos os direitos reservados.