



Computação Natural

UNIDADE 08

Visão geral sobre demais temas de pesquisa e uma revisão sobre a disciplina

A biologia nos ensina que o sistema imunológico dos vertebrados é uma complexa coleção de células, moléculas e órgãos, responsável por manter um equilíbrio dinâmico no corpo. Esse sistema é capaz de reconhecer sinais, tanto internos quanto externos, e controla a ação dos componentes imunes, influenciando o comportamento de outros sistemas. Além disso, ele aprende a combater agentes causadores de doenças, extraíndo informações desses agentes (CASTRO, 2006).


Baseando-se no conceito de sistemas imunológicos, definimos os **sistemas imunológicos artificiais** como qualquer sistema ou ferramenta computacional que utilize ideias e metáforas do sistema imunológico biológico para a resolução de problemas (CASTRO, 2008). Essa área de pesquisa tem aplicações em uma ampla gama

de campos, desde a biologia até a robótica. Existem duas linhas principais: uma centrada na modelagem do sistema imunológico para desenvolver e testar teorias sobre seu funcionamento e outra no uso de metáforas imunológicas para a criação de algoritmos computacionais (BRABAZON; O'NEILL; MCGARRAGHY, 2015).

A **evolução diferencial**, desenvolvida por Storn e Price (1997), é amplamente utilizada em várias aplicações práticas. Como a maioria dos **algoritmos evolutivos**, ela é um otimizador baseado em populações que aborda o problema a partir de múltiplos pontos iniciais selecionados aleatoriamente, amostrando a função objetivo em cada um deles (STORN; PRICE; LAMPINEN, 2006). Assim como outros **algoritmos evolutivos**, a **evolução diferencial** integra conceitos de mutação, recombinação e seleção com base no valor do *fitness*. Ela gera iterativamente soluções eficazes para um problema manipulando uma população de soluções. Um aspecto adicional que a assemelha aos algoritmos evolutivos é a sua capacidade de autoadaptação durante a etapa de mutação, gerando diversidade na população de soluções (BRABAZON; O'NEILL; MCGARRAGHY, 2015).

Revisão de temas

Após discutir os temas desta semana, vamos resumir o que aprendemos até o momento. Ao longo da disciplina, nos dedicamos a explorar tópicos específicos que são centrais no campo da pesquisa. No que se refere a problemas de otimização, estudamos a **computação evolutiva**, inspirada na evolução biológica. Dentro desse campo, focamos em **algoritmos genéticos**, que simulam processos de seleção natural e reprodução para resolver problemas (WIRSANDY, 2020). A figura 1 ilustra o conceito de evolução por seleção natural proposto por Darwin. Além disso, abordamos conceitos fundamentais relacionados a esse tema, incluindo *fitness*, cruzamento, seleção e mutação.



Além dos problemas de otimização, também abordamos algoritmos baseados em enxame, nos quais os indivíduos podem ser tanto insetos quanto humanos (CASTRO, 2006). Escolhemos dois algoritmos para apresentar: o **algoritmo da colônia de abelhas artificial** e a **otimização da colônia de formigas**. O primeiro simula a busca por alimentos realizada pelas abelhas (TAWHID; TEOTIA; ELMILIGI, 2021), enquanto o segundo imita o comportamento eficiente das formigas na localização de recursos e no transporte destes para a colônia (HARTMANN *et al.*, 2011). No algoritmo das abelhas, o foco é na quantidade de néctar, e no das formigas, a ênfase é na trilha de feromônio.




Figura 2: Formigue sua solução. Fonte: ©wladislawka/Adobe Stock.

Finalmente, exploramos a **vida artificial** e a **computação baseada em DNA**. A vida artificial se dedica a recriar formas de sistemas naturais (CASTRO, 2006). No campo da pesquisa, estudamos exemplos clássicos envolvendo rebanhos, manadas e cardumes, além de aplicações mais recentes na robótica, como o robô Aibo, ilustrado na figura 3. Por outro lado, a computação baseada em DNA utiliza biomoléculas e operações biomoleculares para solucionar problemas e realizar cálculos, representando uma interseção singular entre a ciência da computação e a biologia molecular (CASTRO, 2006).




Figura 3: Robô Aibo. Fonte: ©293118554/Adobe Stock.

| Conclusão e Referências

Olá! Com o término da oitava semana da disciplina, concluímos uma fase importante do curso. Nesta semana, iniciamos o estudo da imunocomputação e da evolução diferencial, e finalizamos o conteúdo com uma revisão abrangente dos temas já abordados: computação evolutiva, algoritmos genéticos, sistemas de enxame, vida artificial e computação baseada em DNA.

Exploramos como os sistemas imunológicos artificiais aplicam conceitos do sistema imunológico biológico para resolver problemas (CASTRO, 2006). Observamos também que a evolução diferencial, semelhante a outros algoritmos evolutivos, é um otimizador baseado em populações que emprega mutação, recombinação e seleção (STORN; PRICE; LAMPINEN, 2006; BRABAZON; O'NEILL; MCGARRAGHY, 2015).

Concluimos a semana com uma revisão dos diversos temas estudados anteriormente. Aprofundamos nosso conhecimento em algoritmos genéticos, abordando aspectos como *fitness*, cruzamento, seleção e mutação. No contexto dos algoritmos de enxame, analisamos o algoritmo da colônia de abelhas artificial e a otimização da colônia de formigas, inspirados nos comportamentos desses insetos. Finalmente, revisitamos os conceitos de vida artificial e computação baseada em DNA, fundamentais na área de computação natural.

BRABAZON, A.; O'NEILL, M.; MCGARRAGHY, S. **Natural computing algorithms**. Berlin: Springer, 2015.

CASTRO, L. N. **Fundamentals of natural computing**: basic concepts, algorithms, and applications. [S.l.]: CRC, 2006.

CASTRO, L. N. **Fundamentals of natural computing**: an overview. *Physics of Life Reviews*, [S.l.], v. 4, n. 1, p. 1-36, 2007.

HARTMANN, S. A. *et al.* Social insect societies for the optimization of dynamic NP-hard problems. *In*: XIAO, Y. (Ed.). **Bio-inspired computing and networking**. [S.l.]: CRC, 2011. p. 43-68.

PRICE, K.; STORN, R. M.; LAMPINEN, J. A. **Differential evolution**: a practical approach to global optimization. [S.l.]: Springer, 2006.

STORN, R.; PRICE, K. Differential evolution: a simple and efficient heuristic for global optimization over continuous spaces. **Journal of Global Optimization**, [s.l.], v. 11, n. 4, p. 341-359, 1997.

TAWHID, A.; TEOTIA, T.; ELMILIGI, H. Machine learning for optimizing healthcare resources. *In*: XHAFA, F. (Ed.). **Machine learning, big data, and IoT for medical informatics**. [S.l.]: Academic Press, 2021. p. 215-239.

WIRSANSKY, E. **Hands-on genetic algorithms with Python**: applying genetic algorithms to solve real-world deep learning and artificial intelligence problems. [S.l.]: Packt, 2020.



© PUCPR - Todos os direitos reservados.